

**Analisis dan Evaluasi Prediksi Harian PM10 Jakarta
Menggunakan Model Hibrida Random
Forest-ARIMA Berbasis Rekayasa Fitur**

Laporan Tugas Akhir

Oleh

**Muhammad Rafi Dhiyaulhaq
18222069**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
Mei 2026**

LEMBAR PENGESAHAN

Analisis dan Evaluasi Prediksi Harian PM10 Jakarta Menggunakan Model Hibrida Random Forest-ARIMA Berbasis Rekayasa Fitur

Laporan Tugas Akhir

Oleh

Muhammad Rafi Dhiyaulhaq
18222069

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Laporan Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 30 Mei 2026

Pembimbing

Dr. Fetty Fitriyanti Lubis, S.T., M.T.

NIP. 118110071

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan tugas akhir ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan laporan tugas akhir.
3. Isi laporan ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 30 Mei 2026

Muhammad Rafi Dhiyaulhaq

NIM: 18222069

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan dokumen Tugas Akhir ini, saya menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu di dalam proses penulisan, seperti yang tercantum dalam tabel berikut.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Google Gemini	Rendah	Bab I - VII
2	Pembuatan teks	Google Gemini	Rendah	Bab II
3	Pembuatan grafik, gambar, atau ilustrasi	Google Gemini	Rendah	Bab III
4	Pencarian informasi atau referensi	Google Gemini	Rendah	Bab II
5	Penyusunan bahan diskusi	Google Gemini	Rendah	Bab VI
6	Penyusunan kode program	Google Gemini	Rendah	Lampiran A
7	Penyusunan formula atau perhitungan matematis	Tidak ada	Tidak ada	Tidak ada
8	Penyusunan konsep desain atau algoritma	Google Gemini	Rendah	Bab III
9	Penyusunan analisis data	Google Gemini	Rendah	Bab V dan VI
10	Penyusunan kesimpulan atau rekomendasi	Google Gemini	Rendah	Bab VII

Bandung, 15 Mei 2026

Muhammad Rafi Dhiyaulhaq

NIM: 18222069

ABSTRAK

Analisis dan Evaluasi Prediksi Harian PM₁₀ Jakarta Menggunakan Model Hibrida Random Forest-ARIMA Berbasis Rekayasa Fitur

oleh

Muhammad Rafi Dhiyaulhaq

18222069

Penurunan kualitas udara di DKI Jakarta, khususnya akibat tingginya konsentrasi partikulat PM₁₀, memerlukan sistem peringatan dini untuk membantu mitigasi dampak kesehatan masyarakat. Banyak model prediksi saat ini memproses data polutan mentah tanpa mengekstraksi komponen temporalnya, serta memiliki struktur yang sulit diinterpretasikan secara langsung oleh pemangku kebijakan. Selain itu, penggunaan model tunggal memiliki batasan operasional; *Random Forest* dapat memetakan pola non-linier namun rentan terhadap autokorelasi pada residu, sedangkan model ARIMA efektif dalam memodelkan komponen linier deret waktu namun kurang adaptif terhadap lonjakan data yang ekstrem. Oleh karena itu, penelitian ini menerapkan arsitektur hibrida *Random Forest-ARIMA* sekuensial yang dikombinasikan dengan teknik *feature engineering*. Proses rekayasa fitur menghasilkan 15 variabel turunan, meliputi efek jeda waktu (*lag*), rata-rata bergerak (*rolling statistics*), pola temporal, dan interaksi antarpolutan, yang diekstrak dari dataset Indeks Standar Pencemar Udara (ISPU) DKI Jakarta periode 2010–2025. Evaluasi menggunakan *time-series cross-validation (5-fold)* menunjukkan bahwa model hibrida yang diusulkan menghasilkan nilai *Root Mean Square Error* (RMSE) sebesar 13,4004. Nilai kesalahan prediksi tersebut lebih rendah jika dibandingkan dengan model ARIMA murni (RMSE 18,8432), *Random Forest* murni (RMSE 13,5717), serta algoritma komparasi XGBoost (RMSE 14,3307). Hasil studi ablasi menunjukkan bahwa integrasi fitur turunan berkontribusi dalam menurunkan nilai galat prediksi. Model ini juga dilengkapi dengan metode *SHapley Additive exPlanations* (SHAP) untuk menganalisis kontribusi setiap fitur terhadap hasil prediksi secara lebih transparan.

Kata kunci: PM₁₀, Kualitas Udara, *Random Forest*, ARIMA, *Feature Engineering*, *Explainable AI*, SHAP.

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya, sehingga penulis dapat menyelesaikan Laporan Tugas Akhir yang berjudul "Analisis dan Evaluasi Prediksi Harian PM10 Jakarta Menggunakan Model Hibrida Random Forest-ARIMA Berbasis Rekayasa Fitur". Laporan ini disusun sebagai salah satu syarat untuk menyelesaikan program pendidikan Sarjana pada Program Studi Sistem dan Teknologi Informasi, Sekolah Teknik Elektro dan Informatika, Institut Teknologi Bandung.

Penulis menyadari bahwa penyelesaian Tugas Akhir ini tidak terlepas dari bimbingan, dukungan, serta bantuan dari berbagai pihak. Oleh karena itu, penulis mengucapkan terima kasih dan penghargaan yang sebesar-besarnya kepada:

1. Allah SWT atas segala rahmat dan karunia-Nya, serta semua pihak yang telah mendoakan dan mendukung kelancaran Tugas Akhir ini.
2. Ibu Dr. Fetty Fitriyanti Lubis, S.T., M.T., selaku Dosen Pembimbing atas segala bimbingan dan arahan, serta Bapak I Gusti Bagus Baskara Nugraha, selaku Ketua Program Studi atas dukungan akademik yang diberikan.
3. Keluarga tercinta, khususnya kedua orang tua dan adik, atas doa, perhatian, serta dukungan moral dan material yang senantiasa diberikan kepada penulis.
4. Seluruh teman baik dan rekan kerja atas kolaborasi, bantuan, dan kebersamaan yang saling menguatkan dalam menyelesaikan masa studi ini.

Penulis menyadari bahwa Laporan Tugas Akhir ini masih memiliki batasan dan kekurangan. Oleh karena itu, kritik dan saran yang membangun sangat diharapkan untuk perbaikan di masa mendatang. Akhir kata, semoga laporan ini dapat memberikan manfaat bagi pembaca serta menjadi referensi bagi penelitian selanjutnya di bidang pemodelan kualitas udara.

Bandung, 30 Mei 2026

Penulis

Muhammad Rafi Dhiyaulhaq

DAFTAR ISI

LEMBAR PENGESAHAN	iii
PERNYATAAN ORISINALITAS	v
PERNYATAAN PENGGUNAAN AI	vii
ABSTRAK	ix
KATA PENGANTAR	xi
DAFTAR ISI	xiii
DAFTAR GAMBAR	xix
DAFTAR TABEL	xxi
DAFTAR PERSAMAAN	xxiii
DAFTAR ALGORITMA	xxv
DAFTAR SIMBOL	xxvii
DAFTAR SINGKATAN	xxxii
I PENDAHULUAN	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	3
I.3 Tujuan Penelitian	4
I.4 Kriteria Keberhasilan	4
I.5 Manfaat Penelitian	5
I.6 Kontribusi Penelitian	5
I.7 Batasan Masalah	6
I.8 Metodologi Penelitian	7
I.9 Sistematika Penulisan	9
II STUDI LITERATUR	11
II.1 Pemetaan Riset Terkait (<i>State-of-the-Art</i>)	11
II.1.1 Matriks Perbandingan Literatur Terkini	11
II.1.2 Identifikasi Kesenjangan Riset (<i>Research Gap Analysis</i>)	12
II.2 Domain Sains Atmosfer dan Paradigma Regulasi ISPU	13
II.2.1 Krisis Polusi Jakarta dan Integritas Dataset	14
II.2.2 Kalkulasi Indeks Standar Pencemar Udara (ISPU)	15
II.2.3 Mekanisme Fotokimia: Justifikasi Interaksi Fitur Komposit	16
II.3 Fondasi Teoretis Analisis Deret Waktu (<i>Time Series Analysis</i>)	16
II.3.1 Karakteristik Komponen Temporal	17
II.3.2 Prinsip Stasioneritas dan Formulasi Pengujian ADF	17
II.3.3 <i>Autocorrelation</i> dan <i>Partial Autocorrelation Function</i> (ACF & PACF)	18
II.4 Taksonomi Algoritma Regresi dan Teori Hibridisasi	18
II.4.1 Algoritma <i>Random Forest Regressor</i>	18
II.4.2 Arsitektur <i>AutoRegressive Integrated Moving Average</i> (ARIMA)	20
II.4.3 Hibridisasi Sekuensial (Metodologi Asimilasi Zhang dan Justifikasi Residu)	21
II.4.4 Justifikasi Pemodelan Residu Linier Menggunakan ARIMA	21

II.5	Rekayasa Fitur (<i>Feature Engineering</i>) Dimensi Atmosferik	23
II.5.1	Kalkulasi Jeda Temporal (<i>Lag Features</i>)	24
II.5.2	Metrik Tren Berjalan (<i>Rolling Window Statistics</i>)	24
II.5.3	Penanda Temporal Kategorikal dan Interaksi Polutan	25
II.5.4	Spesifikasi Matriks Fitur Prediktor	26
II.6	Prosedur Penyetelan Parameter Menggunakan Optuna	27
II.6.1	Perbandingan Metode Grid Search dan Pencarian Probabilistik	27
II.6.2	Mekanisme Pencarian Berbasis <i>Tree-structured Parzen Estimator</i> (TPE)	28
II.6.3	Prosedur Pemangkasan Percobaan (<i>Pruning</i>)	28
II.7	Skalabilitas dan Kompleksitas Komputasi Algoritma	28
II.7.1	Kompleksitas Komputasi Fase Primer: <i>Random Forest</i>	29
II.7.2	Kompleksitas Komputasi Fase Sekunder: Arsitektur ARIMA	29
II.8	Interpretabilitas Model menggunakan SHAP	30
II.8.1	Justifikasi Validitas SHAP pada Model Hibrida Sekuensial	30
II.8.2	Distribusi Atribusi <i>Shapley Value</i>	31
II.8.3	Interpretasi Visual Diagnostik SHAP	31
II.9	Prosedur Pengukuran Galat dan Skema Validasi Temporal	32
II.9.1	Metrik <i>Root Mean Square Error</i> (RMSE)	32
II.9.2	Metrik <i>Mean Absolute Error</i> (MAE) dan Koefisien Determinasi (R^2)	32
II.9.3	Skema Validasi Temporal <i>Time-Series Forward Chaining</i>	33
III	ANALISIS MASALAH	35
III.1	Analisis Kondisi Saat Ini dan Kesenjangan Sistem	35
III.1.1	Arsitektur Sistem Pemantauan Berjalan	35
III.1.2	Analisis Kesenjangan (<i>Gap Analysis</i>) dan Keterbatasan Literatur	36
III.2	Analisis Karakteristik Dataset Kualitas Udara (<i>Data Profiling</i>)	37
III.2.1	Analisis Integritas Data dan Kelayakan Multivariat	37
III.2.2	Statistik Deskriptif Global per Stasiun	38
III.2.3	Karakteristik Spasial-Temporal per Stasiun Pemantauan	39
III.2.3.1	Stasiun DKI1 (Bunderan HI)	39
III.2.3.2	Stasiun DKI2 (Kelapa Gading)	40
III.2.3.3	Stasiun DKI3 (Jagakarsa)	41
III.2.3.4	Stasiun DKI4 (Lubang Buaya)	42
III.2.3.5	Stasiun DKI5 (Kebon Jeruk)	43
III.2.4	Analisis Heterogenitas Spasial Melalui Uji Statistik	44
III.2.5	Analisis Autokorelasi dan Musiman	44
III.3	Analisis Domain: Kausalitas dan Dinamika Polutan	45
III.3.1	Analisis Kausalitas Lintas Waktu (<i>Cross-Correlation Analysis</i>)	46
III.3.2	Mekanisme Fisik dan Kimia Pembentukan Partikulat Sekunder	47
III.4	Formalisasi Masalah Matematis	48
III.5	Desain Ekstraksi Fitur Deret Waktu (<i>Feature Engineering</i>)	49

III.5.1	Fitur Jeda Temporal (<i>Lag Features</i>)	49
III.5.2	Fitur Statistik Jendela Berjalan (<i>Rolling Window Statistics</i>)	50
III.5.3	Fitur Interaksi Polutan dan Karakteristik Oksidasi	51
III.5.4	Fitur Temporal dan Siklus Aktivitas	51
III.6	Analisis Kebutuhan Sistem	52
III.6.1	Identifikasi Masalah Pengguna dan Pemetaan Regulasi	52
III.6.2	Kebutuhan Fungsional	53
III.6.3	Kebutuhan Nonfungsional	54
III.7	Analisis Pemilihan Paradigma Melalui <i>Analytical Hierarchy Process</i>	55
III.7.1	Justifikasi Penggunaan AHP Sebelum Evaluasi Empiris	55
III.7.2	Uji Konsistensi Matriks	57
III.7.3	Penilaian Alternatif Berdasarkan Kriteria	58
III.7.3.1	Evaluasi Terhadap Interpretabilitas (INT)	58
III.7.3.2	Evaluasi Terhadap Akurasi (AKR)	59
III.7.3.3	Evaluasi Terhadap Pola Kompleks (PLK)	59
III.7.3.4	Evaluasi Terhadap Efisiensi Komputasi (KMP)	60
III.7.3.5	Evaluasi Terhadap Kemudahan Implementasi (IMP)	60
III.7.4	Sintesis Global dan Solusi Terpilih	61
IV	PERANCANGAN	63
IV.1	Arsitektur Konseptual Sistem	63
IV.1.1	Sistem Berjalan (<i>Existing Sistem</i>)	63
IV.1.2	Arsitektur Usulan (<i>Proposed Sistem</i>)	64
IV.1.3	Perbandingan Sistem	65
IV.2	Desain Data Pipeline dan Pemodelan UML	66
IV.2.1	Diagram Alir Data (DFD)	67
IV.2.2	Desain Proses ETL (<i>Extract, Transform, Load</i>)	67
IV.2.3	Prosedur Pencegahan Kebocoran Data (<i>Data Leakage Prevention</i>)	68
IV.2.4	Activity Diagram Pemodelan Hibrida	69
IV.2.5	Sequence Diagram Sistem Inferensi Berkala	70
IV.3	Spesifikasi Algoritmik Rekayasa Fitur	71
IV.3.1	Matriks Transformasi Fitur	71
IV.3.2	Logika Pembangkitan Fitur Temporal dan Interaksi	72
IV.3.3	Mekanisme Standardisasi Skala	73
IV.4	Desain Arsitektur Hibrida Sekuensial	74
IV.4.1	Desain Fase Primer (<i>Random Forest</i>)	75
IV.4.2	Logika Kalkulasi Residu Temporal	75
IV.4.3	Desain Fase Sekunder (ARIMA)	76
IV.4.4	Desain Orkestrasi Penyetelan Parameter Menggunakan Optuna	77
IV.4.5	Justifikasi Efisiensi Optuna pada Ruang Hiperparameter Kombinasi	77
IV.5	Desain Skenario Eksperimen dan Validasi	78
IV.5.1	Desain Studi Ablasi (<i>Ablation Study</i>)	78
IV.5.2	Skema Validasi <i>TimeSeriesSplit</i> (<i>Forward Chaining</i>)	79

IV.6	Desain Modul Penjelasan Model dan Output Pelaporan	80
IV.6.1	Integrasi <i>TreeSHAP</i> pada <i>Pipeline</i> Inferensi	81
IV.6.2	Desain Laporan Prediksi Harian (<i>Output Mockup</i>)	82
V	IMPLEMENTASI	85
V.1	Lingkungan Implementasi	85
V.1.1	Spesifikasi Perangkat Keras dan Perangkat Lunak	85
V.1.2	Inisialisasi Pustaka (<i>Library Initialization</i>)	86
V.2	Akuisisi dan Eksplorasi Data Awal (EDA)	87
V.2.1	Pemuatan dan Imputasi Deret Waktu	87
V.2.2	Analisis Data Hilang (<i>Missing Values</i>)	88
V.2.3	Distribusi dan Keterkaitan Antarpolutan	89
V.2.4	Plot Tren Historis Stasiun (2010–2025)	90
V.3	Analisis Stasioneritas dan Dekomposisi Musiman	90
V.3.1	Korelasi Silang (Cross-Correlation Function / CCF)	91
V.3.2	Dekomposisi Deret Waktu Aditif	92
V.3.3	Uji Stasioneritas (ADF dan KPSS Test)	92
V.4	Implementasi Rekayasa Fitur (<i>Feature Engineering</i>)	94
V.4.1	Pembangkitan Matriks Fitur Komposit	94
V.5	Skema Validasi dan Pemisahan Data	94
V.5.1	Pemisahan Set Pelatihan dan Pengujian	95
V.5.2	Validasi Silang Deret Waktu (<i>TimeSeriesSplit</i>)	95
V.6	Implementasi Model Hibrida Sekuensial	96
V.6.1	Fase Primer dan Penyetelan Parameter menggunakan Optuna	97
V.6.2	Ekstraksi Residu dan Pemodelan Fase Sekunder	97
VI	EVALUASI	99
VI.1	Metodologi dan Metrik Evaluasi Eksperimen	99
VI.1.1	Metrik Evaluasi Statistik	99
VI.1.2	Skenario Pembanding (<i>Benchmarks</i>)	100
VI.2	Laporan Hasil Eksperimen dan Komputasi	100
VI.2.1	Hasil Studi Ablasi dan Justifikasi Fitur	101
VI.2.2	Perbandingan Performa Lintas Arsitektur	102
VI.2.3	Hasil Penyetelan Parameter (Optuna)	103
VI.2.4	Evaluasi Spasial per Stasiun Pemantau	104
VI.2.5	Analisis Kompleksitas Waktu Komputasi	105
VI.3	Analisis Komprehensif dan Pembahasan	107
VI.3.1	Interpretasi Atribusi Fitur Global dan Lokal (SHAP)	107
VI.3.2	Analisis Interaksi Fotokimiawi dan Musiman Berbasis Pengetahuan Domain	109
VI.3.3	Evaluasi Model Hibrida pada Kondisi Polusi Ekstrem	110
VI.3.4	Diskusi Fenomena Spasial dan Karakteristik Arsitektur	111
VII	PENUTUP	113
VII.1	Kesimpulan	113
VII.2	Saran	114

Lampiran A	KODE PROGRAM	121
-------------------	-------------------------------	------------

DAFTAR GAMBAR

I.1	Kerangka Kerja <i>Design Science Research Methodology</i> (DSRM) (Haryanti dkk. 2022)	7
II.1	Arsitektur Aliran Kerja Model Hibrida <i>Random Forest-ARIMA</i> (Yenkikar dkk. Juli 2025)	23
III.1	Model konseptual alur pelaporan kualitas udara Jakarta saat ini	36
III.2	Analisis persentase data hilang (<i>missing values</i>) pada parameter polutan utama DKI Jakarta (2010–2025)	38
III.3	Tren historis konsentrasi harian PM ₁₀ di Stasiun DKI1 (Bunderan HI)	40
III.4	Tren historis konsentrasi harian PM ₁₀ di Stasiun DKI2 (Kelapa Gading)	41
III.5	Tren Historis Konsentrasi Harian PM ₁₀ di Stasiun DKI3 (Jagakarsa)	41
III.6	Tren Historis Konsentrasi Harian PM ₁₀ di Stasiun DKI4 (Lubang Buaya)	42
III.7	Tren Historis Konsentrasi Harian PM ₁₀ di Stasiun DKI5 (Kebon Jeruk)	43
III.8	Plot ACF dan PACF konsentrasi PM ₁₀ Jakarta untuk identifikasi pola autokorelasi temporal	45
III.9	Analisis Korelasi Silang (CCF) antara PM ₁₀ dengan polutan prekursor pada Lag 0–7 hari	46
III.10	Matriks Korelasi Pearson Antar Parameter Polutan Udara Jakarta . .	47
IV.1	Diagram sistem pemantauan kualitas udara Jakarta saat ini (Sistem Berjalan)	64
IV.2	Diagram Arsitektur Sistem Prediksi Hibrida Terintegrasi (Sistem Usulan)	65
IV.3	DFD Level 0 (Diagram Konteks) Sistem Prediksi PM ₁₀	67
IV.4	<i>Activity Diagram</i> Alur Pelatihan Model Hibrida Sekuensial	70
IV.5	<i>Sequence Diagram</i> Proses Inferensi Prediksi Harian	70
IV.6	Alur Logika Pembangkitan Fitur Komposit	73
IV.7	Visualisasi Pembagian Data pada Skema TimeSeriesSplit	80

V.1	Inisialisasi Lingkungan dan Pemanggilan Pustaka (<i>Library</i>)	86
V.2	Logika Pemuatan Data dan Interpolasi Deret Waktu	87
V.3	Persentase <i>Missing Values</i> pada Parameter Polutan	88
V.4	Distribusi Konsentrasi PM ₁₀ per Stasiun Pemantau	89
V.5	Matriks Korelasi Pearson Antar Parameter Polutan	89
V.6	Implementasi <i>Looping</i> Visualisasi Historis dan Ekstraksi Statistik .	90
V.7	Implementasi Plot Fungsi Korelasi Silang (CCF) dengan Lag 0-7 Hari	91
V.8	Komputasi dan Visualisasi Dekomposisi Aditif Deret Waktu PM ₁₀ .	92
V.9	Implementasi Skrip Evaluasi Stasioneritas Data	93
V.10	Pemotongan Data Latih dan Uji secara Kronologis	95
V.11	Implementasi Perulangan 5-Fold TimeSeriesSplit	96
V.12	Plot ACF/PACF Residu dan Pelatihan Model ARIMA Sekunder . .	98
VI.1	Visualisasi Penurunan RMSE melalui Studi Ablasi Fitur	101
VI.2	Tabel Komparasi Performa Arsitektur Model (Output Komputasi) .	102
VI.3	Plot Perbandingan Konsentrasi Aktual vs Prediksi Hibrida (<i>Tail Si-</i> <i>ze=100</i>)	103
VI.4	Visualisasi Konvergensi Nilai Objektif (<i>Optimization History</i>) . . .	104
VI.5	Evaluasi Kepentingan Parameter (<i>Hyperparameter Importance</i>) . .	104
VI.6	Visualisasi <i>Parallel Coordinates</i> Kombinasi Parameter	104
VI.7	Performa Prediktif Hibrida di Seluruh Stasiun Kualitas Udara Jakarta	105
VI.8	Visualisasi Perbandingan Waktu Pelatihan dan Inferensi Model . . .	106
VI.9	Distribusi Kepentingan Fitur Berdasarkan Nilai SHAP (<i>Summary</i> <i>Plot</i>)	108
VI.10	<i>SHAP Dependence Plot</i> untuk Fitur Paling Berpengaruh	108
VI.11	Evaluasi Dampak Interaksi SHAP (<i>SHAP Interaction Effect</i>) antara Gas CO Lintas Musim	109
VI.12	Evaluasi Model Hibrida pada Kondisi Perubahan Polusi Ekstrem (<i>Extreme Events</i>)	111

DAFTAR TABEL

II.1	Matriks Perbandingan Riset Terkait (<i>State-of-the-Art</i>) Prediksi Kualitas Udara	12
II.2	Perbandingan Karakteristik Polutan PM_{10} dan $PM_{2,5}$	13
II.3	Kategorisasi ISPU dan Dampak Kesehatan Spesifik	15
II.4	Spesifikasi Matriks 15 Fitur Prediktor dalam Arsitektur Model	26
III.1	Ringkasan Statistik Deskriptif Konsentrasi PM_{10} pada Lima SPKUA DKI Jakarta	39
III.2	Kebutuhan Fungsional Sistem Pemodelan PM_{10}	54
III.3	Kebutuhan Nonfungsional Sistem Pemodelan PM_{10}	55
III.4	Matriks Perbandingan Berpasangan Kriteria Utama	56
III.5	Matriks Normalisasi dan Perhitungan <i>Eigenvector</i> Kriteria	57
III.6	Matriks Evaluasi Alternatif Terhadap Interpretabilitas (INT)	58
III.7	Matriks Evaluasi Alternatif Terhadap Akurasi (AKR)	59
III.8	Matriks Evaluasi Alternatif Terhadap Pola Kompleks (PLK)	59
III.9	Matriks Evaluasi Alternatif Terhadap Efisiensi Komputasi (KMP)	60
III.10	Matriks Evaluasi Alternatif Terhadap Kemudahan Implementasi (IMP)	61
III.11	Matriks Sintesis Akhir untuk Penentuan Solusi Prediktif	61
IV.1	Matriks Perbandingan Teknis Sistem Berjalan dan Sistem Usulan	66
IV.2	Matriks Desain Fitur Komposit Hibrida	72
IV.3	Desain Skenario Eksperimen Studi Ablasi	79
V.1	Spesifikasi Lingkungan Implementasi Perangkat Keras dan Lunak	86
V.2	Hasil Komputasi Uji Stasioneritas ADF dan KPSS	93
VI.1	Hasil Pengujian Metrik pada Studi Ablasi Fitur	102
VI.2	Komparasi Performa Akhir Lintas Arsitektur Pemodelan	102
VI.3	Analisis Waktu Komputasi Pelatihan dan Inferensi Model	106

DAFTAR PERSAMAAN

II.1	Formulasi Regresi Uji <i>Augmented Dickey-Fuller</i> (ADF)	17
II.2	Formulasi Koefisien <i>Autocorrelation Function</i> (ACF)	18
II.3	Formulasi Penentuan Pemisahan Simpul pada Pohon Regresi	19
II.4	Formulasi Agregasi Prediksi Akhir Ansambel <i>Random Forest</i>	19
II.5	Formulasi Matematis Komponen <i>AutoRegressive</i> Orde p	20
II.6	Formulasi Transformasi Diferensi Tingkat Pertama	20
II.7	Formulasi Matematis Komponen <i>Moving Average</i> Orde q	20
II.8	Formulasi Terpadu Model ARIMA melalui Notasi Operator <i>Backshift</i>	21
II.9	Formulasi Dekomposisi Hibrida Sekuensial Metodologi Zhang	21
II.10	Formulasi Agregasi Akhir Prediksi Hibrida Sekuensial	22
II.11	Formulasi Implementasi Integrasi Random Forest dan ARIMA	23
II.12	Formulasi Kalkulasi <i>Moving Average</i> Berbasis Jendela Waktu	25
II.13	Formulasi Derivasi <i>Rolling Standard Deviation</i>	25
II.14	Formulasi Kompleksitas Waktu Pelatihan <i>Random Forest</i>	29
II.15	Formulasi Batas Atas Kompleksitas Pelatihan Algoritma ARIMA	30
II.16	Formulasi Diferensiasi Kontribusi Marjinal Fitur Tunggal	31
II.17	Formulasi Agregasi <i>Shapley Value</i>	31
III.1	Formulasi Pemetaan Fungsi Prediksi Deret Waktu Multivariat	48
III.2	Dekomposisi Sinyal Polutan Menjadi Komponen Linier dan Non-Linier	48
III.3	Formulasi Ekstraksi Fitur Jeda Temporal	50
III.4	Formulasi Rata-rata Jendela Berjalan 3 Hari	50
III.5	Formulasi Rata-rata Jendela Berjalan 7 Hari	51
III.6	Formulasi Standar Deviasi Jendela Berjalan 7 Hari	51
III.7	Formulasi Fitur Interaksi Karbon Monoksida dan Ozon	51
III.8	Formulasi Transformasi Siklus Hari dalam Seminggu	52
IV.1	Formulasi Standardisasi Skala Menggunakan Z-Score	74
IV.2	Formulasi Prediksi Akhir Arsitektur Hibrida Sekuensial	75
IV.3	Formulasi Nilai Prediksi sebagai Penjumlahan Kontribusi Fitur (SHAP)	81
VI.1	Formulasi Penghitungan Metrik <i>Root Mean Square Error</i>	99
VI.2	Formulasi Penghitungan Metrik <i>Mean Absolute Error</i>	100

DAFTAR ALGORITMA

IV.1	Algoritma Prapemrosesan dan Imputasi <i>Rolling Mean</i> per Stasiun .	68
IV.2	Pembangkitan Fitur Interaksi dan Temporal	73
IV.3	Kalkulasi Residu Hibrida Sekuensial	76
V.4	Algoritma Validasi Silang <i>TimeSeriesSplit</i> (5-Fold)	96
V.5	Pelatihan dan Inferensi Model Hibrida RF-ARIMA	98

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
PM_{10}	Partikulat debu halus dengan ukuran diameter kurang dari 10 mikrometer	1
CO	Gas Karbon Monoksida	2
O_3	Gas Ozon	2
SO_2	Gas Sulfur Dioksida	6
NO_2	Gas Nitrogen Dioksida	6
t	Indeks urutan waktu saat ini (observasi berjalan)	2
$t + 1$	Proyeksi waktu satu hari ke depan	2
$t - k$	Rentang waktu observasi sebelumnya dengan jeda waktu k	14
w	Rentang jendela observasi berjalan (<i>rolling window</i>)	20
T	Total waktu observasi deret waktu	15
Y_t	Deret waktu observasi aktual pada waktu t	14
X_t	Matriks data variabel observasi polutan historis	36
L	Operator bergeser mundur (<i>backshift operator</i>)	17
Δ	Operator selisih atau pembedaan (<i>differencing</i>)	14
α	Parameter konstanta pada model regresi uji ADF	14
β	Parameter koefisien tren linier pada uji ADF	14
γ	Koefisien parameter jeda pada uji ADF	14
δ_i	Koefisien selisih pada lag ke- i di uji ADF	14
ϵ_t	Sisaan acak (<i>error</i>) atau <i>white noise</i> pada waktu t	14
N	Total jumlah baris data observasi	15

M	Jumlah variabel fitur yang dievaluasi	15
B	Jumlah ansambel pohon pada algoritma <i>Random Forest</i>	16
K	Jumlah pohon keputusan (<i>estimators</i>)	23
p	Orde komponen <i>AutoRegressive</i> (AR) pada ARIMA	16
d	Orde komponen <i>Integrated</i> (I) pada ARIMA	16
q	Orde komponen <i>Moving Average</i> (MA) pada ARIMA	16
c	Parameter konstanta model ARIMA	16
ϕ	Koefisien pembobot komponen <i>AutoRegressive</i>	16
θ	Koefisien pembobot komponen <i>Moving Average</i>	16
N_t	Komponen fluktuasi non-linier dari dekomposisi data	17
L_t	Komponen autokorelasi linier dari dekomposisi data	17
e_t	Sisa galat prediksi (<i>residual</i>) pada waktu t	18
y'_t	Data hasil pembedaan (<i>differencing</i>) tingkat pertama	16
$\hat{N}_t$	Estimasi proyeksi nilai awal dari model fase primer	18
$\hat{L}_t$	Estimasi taksiran sisaan (<i>residual</i>) dari model fase sekunder	18
$\hat{y}_{RF}$	Estimasi regresi dari algoritma <i>Random Forest</i>	16
$\hat{r}_{ARIMA}$	Taksiran sisaan (<i>residual</i>) dari komponen statistik ARIMA	18
$\hat{Y}_{hybrid}$	Taksiran akhir prediksi dari arsitektur model hibrida sekuensial	18
$f(\cdot)$	Fungsi transformasi regresi prediktif	36
R^2	Koefisien determinasi	2
$\bar{y}$	Rata-rata nilai observasi data	15

ρ_k	Koefisien fungsi autokorelasi (ACF) pada jeda waktu k	15
MA_w	Nilai rata-rata bergerak (<i>Moving Average</i>) pada rentang waktu w	20
STD_w	Nilai standar deviasi bergerak pada rentang waktu w	20
RM_w	Nilai rata-rata observasi berjalan pada rentang waktu w	37
$RStd_w$	Nilai standar deviasi observasi berjalan pada rentang waktu w	37
z	Skor standar (Z-Score) untuk normalisasi fitur	54
μ	Rata-rata (<i>mean</i>) distribusi data	16
σ	Deviasi standar distribusi data	54
n	Jumlah dimensi kriteria matriks AHP / jumlah sampel evaluasi	41
λ_{max}	Nilai Eigen Maksimum pada matriks kriteria AHP	41
CI	Indeks Konsistensi (<i>Consistency Index</i>) pada uji AHP	41
RI	Indeks Acak Standar (<i>Random Index</i>) pada uji AHP	41
CR	Rasio Konsistensi (<i>Consistency Ratio</i>) pada uji AHP	41
$O(\cdot)$	Notasi <i>Big-O</i> untuk batas atas kompleksitas komputasi	23
S	Himpunan subset fitur pada perhitungan <i>Shapley Value</i>	24
$\Delta f_i(S)$	Diferensiasi kontribusi marjinal fitur tunggal (SHAP)	24
ϕ_i	Nilai akhir bobot atribusi SHAP untuk fitur i	24
ϕ_0	Nilai prediksi rata-rata (<i>base value</i>) pada algoritma SHAP	58

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
ACF	<i>Autocorrelation Function</i>	13
ADF	<i>Augmented Dickey-Fuller</i>	13
AHP	<i>Analytical Hierarchy Process</i>	3
AKR	Akurasi (Kriteria AHP)	15
AQI	<i>Air Quality Index</i>	1
AR	<i>AutoRegressive</i>	13
ARIMA	<i>AutoRegressive Integrated Moving Average</i>	2
CCF	<i>Cross-Correlation Function</i>	16
CI	<i>Consistency Index</i>	15
CO	Karbon Monoksida	2
CR	<i>Consistency Ratio</i>	15
DFD	<i>Data Flow Diagram</i>	14
DLH	Dinas Lingkungan Hidup	14
DSRM	<i>Design Science Research Methodology</i>	2
EDA	<i>Exploratory Data Analysis</i>	16
ETL	<i>Extract, Transform, Load</i>	14
GPU	<i>Graphics Processing Unit</i>	12
IMP	Kemudahan Implementasi (Kriteria AHP)	15
INT	Interpretabilitas (Kriteria AHP)	15
ISPU	Indeks Standar Pencemar Udara	2
KLHK	Kementerian Lingkungan Hidup dan Kehutanan	2
KMP	Efisiensi Komputasi (Kriteria AHP)	15
KPSS	<i>Kwiatkowski-Phillips-Schmidt-Shin</i>	16
LSTM	<i>Long Short-Term Memory</i>	2
MA	<i>Moving Average</i>	2
MAE	<i>Mean Absolute Error</i>	3
MLE	<i>Maximum Likelihood Estimation</i>	20
NO ₂	Nitrogen Dioksida	6
O ₃	Ozon	2
OOB	<i>Out-of-Bag</i>	12
PACF	<i>Partial Autocorrelation Function</i>	13
PLK	Pola Kompleks (Kriteria AHP)	15

PM	<i>Particulate Matter</i>	12
PM ₁₀	Particulate Matter 10 Mikrometer	1
PM _{2,5}	Particulate Matter 2.5 Mikrometer	12
PPOK	Penyakit Paru Obstruktif Kronis	1
RF	<i>Random Forest</i>	12
RI	<i>Random Index</i>	15
RMSE	<i>Root Mean Square Error</i>	2
SHAP	<i>SHapley Additive exPlanations</i>	3
SO ₂	Sulfur Dioksida	6
SPKUA	Stasiun Pemantauan Kualitas Udara Ambien	14
STD	<i>Standard Deviation</i>	17
TPE	<i>Tree-structured Parzen Estimator</i>	13
WHO	<i>World Health Organization</i>	1
XAI	<i>Explainable Artificial Intelligence</i>	3
XGBoost	<i>Extreme Gradient Boosting</i>	24

BAB I

PENDAHULUAN

I.1 Latar Belakang

Kawasan perkotaan di negara berkembang saat ini menghadapi tantangan penurunan kualitas udara yang memengaruhi kesehatan masyarakat dan lingkungan. DKI Jakarta, sebagai pusat ekonomi dan administrasi di Indonesia, tercatat memiliki konsentrasi polutan yang fluktuatif dan sering kali melebihi ambang batas aman yang ditetapkan oleh Organisasi Kesehatan Dunia (WHO). Kondisi atmosfer di wilayah beriklim tropis seperti Jakarta dipengaruhi oleh faktor meteorologi serta emisi dari sektor transportasi dan aktivitas konstruksi (Firdaus dkk. September 2023). Berdasarkan data historis, tren penurunan kualitas udara ini ditunjukkan oleh kenaikan rata-rata Indeks Kualitas Udara (AQI) sebesar 69% pada periode observasi tahun 2017 hingga 2020 (Aulia 2024).

Dari berbagai parameter kualitas udara yang dipantau melalui stasiun pemantauan, partikulat debu halus dengan ukuran diameter aerodinamis kurang dari 10 mikrometer (PM_{10}) merupakan polutan yang memerlukan analisis mendalam. Di kawasan perkotaan Jakarta, PM_{10} umumnya bersumber dari debu jalan raya, aktivitas konstruksi, dan emisi hasil pembakaran (California Air Resources Board 2025). Karakteristik fisik partikulat yang kecil ini berpotensi menembus sistem filtrasi alami saluran pernapasan manusia dan mengendap pada jaringan paru-paru, sehingga memicu risiko gangguan respirasi jangka panjang.

Dampak paparan PM_{10} terhadap kesehatan telah didokumentasikan dalam berbagai studi epidemiologi. Penelitian oleh Zhang dkk. (Juni 2021) menunjukkan bahwa setiap kenaikan konsentrasi PM_{10} sebesar $10 \mu g/m^3$ berkaitan dengan kenaikan jumlah kunjungan gawat darurat akibat penyakit kardiovaskular sebesar 0,14%. Sementara itu, Kyung dan Jeong (Maret 2020) menemukan bahwa paparan jangka pendek terhadap PM_{10} berkorelasi dengan kenaikan angka rawat inap pasien Penyakit Paru Obstruktif Kronis (PPOK) sebesar 2,7%. Data rekam medis tersebut menegaskan bahwa penyediaan informasi proyeksi kualitas udara diperlukan untuk mendukung

upaya preventif, khususnya bagi kelompok masyarakat rentan.

Sebagai instrumen mitigasi, Pemerintah Indonesia menerapkan Indeks Standar Pencemar Udara (ISPU) untuk menyampaikan status kualitas udara kepada publik, mengacu pada Peraturan Menteri Lingkungan Hidup dan Kehutanan Nomor 14 Tahun 2020 (Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia, Juli 2020; Chaniago, Zahara, dan Ramadhani, September 2020). Kendati demikian, mekanisme pelaporan ISPU saat ini bersifat retrospektif, di mana nilai indeks yang dipublikasikan merupakan representasi dari rata-rata konsentrasi polutan selama 24 jam ke belakang (Septiani, Juni 2024). Akibatnya, informasi yang diterima masyarakat tidak mencerminkan kondisi riil pada waktu penayangan. Guna mengatasi keterbatasan pelaporan yang reaktif tersebut, diperlukan pendekatan prediktif berupa sistem pemodelan yang mampu memproyeksikan konsentrasi polutan untuk satu hari ke depan ($t + 1$).

Dalam mengembangkan sistem proyeksi kualitas udara, penerapan algoritma komputasi berbasis *machine learning* banyak diadopsi karena kapasitasnya dalam mengenali pola data lingkungan yang non-linier. Sebagai contoh, Arsy dan Yasir (April 2025) menerapkan algoritma *Random Forest* untuk memprediksi polusi di wilayah urban dan menunjukkan karakteristik yang stabil saat memproses data dengan nilai ekstrem (*outliers*). Di samping itu, arsitektur *Deep Learning* seperti *Long Short-Term Memory* (LSTM) juga kerap diteliti untuk pemrosesan data deret waktu jangka panjang (Radjabaycolle, Wattimena, dan Pattiradjawane, Oktober 2025).

Meski demikian, masing-masing pendekatan memiliki karakteristik batasan tertentu. Model *machine learning* konvensional sering kali mengalami penurunan akurasi saat memetakan tren linier jangka panjang, sementara metode *Deep Learning* memerlukan alokasi sumber daya komputasi dan durasi pelatihan yang relatif besar. Di sisi lain, metode statistik tradisional seperti *Autoregressive Integrated Moving Average* (ARIMA) efektif dalam memodelkan komponen linier dan tren musiman, namun kurang responsif terhadap lonjakan fluktuasi jangka pendek yang drastis (Vasconcelos, Juli 2025). Guna mengompensasi keterbatasan tersebut, integrasi kedua metode ke dalam model hibrida mulai dikembangkan. Studi oleh Yenkikar dkk. (Juli 2025) menunjukkan bahwa kombinasi *Random Forest* dan ARIMA mampu menghasilkan estimasi kualitas udara dengan koefisien determinasi (R^2) mencapai 0,94.

Namun demikian, sebagian besar literatur yang mengimplementasikan model hibrida *Random Forest*-ARIMA (Naz dkk. 2024; Chen dkk. Januari 2025; Yunis, Andri, dan Djoni, Juni 2024) umumnya memproses variabel polutan secara langsung tanpa

melibatkan tahapan pengayaan informasi fitur (*feature engineering*). Padahal, variabilitas konsentrasi PM_{10} secara fisik memiliki ketergantungan pada kondisi temporal sebelumnya (efek *lag*), nilai rata-rata bergerak (*rolling statistics*), serta interaksi kimiawi antar-polutan di atmosfer, seperti interaksi antara karbon monoksida (CO) dan ozon (O_3). Representasi fitur turunan ini diperlukan agar model dapat menangkap karakteristik dinamika polusi secara lebih komprehensif.

Keterbatasan lain dalam implementasi pemodelan prediktif berbasis *machine learning* adalah karakteristiknya yang menyerupai kotak hitam (*black-box*), sehingga hubungan inferensial internal model sulit diinterpretasikan (Jiménez-Navarro dkk. Desember 2024). Walaupun model hibrida mampu menghasilkan estimasi numerik PM_{10} , model tersebut tidak secara langsung mengonfirmasi kontribusi spesifik dari tiap faktor prediktor. Aspek transparansi ini krusial apabila hasil prediksi akan digunakan sebagai basis analisis oleh otoritas terkait. Untuk mengatasi hambatan tersebut, pendekatan *Explainable Artificial Intelligence* (XAI) dapat diintegrasikan. Metode *SHapley Additive exPlanations* (SHAP) merupakan salah satu pendekatan matematis berbasis teori permainan (*game theory*) yang digunakan untuk mengukur dan memvisualisasikan kontribusi marginal masing-masing fitur terhadap hasil keluaran model (Molnar 2025).

Berdasarkan kondisi kualitas udara di DKI Jakarta serta ruang pengembangan pada literatur terdahulu, penelitian Tugas Akhir ini bertujuan untuk menguji model hibrida *Random Forest-ARIMA* untuk prediksi harian PM_{10} . Model ini dikonstruksi dengan memanfaatkan teknik *feature engineering* guna mengeksplorasi hubungan temporal dan interaksi polutan pada dataset kualitas udara Jakarta periode tahun 2010–2025. Selanjutnya, model prediksi dianalisis menggunakan metode SHAP untuk memberikan gambaran mengenai kontribusi fitur prediktor (Lundberg 2025). Melalui pengujian pendekatan ini, diharapkan penelitian ini dapat memberikan analisis komparatif estimasi kualitas udara yang dapat ditelaah secara sistematis sebagai materi pertimbangan dalam pengelolaan lingkungan.

I.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian Tugas Akhir ini difokuskan pada analisis karakteristik pemodelan prediktif untuk memproyeksikan konsentrasi polutan secara harian serta evaluasi performa model hibrida. Permasalahan tersebut dirumuskan ke dalam pertanyaan-pertanyaan berikut:

1. Bagaimana merancang model estimasi harian konsentrasi PM_{10} di DKI Jakarta untuk memproyeksikan kualitas udara satu hari ke depan ($t + 1$)?
2. Bagaimana mengintegrasikan algoritma *Random Forest* dan ARIMA ke dalam sebuah model hibrida sekuensial untuk memodelkan komponen linier dan non-linier pada data deret waktu?
3. Bagaimana pengaruh penerapan teknik rekayasa fitur (*feature engineering*), yang meliputi variabel *lag*, statistik berjalan, dan interaksi antarpolutan, terhadap performa galat (*error*) estimasi model hibrida *Random Forest*-ARIMA?
4. Bagaimana menerapkan metode *SHapley Additive exPlanations* (SHAP) untuk menganalisis dan menggambarkan kontribusi marginal dari masing-masing fitur prediktor terhadap hasil keluaran model hibrida?

I.3 Tujuan Penelitian

Tujuan utama dari penelitian Tugas Akhir ini adalah mengembangkan dan menguji model prediksi harian konsentrasi PM_{10} di DKI Jakarta menggunakan pendekatan hibrida *Random Forest*-ARIMA guna mengevaluasi performa galat dan tingkat interpretabilitas model tersebut pada data deret waktu. Secara lebih spesifik, tujuan penelitian ini adalah:

1. Mengonstruksi arsitektur model hibrida *Random Forest*-ARIMA dengan menerapkan teknik rekayasa fitur (*feature engineering*) pada dataset kualitas udara Jakarta periode tahun 2010–2025 serta mengevaluasi nilai galat prediksinya.
2. Menganalisis kontribusi marginal dan pengaruh fitur masukan terhadap hasil estimasi PM_{10} menggunakan metode *SHapley Additive exPlanations* (SHAP) untuk memberikan penjelasan internal model yang terstruktur.

I.4 Kriteria Keberhasilan

Untuk mengukur dan mengevaluasi hasil pemodelan ini secara objektif, ditetapkan tiga kriteria evaluasi teknis sebagai berikut:

1. Reduksi Kesalahan Estimasi (Benchmarking): Model hibrida *Random Forest*-ARIMA yang dikembangkan dapat meminimalkan tingkat kesalahan peramalan. Keberhasilan ini diukur melalui penurunan metrik *Root Mean Square Error* (RMSE) minimal sebesar 15% jika dibandingkan dengan model *baseline* (ARIMA murni). Batas threshold 15% ini merujuk pada acuan batas reduksi galat yang representatif dalam evaluasi model deret waktu (Yenkikar dkk. Juli 2025).
2. Kontribusi Rekayasa Fitur (Studi Ablasi): Hasil eksperimen studi ablasi menunjukkan secara empiris bahwa pemanfaatan fitur turunan (hasil *feature engi-*

neering) menghasilkan nilai kesalahan prediksi yang lebih rendah jika dibandingkan dengan arsitektur model yang hanya dilatih menggunakan variabel polutan dasar.

3. Interpretabilitas Hasil Model (XAI): Pemodelan dapat diintegrasikan dengan metode SHAP untuk menghasilkan visualisasi kontribusi fitur, baik pada tingkat global maupun lokal. Visualisasi tersebut dapat memetakan arah hubungan dan pengaruh masing-masing fitur masukan terhadap hasil prediksi PM_{10} secara logis serta selaras dengan karakteristik fisis kualitas udara.

I.5 Manfaat Penelitian

Penelitian Tugas Akhir ini diharapkan dapat memberikan kontribusi manfaat ilmiah serta aplikatif sebagai berikut:

1. Memberikan kajian empiris tambahan mengenai karakteristik pencatatan dan implementasi model hibrida *Random Forest-ARIMA* yang dikombinasikan dengan teknik rekayasa fitur pada data kualitas udara di wilayah urban beriklim tropis.
2. Menjadi materi referensi ilmiah mengenai pengaruh penggunaan dimensi fitur temporal (*lag* dan *rolling window*) terhadap fluktuasi nilai galat pemodelan deret waktu untuk polutan udara secara berskala.
3. Menyediakan contoh dokumentasi metodologis terkait penerapan pendekatan *Explainable AI* (XAI) menggunakan analisis SHAP untuk memetakan hubungan kausalitas antarpolutan udara secara terstruktur.
4. Menghasilkan rancangan konfigurasi model prediksi harian PM_{10} yang dapat dijadikan bahan pertimbangan atau komponen awal dalam pengembangan sistem kajian kualitas udara di kawasan perkotaan Jakarta.
5. Menyediakan data dan analisis kontribusi polutan yang dapat dimanfaatkan oleh analis lingkungan sebagai referensi tambahan dalam memahami faktor-faktor dominan yang memengaruhi dinamika kualitas udara lokal.
6. Membantu praktisi pemodelan dalam menginterpretasikan perilaku keputusan internal model *machine learning* melalui visualisasi kontribusi fitur yang lebih transparan dan akuntabel.

I.6 Kontribusi Penelitian

Penelitian Tugas Akhir ini memberikan kontribusi teknis dan empiris yang difokuskan pada tiga aspek pengembangan sistem estimasi kualitas udara berikut:

1. Penyusunan Atribut Rekayasa Fitur Temporal dan Komposit: Penelitian ini berkontribusi dalam menyusun matriks 15 fitur komposit turunan yang menggabungkan dependensi temporal (*lag* dan *rolling statistics*) serta variabel ha-

sil perkalian antarpolutan ($CO \times O_3$). Pendekatan harian ini digunakan untuk menyertakan karakteristik hubungan antarvariabel polutan secara statistik, sebagai alternatif dari pemrosesan variabel dasar secara terpisah.

2. Penerapan Konstruksi Model Hibrida Sekuensial: Penelitian ini berkontribusi pada implementasi model estimasi harian PM_{10} melalui penggabungan algoritma *Random Forest* dan ARIMA secara sekuensial. Metode ini mengeksplorasi pembagian tugas pemrosesan data, di mana algoritma pohon keputusan digunakan untuk memetakan fluktuasi non-linier dari data masukan, sedangkan model statistik ARIMA digunakan untuk mengolah data sisaan (*residual*) guna menguji pengurangan nilai galat peramalan.
3. Analisis Transparansi Perilaku Model Menggunakan SHAP: Penelitian ini berkontribusi dalam pemanfaatan pendekatan *Explainable AI* (XAI) melalui metode *TreeSHAP* untuk menganalisis keputusan internal model hibrida yang bersifat tertutup (*black-box*). Tahapan ini menghasilkan gambaran kuantitatif mengenai bobot kontribusi masing-masing fitur rekayasa terhadap nilai estimasi, sehingga memberikan informasi tambahan yang dapat ditelaah secara logis dalam konteks kualitas udara Jakarta.

I.7 Batasan Masalah


Guna menjaga fokus penelitian serta kejelasan parameter yang dievaluasi, ruang lingkup kajian dalam Tugas Akhir ini dibatasi pada hal-hal berikut:

1. Lokasi Geografis dan Stasiun Pemantauan: Penelitian hanya menggunakan data kualitas udara di wilayah administratif Provinsi DKI Jakarta yang terekam dari lima stasiun pemantauan resmi di bawah pengelolaan otoritas terkait.
2. Dataset dan Rentang Waktu: Data yang digunakan merupakan data sekunder Indeks Standar Pencemar Udara (ISPU) dengan resolusi harian, terhitung mulai tanggal 1 Januari 2010 hingga 28 Februari 2025.
3. Variabel Penelitian: Fitur masukan (prediktor) yang dimasukkan ke dalam model dibatasi pada lima parameter polutan ISPU, yaitu PM_{10} , SO_2 , CO , O_3 , dan NO_2 . Parameter PM_{10} bertindak sebagai target proyeksi sekaligus sebagai fitur riwayat temporal (*lag feature*). Penelitian ini tidak melibatkan variabel eksternal seperti data meteorologi (curah hujan, kecepatan angin) maupun volume lalu lintas kendaraan.
4. Resolusi Prediksi: Target luaran (*output*) dari model difokuskan pada estimasi tingkat polusi harian untuk satu hari ke depan (*next-day forecast, $t+1$*), dan tidak mencakup proyeksi berskala per jam (*hourly*) atau waktu nyata (*real-time*).

5. Ruang Lingkup Implementasi: Penelitian ini dibatasi pada siklus evaluasi model secara *offline* (*offline model evaluation*), yang mencakup tahap prapemrosesan data, perancangan konfigurasi model, penyetelan *hyperparameter*, pengamatan metrik evaluasi galat, hingga visualisasi SHAP. Penelitian ini tidak mencakup tahap rekayasa perangkat lunak lanjutan seperti pembuatan antarmuka aplikasi (*dashboard*) maupun implementasi sistem di lingkungan produksi nyata (*deployment*).

I.8 Metodologi Penelitian

Penelitian Tugas Akhir ini menggunakan kerangka kerja *Design Science Research Methodology* (DSRM). DSRM merupakan salah satu kerangka metodologi yang digunakan untuk penelitian di bidang sistem informasi dan sains data yang berfokus pada analisis rancangan objek kajian. Pemilihan metodologi ini didasarkan pada tujuan penelitian untuk mengonstruksi, menguji konfigurasi artefak komputasi, mendemonstrasikan, serta mengevaluasi kinerjanya secara terukur melalui serangkaian eksperimen numerik (Haryanti dkk. 2022). Alur kerangka kerja DSRM tersebut dapat dilihat pada Gambar I.1.



Gambar I.1 Kerangka Kerja *Design Science Research Methodology* (DSRM) (Haryanti dkk. 2022)

Artefak yang dikembangkan dalam penelitian ini berupa konfigurasi pemodelan hibrida *Random Forest-ARIMA* yang disusun berdasarkan prinsip pemisahan komponen data (Yenkikar dkk. Juli 2025). Eksplorasi model ini mencakup tiga karakteristik penyesuaian: Pemanfaatan dataset kualitas udara Jakarta dengan rentang waktu 15 tahun (2010–2025) untuk mengamati konsistensi perilaku model pada variasi tren yang panjang, pengayaan dimensi masukan melalui rekayasa fitur menjadi matriks 15 fitur turunan, dan penempatan parameter PM_{10} sebagai target proyeksi keluaran sekaligus sebagai variabel riwayat (*lag*) masukan.

Guna menjaga keteraturan tahapan penelitian, pelaksanaan DSRM dibagi ke dalam lima langkah sistematis sebagai berikut:

1. *Literature Review for Problem Identification*

Tahap awal penelitian meliputi tinjauan pustaka secara sistematis mengenai pemodelan estimasi kualitas udara. Pencarian literatur dilakukan melalui basis data akademik (*Google Scholar, IEEE Xplore, PubMed*) dengan fokus pada publikasi artikel ilmiah terkait periode tahun 2019–2025. Hasil dari tahap ini adalah penetapan karakteristik dasar pemodelan *Random Forest-ARIMA* dari Yenikar dkk. (Juli 2025) sebagai referensi struktur hibrida awal yang akan dievaluasi.

2. *Identify Research Gap*

Tahap ini bertujuan untuk menganalisis karakteristik batasan pada metode eksperimen dari penelitian-penelitian terdahulu. Analisis menunjukkan bahwa sebagian besar pemodelan estimasi masih memproses variabel polutan secara langsung dan belum melibatkan rekayasa fitur temporal yang merepresentasikan akumulasi zat di atmosfer. Kondisi tersebut menjadi landasan untuk menerapkan metode rekayasa fitur komposit pada penelitian ini.

3. *Proposed DSRM Approach for Developing Artifact*

Tahap ini merupakan proses perancangan konfigurasi komputasi. Arsitektur pemodelan dirancang secara sekuensial: algoritma *Random Forest* digunakan untuk memproses matriks hasil rekayasa fitur guna memetakan pola non-linier, sedangkan fungsi *autoregressive* pada ARIMA bertugas memodelkan komponen linier pada data deret waktu. Tahap ini juga mencakup integrasi pendekatan *SHAP Explainer* agar karakteristik keputusan internal model dapat ditelaah.

4. *Identify DSRM Step (Execution Procedure)*

Tahap ini merupakan pelaksanaan teknis pemrograman yang mencakup prosedur berikut:

- (a) *Data Preprocessing*: Rangkaian pembersihan data deret waktu, termasuk penyelarasan data antarstasiun, pengisian nilai kosong (*imputation*), serta penyesuaian rentang nilai (*scaling*).
- (b) *Time-Series Feature Engineering*: Ekstraksi fitur masukan menggunakan bahasa pemrograman Python untuk menghasilkan 15 turunan fitur temporal, seperti jeda waktu (*lag*) dan statistik berjalan (*rolling window*).
- (c) *Skema Pelatihan Kronologis*: Validasi model menggunakan metode *Time-Series Cross-Validation (Forward Chaining)* dengan pembagian rasio data latih dan uji sebesar 80:20 secara berurutan tanpa pengacakan (*shuffle=False*) untuk menghindari risiko kebocoran data masa depan (*look-*

ahead bias).

- (d) *Hyperparameter Tuning*: Pencarian konfigurasi nilai hiperparameter (seperti parameter jumlah pohon keputusan dan kedalaman maksimum) menggunakan kerangka eksperimen Bayesian pada pustaka Optuna untuk meminimalkan nilai galat.

5. *Case Study and Implementation DSRM*

Tahap terakhir adalah implementasi konfigurasi model menggunakan dataset historis ISPU DKI Jakarta (Pohan 2025). Tahap ini ditujukan untuk mengukur perbandingan performa galat model usulan terhadap model *baseline* (ARIMA murni). Evaluasi diukur melalui persentase penurunan nilai *Root Mean Square Error* (RMSE), serta perbandingan metrik *Mean Absolute Error* (MAE) dan koefisien determinasi (R^2). Sebagai analisis akhir, hasil estimasi ditelaah menggunakan grafik *SHAP beeswarm* dan *SHAP dependence*.

I.9 Sistematika Penulisan

Laporan Tugas Akhir ini disusun ke dalam tujuh bab dengan sistematika penulisan sebagai berikut:

1. Bab I Pendahuluan: Menguraikan latar belakang penurunan kualitas udara, rumusan masalah, tujuan penelitian, kriteria keberhasilan, manfaat penelitian, kontribusi penelitian, batasan masalah, metodologi penelitian, serta sistematika penulisan laporan.
2. Bab II Studi Literatur: Menjelaskan pemetaan riset terkait (*state-of-the-art*) dan landasan teori yang mendasari penelitian, meliputi regulasi ISPU, algoritma *Random Forest*, pemodelan deret waktu ARIMA, metode rekayasa fitur, mekanisme kerja Optuna, serta kerangka interpretasi model menggunakan SHAP.
3. Bab III Analisis Masalah: Menyajikan evaluasi terhadap mekanisme pelaporan data yang berjalan, analisis karakteristik dataset kualitas udara Jakarta, analisis pola hubungan empiris polutan, formulasi desain fitur, hingga justifikasi pemilihan solusi prediktif menggunakan *Analytical Hierarchy Process* (AHP).
4. Bab IV Perancangan: Mendeskripsikan arsitektur konseptual pemodelan usulan, desain *data pipeline* eksperimen, spesifikasi algoritmik rekayasa fitur, desain struktur hibrida sekuensial, serta skenario pengujian studi ablasi dan validasi silang.
5. Bab V Implementasi: Mendokumentasikan langkah teknis komputasi pada lingkungan eksperimen yang mencakup eksplorasi data awal, analisis stasioneritas, penerapan rekayasa fitur komposit, pemisahan data latih-uji secara

kronologis, hingga kalkulasi fase primer dan sekunder pada model hibrida.

6. Bab VI Evaluasi: Menyajikan metrik evaluasi ekspektasi statistik, pelaporan hasil pengujian studi ablas, komparasi performa nilai galat antar-model, analisis waktu komputasi pelatihan dan inferensi, serta pembahasan mengenai interpretasi kontribusi fitur menggunakan visualisasi deskriptif SHAP.
7. Bab VII Penutup: Menyampaikan kesimpulan akhir yang ditarik dari hasil evaluasi untuk menjawab pertanyaan penelitian, serta menyajikan saran mengenai keterbatasan dan peluang studi komparatif di masa mendatang.

BAB II

STUDI LITERATUR

II.1 Pemetaan Riset Terkait (*State-of-the-Art*)

Dalam pengembangan pemodelan komputasi berbasis *machine learning* untuk pemantauan lingkungan, transisi dari model regresi tunggal menuju arsitektur hibrida merupakan pendekatan yang banyak dikaji saat ini. Penempatan penelitian ini dalam khazanah literatur menjadi penting untuk memetakan posisi dan batasan dari pendekatan yang digunakan dibandingkan dengan penelitian-penelitian sebelumnya.

II.1.1 Matriks Perbandingan Literatur Terkini

Untuk mengevaluasi posisi metodologi penelitian ini, dilakukan tinjauan terhadap penelitian terdahulu dalam rentang lima tahun terakhir (2020–2025). Pemilihan literatur didasarkan pada relevansi penggunaan algoritma ansambel, pendekatan hibrida, serta studi kasus estimasi kualitas udara pada wilayah perkotaan. Tinjauan ini bertujuan untuk mempelajari perkembangan model prediktif sekaligus mengidentifikasi batasan dari metodologi yang ada sebagai acuan pengembangan sistem.

Perkembangan pemodelan dalam literatur menunjukkan kecenderungan pergeseran dari penggunaan algoritma tunggal ke arah arsitektur yang digabung (*hybrid*) guna menangani sifat pola polutan yang tidak beraturan (*non-linier*). Meskipun demikian, terdapat variasi yang cukup besar dalam hal pemilihan fitur masukan dan metode penyetelan parameter. Kondisi ini menunjukkan bahwa pemahaman mengenai bagaimana suatu arsitektur merespons dinamika waktu dan lokasi yang berbeda masih terus berkembang.

Lebih lanjut, tren publikasi menunjukkan adanya perbedaan fokus dalam pemanfaatan fitur turunan tambahan. Sebagian besar literatur memproses polutan sebagai variabel yang berdiri sendiri secara statistik, tanpa mengaitkannya dengan reaksi kimiawi atmosferik di lapangan. Hal ini membatasi kemampuan model dalam merespons fluktuasi polusi akibat perubahan cuaca. Oleh karena itu, diperlukan tinjauan komparatif untuk memetakan cakupan fitur dan celah (*gap*) dari masing-masing

penelitian terdahulu, sebagaimana disajikan pada Tabel II.1.

Tabel II.1 Matriks Perbandingan Riset Terkait (*State-of-the-Art*) Prediksi Kualitas Udara

Penulis	Metode	Fitur Utama	Celah Riset (<i>Gap</i>)
Yenkikar dkk. (Juli 2025)	Hybrid RF-ARIMA	Polutan dasar	Mengabaikan interaksi antar-polutan.
Naz dkk. (2024)	<i>Feature Engineering</i>	Turunan temporal	Ketiadaan koreksi residu temporal.
Arsy dan Yasir (April 2025)	<i>Random Forest</i>	Polutan mentah	Mengabaikan tren linier jangka panjang.
Chen dkk. (Januari 2025)	<i>Deep Learning</i>	<i>Spatio-temporal attention</i>	Beban komputasi harian tinggi (GPU).
Radjabaycolle, Wattimena, dan Pattiradjawane (Oktober 2025)	LSTM- SHAP	Memori sekuensial	Operasional terlalu kompleks untuk peladen lokal.

II.1.2 Identifikasi Kesenjangan Riset (*Research Gap Analysis*)

Berdasarkan analisis komparatif pada Tabel II.1, terlihat bahwa meskipun metrik akurasi yang dihasilkan oleh berbagai pemodelan terdahulu cukup bervariasi, mayoritas pendekatan saat ini menitikberatkan pada sisi arsitektur komputasinya (*model-centric*). Kondisi ini menyebabkan variabel polutan sering kali diproses oleh model sebagai representasi numerik murni tanpa memperhitungkan aspek keterkaitan fisik dan kimiawinya di atmosfer.

Hal tersebut dapat menyebabkan tidak tertangkapnya pola indikator penyebab polusi sekunder yang memengaruhi fluktuasi kualitas udara di wilayah tropis. Dari evaluasi literatur di atas, teridentifikasi tiga celah riset fundamental yang menjadi dasar pelaksanaan penelitian ini:

1. Pengabaian Interaksi Kimiawi: Mayoritas penelitian (seperti pada studi (Arsy dan Yasir, April 2025) dan (Yenkikar dkk. Juli 2025)) hanya memasukkan parameter polutan secara individual ke dalam model. Faktanya, perubahan konsentrasi PM₁₀ di udara terbuka juga dipengaruhi oleh efek interaksi antar-gas akibat radiasi matahari (*fotolisis*). Celah ini mendasari penerapan *feature engineering* untuk memetakan hubungan antar variabel tersebut.
2. Keterbatasan Fleksibilitas Arsitektur Model: Pendekatan yang masih terpisah antara model statistik (ARIMA) yang linear atau *machine learning* yang non-linear namun kurang menangkap pola autokorelasi pada data sisaan (*residual*).

Penggunaan arsitektur hibrida sekuensial untuk mengevaluasi data berjangka waktu panjang (15 tahun) di wilayah Jakarta masih terbatas dibahas.

3. Kebutuhan Efisiensi dan Transparansi: Penelitian yang mengejar nilai akurasi menggunakan arsitektur *Deep Learning* (seperti pada studi (Chen dkk. Januari 2025)) memerlukan sumber daya komputasi yang besar dan sifatnya tidak transparan (*black-box*). Pendekatan tersebut kurang sesuai untuk diterapkan pada sistem instansi lokal yang membutuhkan efisiensi operasional harian serta kejelasan dasar pengambilan keputusan melalui metode XAI.

II.2 Domain Sains Atmosfer dan Paradigma Regulasi ISPU

Pemahaman mengenai parameter kualitas udara tidak dapat dilepaskan dari konteks sains atmosfer dan regulasi pemerintah yang mengaturnya. Bagian ini membahas karakteristik partikulat udara, kondisi spesifik polusi di Jakarta, standar pelaporan Indeks Standar Pencemar Udara (ISPU), serta mekanisme pembentukan polutan sekunder. Pemantauan kualitas udara secara global umumnya dilakukan terhadap *Particulate Matter* (PM), yaitu campuran partikel padat dan cair yang melayang di udara. Partikel ini diklasifikasikan secara mendasar berdasarkan ukuran diameternya untuk menentukan sifat retensi dan perilakunya di udara (California Air Resources Board 2025). Pengelompokan ini diperlukan karena perbedaan dimensi fisik polutan memengaruhi karakteristik dispersi dan tingkat penetrasinya ke dalam organ pernapasan manusia. Perbandingan dimensi, sumber emisi, dan implikasi klinis secara lebih rinci antara dua jenis partikulat utama disajikan pada Tabel II.2.

Tabel II.2 Perbandingan Karakteristik Polutan PM_{10} dan $PM_{2,5}$

Aspek Analisis	PM_{10}	$PM_{2,5}$
Ukuran Fisik	Diameter $< 10 \mu m$	Diameter $< 2,5 \mu m$
Sumber Dominan	Debu jalan, aktivitas konstruksi, abrasi ban, dan proses mekanis.	Emisi kendaraan, proses pembakaran, dan reaksi fotokimia industri.
Tingkat Penetrasi	Mengendap di saluran pernapasan atas (trakeobronkial).	Menembus saluran pernapasan dalam hingga kantung alveoli.
Risiko Kesehatan	Iritasi saluran napas, eksaserbasi asma, dan PPOK (COPD).	Penyakit kardiovaskular, stroke, dan risiko kanker paru-paru.

Berdasarkan karakteristik fisik yang disajikan pada Tabel II.2, profil risiko kesehatan dari partikulat ini menjadi aspek yang ditelaah secara mendalam dalam berbagai studi epidemiologi. Partikulat PM_{10} dapat masuk ke sistem pernapasan bagian atas karena karakteristik fisisnya yang banyak dihasilkan dari proses mekanis, se-

perti debu jalan raya dan aktivitas konstruksi harian (Firdaus dkk. September 2023). Penelitian oleh Zhang dkk. (Juni 2021) menunjukkan bahwa setiap kenaikan konsentrasi PM_{10} sebesar $10 \mu g/m^3$ berkaitan dengan kecenderungan kenaikan jumlah kunjungan gawat darurat akibat penyakit kardiovaskular sebesar 0,14%. Sementara itu, Kyung dan Jeong (Maret 2020) menemukan bahwa paparan terhadap PM_{10} berkorelasi dengan adanya perubahan angka rawat inap pasien Penyakit Paru Obstruktif Kronis (PPOK) sebesar 2,7%.

Kecenderungan data statistik dan rekam medis tersebut menunjukkan bahwa pemantauan dan penyediaan informasi proyeksi kualitas udara diperlukan untuk mendukung langkah preventif, khususnya bagi kelompok masyarakat yang rentan. Hal ini menjadi relevan bagi wilayah dengan tingkat aktivitas urban yang padat seperti DKI Jakarta, di mana akumulasi emisi harian berpotensi memengaruhi kondisi kesehatan publik dalam jangka panjang. Oleh karena itu, analisis pemodelan untuk mengestimasi konsentrasi polutan ini diposisikan sebagai pendekatan teoretis dan eksperimental guna menyediakan acuan data yang dapat ditelaah secara terukur bagi pengelolaan lingkungan perkotaan.

II.2.1 Krisis Polusi Jakarta dan Integritas Dataset

DKI Jakarta tercatat sebagai salah satu kota dengan tingkat polusi udara yang tinggi di kawasan Asia Tenggara. Berbeda dengan kota-kota di lintang subtropis, kondisi polusi di Jakarta dipengaruhi oleh iklim tropis dan pola angin muson. Menurut Firdaus dkk. (September 2023), konsentrasi polutan mengalami kenaikan selama musim kemarau. Pada periode tersebut, fenomena inversi suhu menahan gas buang dari kendaraan bermotor dan industri di lapisan udara bawah kota. Kondisi ini sejalan dengan data Kementerian Kesehatan RI yang mencatat bahwa kualitas udara Jakarta dapat masuk ke dalam zona "Tidak Sehat" (Pusat Krisis Kesehatan Kementerian Kesehatan Republik Indonesia, Juli 2019; Aulia 2024).

Dalam perancangan model sains data berbasis deret waktu (*time series*), validitas hasil estimasi bergantung pada kelengkapan data historis. Penelitian ini menggunakan data Indeks Standar Pencemar Udara (ISPU) Jakarta untuk periode 2010–2025 (Pohan 2025). Pemilihan PM_{10} sebagai target utama prediksi didasarkan pada tingkat keandalan instrumen pemantauan di lapangan. Data polutan $PM_{2,5}$ di Jakarta sebelum tahun 2020 memiliki tingkat data kosong (*missing values*) yang mencapai 73%. Kondisi ini kurang ideal untuk melatih algoritma deret waktu yang membutuhkan kesinambungan data kronologis. Sebaliknya, parameter PM_{10} memiliki tingkat keterisian data yang tinggi, yaitu 94% observasi valid sejak tahun 2010, sehingga men-

jadi variabel yang stabil untuk digunakan dalam pemodelan.

II.2.2 Kalkulasi Indeks Standar Pencemar Udara (ISPU)

Untuk mempermudah penyampaian informasi tingkat polusi kepada masyarakat, Kementerian Lingkungan Hidup dan Kehutanan (KLHK) menggunakan indikator Indeks Standar Pencemar Udara (ISPU) (Chaniago, Zahara, dan Ramadhani, September 2020). Berdasarkan Peraturan Menteri LHK No. P.14 Tahun 2020 (Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia, Juli 2020), ISPU didefinisikan sebagai angka tanpa satuan (dari 0 hingga lebih dari 300) yang merangkum tingkat pencemaran dari berbagai indikator utama melalui mekanisme interpolasi linear bersegmen.

Penelitian Tugas Akhir ini difokuskan secara langsung pada prediksi nilai konsentrasi numerik mentah dari partikulat PM_{10} ($\mu g/m^3$) dan bukan pada angka indeks transformasi ISPU. Pendekatan ini dipilih guna menjaga granularitas varians data asli agar tidak tereduksi oleh fungsi pembagian segmen regulasi, sehingga algoritma komputasi dapat mempelajari pola fluktuasi secara lebih sensitif. Namun, klasifikasi kategori mutu udara berdasarkan rentang nilai regulasi tetap dimanfaatkan sebagai acuan dasar dalam memetakan tingkat risiko lingkungan di DKI Jakarta, sebagaimana disajikan pada Tabel II.3.

Tabel II.3 Kategorisasi ISPU dan Dampak Kesehatan Spesifik

Rentang Indeks	Kategori Mutu	Dampak dan Implikasi Kesehatan
0 – 50	Baik	Tidak memberikan efek negatif bagi kesehatan manusia, hewan, atau tumbuhan.
51 – 100	Sedang	Kualitas udara dapat diterima; berpotensi memengaruhi kelompok tumbuhan yang sensitif.
101 – 200	Tidak Sehat	Merugikan kesehatan umum, terutama kelompok rentan (bayi, lansia, dan penderita asma).
201 – 300	Sangat Tidak Sehat	Risiko tinggi penurunan fungsi paru serta memicu masalah kesehatan masyarakat yang lebih luas.
> 300	Berbahaya	Tingkat kritis; memicu keadaan darurat kesehatan serta gangguan pernapasan serius pada populasi.

Keterbatasan utama dari mekanisme pelaporan ISPU saat ini adalah sifatnya yang reaktif (Septiani, Juni 2024). Nilai ISPU yang dipublikasikan merupakan hasil per-

hitungan rata-rata dari kondisi kualitas udara selama 24 jam ke belakang. Artinya, mekanisme tersebut bersifat retrospektif karena mencerminkan akumulasi nilai masa lalu, sehingga belum menyediakan informasi prediktif untuk periode mendatang. Keterbatasan ini menjadi alasan mengapa integrasi pendekatan *machine learning* digunakan untuk membantu membangun pemodelan estimasi dini yang proaktif.

II.2.3 Mekanisme Fotokimia: Justifikasi Interaksi Fitur Komposit

Dinamika partikulat di udara perkotaan tidak hanya ditentukan oleh emisi pembuangan langsung, tetapi juga oleh pembentukan partikel sekunder melalui reaksi kimia di udara. Di wilayah beriklim tropis seperti Jakarta, radiasi ultraungu (UV) dari matahari bertindak sebagai pemicu reaksi fotokimia. Reaksi ini mengubah gas polutan menjadi partikel padat PM_{10} . Pemahaman mengenai reaksi kimia ini menjadi landasan untuk melakukan proses rekayasa fitur (*feature engineering*) pada model prediksi yang dikembangkan.

Dalam rantai reaksi tersebut, gas Karbon Monoksida (CO) dan Ozon (O_3) memiliki keterkaitan. CO digunakan sebagai indikator besarnya aktivitas emisi primer kendaraan sekaligus agen yang mempercepat reaksi kimia di udara. Di sisi lain, O_3 di permukaan tanah terbentuk dari hasil reaksi gas buang kendaraan akibat paparan radiasi matahari. Apabila konsentrasi gas CO dan O_3 berada pada tingkat yang tinggi dalam waktu yang bersamaan, kondisi ini mengindikasikan bahwa proses pembentukan polutan sekunder di udara sedang berlangsung, yang memengaruhi fluktuasi konsentrasi PM_{10} .

Pembuatan fitur turunan baru yang merupakan hasil kali interaksi antara gas tersebut ($CO \times O_3$) bertujuan untuk mendeteksi kondisi atmosferik yang reaktif tersebut. Secara komputasi, fitur tambahan ini memberikan informasi varians tambahan kepada algoritma *Random Forest* untuk mengenali pola pembentukan polusi sekunder. Penggunaan fitur interaksi kimiawi ini ditujukan untuk meminimalkan kesalahan prediksi pada saat terjadinya lonjakan polusi mendadak (Naz dkk. 2024). Dengan demikian, model memasukkan representasi karakteristik fisik dan kimia yang terjadi di atmosfer perkotaan.

II.3 Fondasi Teoretis Analisis Deret Waktu (*Time Series Analysis*)

Pemodelan kualitas udara pada dasarnya merupakan analisis data deret waktu (*time series*). Deret waktu PM_{10} (Y_t) didefinisikan sebagai sekumpulan variabel observasi yang diindeks berdasarkan urutan waktu (t). Prinsip utama dari analisis ini adalah asumsi bahwa nilai observasi pada waktu saat ini (t) memiliki keterikatan atau korelasi dengan nilai observasi pada rentang waktu sebelumnya ($t - k$) (Vasconcelos,

Juli 2025).

II.3.1 Karakteristik Komponen Temporal

Konsentrasi PM₁₀ di wilayah perkotaan merupakan perpaduan dari beberapa pola pergerakan temporal yang terjadi secara bersamaan. Secara teoretis, fluktuasi data runtun waktu dapat dipisahkan secara konseptual menjadi komponen tren jangka panjang (yang mencerminkan arah pergerakan pola emisi perkotaan secara perlahan) dan komponen musiman (yang berulang secara periodik mengikuti siklus iklim harian, mingguan, atau bulanan). Pemahaman terhadap karakteristik fluktuasi ini diperlukan agar pemodelan dapat memetakan dinamika data secara lebih terstruktur.

Pemisahan konseptual antara komponen pergerakan jangka panjang dan pola fluktuasi periodik ini menjadi landasan teoretis bagi penerapan arsitektur model hibrida sekuensial pada penelitian ini. Pemodelan tidak menggunakan fungsi dekomposisi statistik klasik secara formal, melainkan mengadopsi pendekatan asimilasi komponen varians. Algoritma *machine learning* berbasis pohon keputusan digunakan pada tahap awal untuk memetakan pola fluktuasi non-linier jangka pendek yang dipengaruhi oleh rekayasa fitur temporal. Selanjutnya, model statistik ARIMA difokuskan untuk menangkap sisaan pola autokorelasi linier yang belum terpetakan oleh model pertama guna meminimalkan nilai galat estimasi.

II.3.2 Prinsip Stasioneritas dan Formulasi Pengujian ADF

Syarat dalam menggunakan model statistik linier seperti ARIMA adalah data deret waktu harus bersifat stasioner. Sebuah data deret waktu dikatakan stasioner apabila karakteristik statistiknya, seperti nilai rata-rata (*mean*) dan ragam (*variance*), konstan seiring berjalannya waktu (Minitab, LLC 2025). Jika syarat stasioneritas ini tidak terpenuhi, model prediksi dapat menghasilkan estimasi yang kurang akurat.

Untuk memastikan apakah sebuah data sudah stasioner, pengujian dilakukan secara statistik menggunakan uji *Augmented Dickey-Fuller* (ADF) (Vasconcelos, Juli 2025). Uji ADF bekerja dengan mendeteksi ada tidaknya akar unit (*unit root*) pada data. Evaluasi ini dilakukan menggunakan model regresi yang diturunkan pada Persamaan II.1.

$$\Delta y_t = \alpha + \beta t + \gamma y_{t-1} + \sum_{i=1}^p \delta_i \Delta y_{t-i} + \epsilon_t \quad (\text{II.1})$$

Hasil dari perhitungan uji ADF dievaluasi melalui nilai probabilitas (*p-value*). Hipotesis nol (H_0) pada pengujian ini menyatakan bahwa data memiliki akar unit (tidak stasioner). Jika nilai *p-value* yang dihasilkan lebih kecil dari 0,05, maka H_0 ditolak, yang mengonfirmasi bahwa data PM_{10} telah stasioner sehingga pemodelan menggunakan ARIMA dapat dilakukan.

II.3.3 Autocorrelation dan Partial Autocorrelation Function (ACF & PACF)

Identifikasi korelasi waktu digunakan untuk memahami hubungan antara kualitas udara di masa lalu terhadap kondisi saat ini. Dalam pemodelan statistik, parameter model ditentukan dengan menganalisis nilai autokorelasi pada data tersebut.

Autocorrelation Function (ACF) mengukur tingkat korelasi antara nilai observasi saat ini (y_t) dengan nilai observasi pada masa lalu (y_{t-k}) pada berbagai interval waktu jeda (*lag*). Formulasi matematis untuk menghitung koefisien ACF diturunkan pada Persamaan II.2.

$$\rho_k = \frac{\sum_{t=k+1}^T (y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^T (y_t - \bar{y})^2} \quad (II.2)$$

Sementara itu, *Partial Autocorrelation Function* (PACF) mengukur korelasi antara observasi saat ini (y_t) dengan observasi masa lalu (y_{t-k}), tanpa memperhitungkan pengaruh dari jeda waktu yang berada di antaranya. Analisis kombinasi dari grafik ACF dan PACF digunakan sebagai instrumen untuk membantu menentukan batasan orde model (p dan q) dalam algoritma ARIMA.

II.4 Taksonomi Algoritma Regresi dan Teori Hibridisasi

Pemodelan data deret waktu PM_{10} berhadapan dengan dua karakteristik utama, yaitu pola non-linier yang dipicu oleh fluktuasi cuaca serta interaksi antar-polutan, dan pola linier dari tren jangka panjang. Oleh karena itu, pendekatan teoretis dalam penelitian ini menggabungkan algoritma *machine learning* berbasis pohon keputusan dan model statistik klasik.

II.4.1 Algoritma Random Forest Regressor

Random Forest (RF) merupakan algoritma *ensemble learning* yang bekerja dengan menggabungkan sekumpulan pohon keputusan (*Decision Trees*) untuk menghasilkan prediksi akhir dengan nilai kesalahan yang rendah (Arsy dan Yasir, April 2025; Abdallah dan Elameen, Juni 2025). Algoritma ini dirancang untuk mereduksi masalah varians tinggi (*overfitting*) yang dapat terjadi jika hanya menggunakan satu

pohon keputusan tunggal. RF menjaga stabilitas estimasi melalui dua proses acak utama:

1. *Bootstrap Aggregating* (Bagging): Setiap pohon keputusan di dalam model dilatih menggunakan sebagian baris data sampel acak berukuran N yang diambil dengan pengembalian (*with replacement*). Sekitar 36,8% data yang tidak terambil oleh sebuah pohon disebut sebagai data *Out-of-Bag* (OOB), yang dimanfaatkan untuk proses validasi internal model.
2. *Random Subspace Method*: Pada setiap proses penentuan cabang (*node splitting*), algoritma membatasi jumlah variabel fitur yang diuji. Jika terdapat M total fitur, algoritma hanya memilih sebagian fitur (umumnya $\sqrt{M}$ atau $M/3$) secara acak. Proses ini meminimalkan dominasi dari satu fitur tertentu, sehingga pohon-pohon yang dihasilkan menjadi lebih bervariasi secara independen.

Dalam setiap pembentukan pohon regresi, algoritma mencari fitur dan nilai batas (*threshold*) yang menghasilkan tingkat kesalahan minimum. Titik pemisahan tersebut dihitung dengan meminimalkan jumlah kuadrat sisaan (*Sum of Squared Residuals*) pada ruang pemisahan, sebagaimana diturunkan pada Persamaan II.3.

$$\min_{j,s} \left[\min_{c_1} \sum_{x_i \in R_1(j,s)} (y_i - c_1)^2 + \min_{c_2} \sum_{x_i \in R_2(j,s)} (y_i - c_2)^2 \right] \quad (\text{II.3})$$

$$\hat{y}_{RF} = \frac{1}{B} \sum_{b=1}^B T_b(x) \quad (\text{II.4})$$

Kelebihan fungsional RF adalah kemampuannya memodelkan data non-linier tanpa memerlukan asumsi distribusi data normal (*non-parametric*). Namun, struktur pembagian cabang membuat algoritma ini memiliki keterbatasan dalam memetakan tren pergerakan linier pada data deret waktu (Yenkikar dkk. Juli 2025). Hal ini menjadi dasar pertimbangan penggunaan algoritma tambahan, seperti ARIMA, untuk memodelkan sisaan (*residual*) linier yang tidak tertangkap oleh komponen RF.

II.4.2 Arsitektur *AutoRegressive Integrated Moving Average* (ARIMA)

Algoritma ARIMA adalah model statistik yang digunakan untuk menganalisis dan melakukan peramalan data deret waktu murni (*univariate*). Model ini memproyeksikan nilai masa depan berdasarkan kombinasi linier dari data historis dan nilai kesalahan (*error*) di masa lalu. Struktur model didefinisikan oleh tiga parameter orde utama, yaitu ARIMA(p, d, q) (Yunis, Andri, dan Djoni, Juni 2024).

Komponen *AutoRegressive* (AR) memodelkan nilai saat ini (Y_t) sebagai fungsi linier dari sejumlah p observasi masa lalu. Parameter orde p menentukan jumlah periode waktu (*lag*) yang dimasukkan ke dalam persamaan. Formulasi AR(p) dengan penambahan nilai konstanta c dan nilai galat acak ϵ_t diturunkan pada Persamaan II.5.

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t \quad (\text{II.5})$$

Transformasi *Integrated* (I) berfungsi untuk menstabilkan data yang tidak stasioner menjadi stasioner. Transformasi ini dilakukan melalui metode pembedaan (*differencing*) tingkat d , yaitu menghitung selisih antara nilai saat ini dengan nilai pada waktu sebelumnya secara berulang. Formulasi pembedaan tingkat pertama ($d = 1$) direpresentasikan pada Persamaan II.6.

$$y'_t = y_t - y_{t-1} \quad (\text{II.6})$$

Sementara itu, komponen *Moving Average* (MA) memodelkan observasi saat ini sebagai fungsi dari nilai sisaan galat (*error*) yang terjadi pada observasi masa lalu. Model ini digunakan untuk mengakomodasi fluktuasi acak pada data deret waktu. Orde q menentukan jumlah jendela observasi galat yang disertakan, sebagaimana diformulasikan pada Persamaan II.7.

$$Y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \cdots + \theta_q \epsilon_{t-q} \quad (\text{II.7})$$

Penggabungan operasional dari ketiga komponen tersebut menghasilkan struktur utuh model ARIMA. Penulisan matematis ARIMA disederhanakan menggunakan

fungsi operator bergeser mundur (*backshift operator*, L). Formulasi integrasi dari algoritma ARIMA diturunkan pada Persamaan II.8.

$$\left(1 - \sum_{i=1}^p \phi_i L^i\right) (1 - L)^d y_t = \left(1 + \sum_{i=1}^q \theta_i L^i\right) \epsilon_t \quad (\text{II.8})$$

II.4.3 Hibridisasi Sekuensial (Metodologi Asimilasi Zhang dan Justifikasi Residu)

Mengingat model tunggal memiliki batasan dalam memproses karakteristik linier dan non-linier secara bersamaan, analisis kualitas udara mulai memanfaatkan pendekatan hibridisasi. Secara konseptual, metodologi asimilasi yang dikembangkan oleh Zhang memandang fluktuasi deret waktu (Y_t) sebagai gabungan dari komponen linier (L_t) dan komponen non-linier (N_t), sebagaimana dirumuskan pada Persamaan II.9.

$$Y_t = N_t + L_t \quad (\text{II.9})$$

II.4.4 Justifikasi Pemodelan Residu Linier Menggunakan ARIMA

Pertanyaan mendasar dalam arsitektur ini adalah mengapa sisaan atau residu perlu dimodelkan secara terpisah dan mengapa ARIMA ditempatkan pada fase sekunder untuk memproses residu tersebut.

Algoritma berbasis pohon keputusan seperti *Random Forest* melatih pemisahan fitur secara non-parametrik tanpa asumsi deret waktu. Akibatnya, *Random Forest* cenderung memperlakukan setiap baris data sebagai observasi independen dan tidak mampu menangkap struktur autokorelasi linier (ketergantungan data hari t dengan hari $t - k$) yang intrinsik pada sisaan prediksi. Residu dari *Random Forest* ($e_t = Y_t - \hat{N}_t$) bukanlah derau acak putih (*white noise*), melainkan masih menyimpan informasi temporal dan tren linier sisa yang tidak terurai oleh percabangan pohon keputusan.

Di sinilah letak peran ARIMA. ARIMA secara spesifik dirancang untuk menyelesaikan struktur autokorelasi linier pada data univariat yang stasioner melalui parameter AutoRegressive (AR) dan Moving Average (MA). Dengan menempatkan ARIMA khusus pada fase sekunder untuk memodelkan deret residu, model hibrida ini bekerja secara komplementer: *Random Forest* menyelesaikan fluktuasi kompleks non-linier dari parameter multivariat, sedangkan ARIMA membersihkan dan mengoreksi sisa galat linier temporal yang tertinggal. Pendekatan gabungan ini terbukti menghasilkan nilai kesalahan peramalan yang lebih rendah dibandingkan jika hanya mengandalkan satu model regresi tunggal murni.

Implementasi model hibrida sekuensial membagi proses kalkulasi berdasarkan karakteristik fungsi datanya. Model ini bekerja melalui tiga fase proses algoritma:

1. Fase Primer: Model *Random Forest* (RF) digunakan pada tahap awal untuk memproses variabel fitur masukan dan menghasilkan proyeksi estimasi nilai awal ($\hat{N}_t$). RF bertugas menangkap komponen tren non-linier data polusi.
2. Ekstraksi Residu: Sisa galat prediksi (*residual*) dari hasil RF dihitung melalui persamaan $e_t = Y_t - \hat{N}_t$. Sisa galat ini merepresentasikan komponen linier data yang tidak dikenali oleh algoritma pohon keputusan.
3. Fase Sekunder: Nilai sisaan galat (e_t) tersebut kemudian diolah secara terpisah oleh model linier ARIMA. ARIMA akan menyesuaikan ordenya untuk memprediksi arah nilai galat pada periode selanjutnya ($\hat{L}_t$).


Taksiran akhir dari arsitektur hibrida sekuensial ($\hat{Y}_{hybrid}$) merupakan hasil penjumlahan dari prediksi fase primer dan koreksi dari fase sekunder, sebagaimana diturunkan pada Persamaan II.10.

$$\hat{Y}_{hybrid} = \hat{N}_t + \hat{L}_t \quad (II.10)$$

Keluaran prediksi akhir untuk parameter PM_{10} diperoleh melalui operasi penjumlahan antara nilai estimasi komponen regresi *Random Forest* ($\hat{y}_{RF}$) dengan taksiran sisaan (*residual*) dari komponen statistik ARIMA ($\hat{r}_{ARIMA}$). Proses penggabungan hasil kalkulasi komponen non-linier dan linier ini secara matematis direpresentasikan pada Persamaan II.11.

$$\hat{y}_{hybrid} = \hat{y}_{RF} + \hat{r}_{ARIMA} \quad (II.11)$$

Sebagai bentuk penerapan dari kerangka pemodelan komplementer tersebut, penelitian ini mengasimilasi algoritma *Random Forest* dan ARIMA ke dalam satu alur sekuensial yang saling melengkapi (Yenkikar dkk. Juli 2025). Konfigurasi aliran data, ekstraksi nilai residu, hingga tahapan jumlahan hasil penaksiran nilai pada arsitektur hibrida yang diusulkan ini secara menyeluruh divisualisasikan pada Gambar II.1.



Gambar II.1 Arsitektur Aliran Kerja Model Hibrida *Random Forest*-ARIMA (Yenkikar dkk. Juli 2025)

II.5 Rekayasa Fitur (*Feature Engineering*) Dimensi Atmosferik

Batasan dari beberapa pemodelan estimasi kualitas udara terdahulu terletak pada penggunaan data historis secara langsung tanpa melalui tahapan rekayasa fitur (*feature engineering*). Konsentrasi polutan di atmosfer dipengaruhi oleh dinamika lingkungan lokal. Penelitian oleh Naz dkk. (2024) menunjukkan bahwa ketidakhadiran tahapan rekayasa fitur dapat memengaruhi nilai galat estimasi karena model mengalami keterbatasan dalam mengidentifikasi hubungan empiris dari variabel prediktor.

Oleh karena itu, rekayasa fitur digunakan untuk mentransformasi data dasar menjadi variabel turunan (*engineered features*) yang merepresentasikan variasi temporal dan karakteristik hubungan polutan. Proses ini mencakup pembentukan fitur jeda temporal (*temporal lags*) untuk memetakan pengaruh variabel dari periode sebelumnya, metrik tren berjalan untuk mengamati volatilitas data, serta fitur interaksi komposit untuk mendeteksi indikasi kondisi atmosferik tertentu. Transformasi ini ditujukan

untuk membantu algoritma *machine learning* dalam mengenali karakteristik data secara lebih terstruktur.

II.5.1 Kalkulasi Jeda Temporal (*Lag Features*)

Pemodelan deret waktu untuk kualitas udara didasarkan pada asumsi bahwa nilai konsentrasi polutan pada waktu saat ini (t) memiliki ketergantungan terhadap nilai pada rentang waktu sebelumnya ($t - k$). Keterikatan temporal ini terjadi karena partikulat (seperti PM_{10}) mengalami proses peluruhan secara bertahap di atmosfer. Oleh karena itu, mentransformasi data observasi masa lalu menjadi variabel masukan melalui fitur jeda temporal (*lag features*) digunakan sebagai mekanisme untuk menyertakan informasi dependensi temporal pada algoritma.

Pembentukan fitur jeda jangka pendek, yaitu *lag-1* (satu hari sebelumnya) dan *lag-2* (dua hari sebelumnya), dirancang untuk memetakan pengaruh sisa polutan harian. Fluktuasi nilai PM_{10} pada hari ini dipengaruhi oleh akumulasi polutan hari sebelumnya yang tertahan di lapisan atmosfer bawah akibat fenomena inversi suhu. Melalui penambahan variabel ini, algoritma dapat mengidentifikasi kecenderungan akumulasi polutan di suatu wilayah.

Selain itu, fitur jeda jangka menengah seperti *lag-7* (tujuh hari sebelumnya) disertakan untuk mendeteksi siklus aktivitas mingguan. Di wilayah urban seperti Jakarta, aktivitas transportasi dan industri menunjukkan perbedaan karakteristik pola antara hari kerja (*weekdays*) dan akhir pekan (*weekends*). Fitur *lag-7* menggunakan penanda fungsional agar model mengenali siklus periodik mingguan tersebut agar dapat mengantisipasi pola variasi mobilitas masyarakat perkotaan.

II.5.2 Metrik Tren Berjalan (*Rolling Window Statistics*)

Data kualitas udara harian dapat mengandung fluktuasi acak (*noise*) akibat faktor meteorologi sesaat. Jika model prediksi hanya menggunakan nilai observasi tunggal seperti fitur jeda (*lag*), model tersebut berpotensi mengalami *overfitting* karena algoritma menjadi sensitif terhadap fluktuasi jangka pendek dan kurang mampu mengidentifikasi kecenderungan pergerakan data secara keseluruhan.

Untuk meminimalkan risiko tersebut, rekayasa fitur diperluas dengan menambahkan perhitungan statistik berbasis rentang waktu berjalan (*rolling window statistics*). Metode ini berfungsi untuk mentransformasi fluktuasi harian menjadi nilai tren pergerakan akumulasi polutan. Fitur ini dihitung melalui dua pendekatan, yaitu rata-rata bergerak (*rolling mean*) dan standar deviasi bergerak (*rolling standard deviation*).

Pendekatan rata-rata bergerak (*moving average*) digunakan untuk memperhalus fluktuasi harian yang ekstrim pada data. Fitur ini menyajikan representasi mengenai arah pergerakan tren polutan secara umum. Pada penelitian ini, digunakan jendela waktu berjalan 3-hari (pm10_ma3) untuk mengidentifikasi tren jangka pendek dan jendela 7-hari (pm10_ma7) untuk mengevaluasi stabilitas tren mingguan. Formulasi matematika untuk menghitung rata-rata bergerak pada rentang waktu w diturunkan pada Persamaan II.12.

$$MA_w(t) = \frac{1}{w} \sum_{i=1}^w y_{t-i} \quad (\text{II.12})$$

Sementara itu, pendekatan standar deviasi bergerak (*rolling standard deviation*) berfungsi untuk mengukur derajat volatilitas data. Karakteristik stabilitas atmosfer dapat mengalami variasi seiring dengan perubahan cuaca harian. Penambahan variabel pm10_std7 digunakan sebagai indikator bagi model untuk mendeteksi keberadaan fluktuasi yang besar pada data. Perhitungan standar deviasi ini diturunkan pada Persamaan II.13.

$$STD_w(t) = \sqrt{\frac{1}{w-1} \sum_{i=1}^w (y_{t-i} - MA_w(t))^2} \quad (\text{II.13})$$

II.5.3 Penanda Temporal Kategorikal dan Interaksi Polutan

Model juga memerlukan variabel temporal eksplisit untuk mengenali pengaruh pergantian musim. Fitur kategorikal month (bulan) dan season (musim) digunakan agar algoritma dapat mempelajari pola pengendapan basah (*wet scavenging*) di mana curah hujan berkontribusi menurunkan konsentrasi polutan di udara. Selain itu, variabel biner is_weekend ditambahkan sebagai penanda komputasi mengenai penurunan volume kendaraan pada akhir pekan.

Untuk aspek kimiawi, pembentukan partikulat sangat dipengaruhi oleh reaksi fotokimiawi akibat radiasi sinar matahari. Fitur interaksi komposit co_times_o3 (hasil perkalian konsentrasi Karbon Monoksida dengan Ozon) dimasukkan sebagai variabel baru. Karbon Monoksida merepresentasikan indikator emisi primer kendaraan, sedangkan Ozon merupakan indikator derajat oksidasi atmosferik. Melalui penggabungan kedua nilai tersebut menjadi fitur tunggal, model *Random Forest* dapat mengidentifikasi kondisi pembentukan polutan sekunder secara lebih efisien tanpa

memerlukan kedalaman percabangan pohon keputusan yang tinggi.

II.5.4 Spesifikasi Matriks Fitur Prediktor

Proses rekayasa fitur dalam penelitian ini disusun menjadi sebuah himpunan variabel masukan (*feature matrix*). Naz dkk. (2024) mengonfirmasi bahwa penerapan rekayasa fitur secara tepat dapat memberikan kontribusi positif terhadap performa model prediksi deret waktu kualitas udara.

Matriks fitur pada penelitian ini terdiri dari 15 variabel yang dikelompokkan ke dalam 5 fitur dasar (*baseline*) dan 10 fitur turunan (*engineered features*). Keseluruhan spesifikasi dari kelima belas fitur masukan tersebut beserta fungsi fisisnya disajikan pada Tabel II.4.

Tabel II.4 Spesifikasi Matriks 15 Fitur Prediktor dalam Arsitektur Model

Kategori	Nama Fitur	Deskripsi dan Fungsi Fisis Atmosferik
Baseline	pm10	Konsentrasi harian PM ₁₀ aktual.
Baseline	so2	Konsentrasi Sulfur Dioksida (SO ₂).
Baseline	co	Konsentrasi Karbon Monoksida (CO) sebagai indikator emisi primer transportasi.
Baseline	o3	Konsentrasi Ozon Permukaan (O ₃) sebagai indikator aktivitas fotokimia.
Baseline	no2	Konsentrasi Nitrogen Dioksida (NO ₂).
Lag Temporal	pm10_lag1	Nilai PM ₁₀ hari $t - 1$ untuk menangkap pengaruh persistensi polutan.
Lag Temporal	pm10_lag2	Nilai PM ₁₀ hari $t - 2$.
Lag Temporal	pm10_lag7	Nilai PM ₁₀ hari $t - 7$ untuk memetakan pola perulangan mingguan.
Statistik Berjalan	pm10_ma3	Rata-rata bergerak 3 hari untuk mereduksi fluktuasi jangka pendek.
Statistik Berjalan	pm10_ma7	Rata-rata bergerak 7 hari untuk mengevaluasi stabilitas satu minggu.
Statistik Berjalan	pm10_std7	Standar deviasi bergerak 7 hari untuk mengukur tingkat volatilitas data.
Kategorikal	month	Penanda bulan (1–12) untuk memetakan variasi musiman makro.
Kategorikal	is_weekend	Indikator biner akhir pekan (0/1) untuk meninjau perubahan mobilitas urban.

Bersambung ke halaman berikutnya.

Tabel II.4 Spesifikasi Matriks 15 Fitur Prediktor (Lanjutan)

Kategori	Nama Fitur	Deskripsi dan Fungsi Fisis Atmosferik
<i>Kategorikal</i>	season	Klasifikasi musim hujan/kemarau sebagai representasi efek pengendapan basah.
<i>Interaksi Kimia</i>	co_times_o3	Hasil kali $\text{CO} \times \text{O}_3$ untuk mendeteksi laju pembentukan polutan sekunder.

II.6 Prosedur Penyetelan Parameter Menggunakan Optuna

Dalam pengembangan model pembelajaran mesin, penyesuaian nilai parameter internal (*hyperparameter*) merupakan tahapan pendukung untuk memfasilitasi proses pelatihan komponen pembentuk model hibrida. Pada algoritma *Random Forest*, tahapan ini mencakup pengaturan batasan struktural seperti jumlah pohon keputusan dan batas kedalaman cabang. Penentuan nilai parameter ini diterapkan sebagai instrumen bantu untuk mengendalikan kondisi di mana model meniru data latih secara berlebihan (*overfitting*) atau kurang mampu menangkap pola dasar data (*underfitting*). Pustaka Optuna digunakan dalam penelitian ini sebagai alat pendukung untuk mencari konfigurasi parameter secara terarah berdasarkan riwayat eksperimen sebelumnya, guna membantu proses inisialisasi komponen non-linier pada arsitektur hibrida (Kostadinov dkk. Desember 2024).

II.6.1 Perbandingan Metode Grid Search dan Pencarian Probabilistik

Metode *Grid Search* bekerja dengan mengevaluasi seluruh kombinasi parameter yang ditentukan dalam ruang pencarian secara berurutan. Pendekatan konvensional ini memerlukan alokasi waktu pemrosesan yang bertambah seiring banyaknya variasi parameter yang diuji. Sebagai alternatif pendukung, pencarian berbasis probabilitas memanfaatkan data evaluasi dari tahapan sebelumnya untuk memperkirakan rentang parameter berikutnya yang memiliki potensi nilai kesalahan harian yang lebih rendah. Pustaka Optuna menerapkan prinsip ini dengan membangun fungsi perkiraan (*surrogate model*) untuk memetakan pengaruh nilai parameter terhadap nilai galat estimasi, sehingga durasi pencarian konfigurasi pada komponen model hibrida dapat berjalan secara teratur (Kostadinov dkk. Desember 2024).

II.6.2 Mekanisme Pencarian Berbasis *Tree-structured Parzen Estimator* (TPE)

Algoritma *Tree-structured Parzen Estimator* (TPE) di dalam pustaka Optuna memisahkan hasil evaluasi parameter dari tahapan sebelumnya ke dalam dua kelompok distribusi secara statistik, yaitu kelompok dengan nilai galat rendah dan kelompok dengan nilai galat tinggi. Rekomendasi nilai parameter baru kemudian diarahkan secara probabilistik pada area ruang parameter yang mendekati karakteristik kelompok galat rendah. Prosedur ini difungsikan untuk membantu proses kalibrasi parameter pembentuk arsitektur hibrida.

II.6.3 Prosedur Pemangkasan Percobaan (*Pruning*)

Pencarian parameter didukung oleh prosedur pemangkasan otomatis (*pruning*). Mekanisme ini mengevaluasi perkembangan nilai galat di pertengahan proses pelatihan suatu urutan percobaan. Jika pada tahapan awal nilai galat yang dihasilkan menunjukkan kecenderungan yang lebih besar dibandingkan riwayat percobaan sebelumnya, proses komputasi untuk kombinasi parameter tersebut akan dihentikan secara dini. Langkah ini digunakan untuk menghemat penggunaan sumber daya memori tanpa memengaruhi hasil akhir pencarian parameter pendukung model.

II.7 Skalabilitas dan Kompleksitas Komputasi Algoritma

Evaluasi terhadap sebuah arsitektur pemodelan *machine learning* tidak hanya diukur berdasarkan akurasi statistik, tetapi juga berdasarkan skalabilitas komputasinya. Analisis kompleksitas komputasi digunakan sebagai standar pengukuran untuk memperkirakan kecenderungan kebutuhan memori (*space complexity*) dan waktu pemrosesan (*time complexity*) seiring dengan bertambahnya volume data masukan.

Estimasi efisiensi algoritma ini diformulasikan menggunakan notasi *Big-O* (O). Notasi ini mendeskripsikan batas atas waktu eksekusi (*upper bound*) atau performa algoritma pada skenario terburuk (*worst-case scenario*) ketika ukuran data observasi (N) bernilai besar. Melalui pendekatan teoretis ini, potensi kendala efisiensi komputasi dapat diidentifikasi sebelum model diterapkan pada tahap implementasi operasional ke dalam sistem peladen (*server*).

Pada kasus peramalan kualitas udara harian di Jakarta, sistem memerlukan proses kalkulasi yang cepat secara berulang (iteratif) setiap hari. Oleh karena itu, penggabungan model pada arsitektur hibrida *Random Forest-ARIMA* harus dipastikan secara teoritis tidak menghasilkan pertumbuhan durasi eksekusi yang eksponensial.

II.7.1 Kompleksitas Komputasi Fase Primer: *Random Forest*

Kompleksitas waktu untuk proses pelatihan (*training time*) pada algoritma *Random Forest* ditentukan oleh interaksi tiga variabel utama, yaitu total jumlah baris data observasi (N), jumlah fitur prediktor yang dievaluasi pada setiap penentuan cabang (M), dan jumlah pohon keputusan yang dibangun dalam model (*estimators*) yang disimbolkan dengan K . Ketiga parameter ini menentukan jumlah operasi perhitungan yang dieksekusi oleh prosesor komputer.

Dalam proses pembangunan satu pohon keputusan, tahapan dengan kebutuhan komputasi terbesar adalah proses pengurutan (*sorting*) nilai fitur untuk menemukan titik pisah (*threshold*) dengan nilai kesalahan minimum. Algoritma *sorting* secara umum memerlukan waktu komputasi sebesar $N \log N$. Proses ini kemudian dikalikan dengan jumlah fitur (M) dan jumlah pohon yang dibangun (K). Dengan demikian, kompleksitas waktu batas atas untuk pelatihan *Random Forest* diturunkan pada Persamaan II.14.

$$O(K \cdot M \cdot N \log N) \quad (\text{II.14})$$

Berdasarkan Persamaan II.14, *Random Forest* memiliki kompleksitas waktu bersifat kuasi-linier ($N \log N$). Waktu komputasinya mengalami pertumbuhan yang konstan seiring dengan penambahan baris data. Karakteristik skalabilitas ini mendukung efisiensi *Random Forest* untuk memproses data tabular berjumlah besar jika dibandingkan dengan arsitektur *Deep Learning* seperti LSTM yang memiliki kompleksitas fungsi kuadratik $O(N^2)$ serta memerlukan proses perulangan mundur (*backpropagation*) secara berulang.

II.7.2 Kompleksitas Komputasi Fase Sekunder: Arsitektur ARIMA

Pada fase sekunder, pemrosesan sisa galat dilakukan menggunakan algoritma statistik ARIMA. Karakteristik komputasi ARIMA berbeda dengan arsitektur pohon keputusan. ARIMA tidak melakukan pemisahan variabel fitur, melainkan berfokus pada penyelesaian fungsi estimasi matematis berupa *Maximum Likelihood Estimation* (MLE). Fungsi MLE bertujuan menemukan kombinasi koefisien pembobotan yang mendekati pola data sisaan (*residuals*) aktual.

Kompleksitas konvergensi dari fungsi MLE dipengaruhi oleh penjumlahan orde *AutoRegressive* (p) dan orde *Moving Average* (q), serta total baris deret waktu observa-

si (N). Jika proses perulangan internal pencarian dibatasi oleh konstanta maksimal sebesar c , maka batas atas kompleksitas waktu pelatihan algoritma ARIMA direpresentasikan pada Persamaan II.15.

$$O(c \cdot N \cdot (p + q)^2) \quad (\text{II.15})$$

Persamaan II.15 menunjukkan karakteristik matematis di mana waktu proses ARIMA tumbuh secara linier $O(N)$ terhadap panjang riwayat data. Pertumbuhan waktu berbentuk fungsi kuadratik terjadi pada elemen orde model $(p + q)^2$. Namun, dalam penerapan praktis pemodelan deret waktu, total penjumlahan orde p dan q umumnya bernilai kecil. Dengan karakteristik tersebut, penambahan tahap ARIMA di akhir rangkaian sistem estimasi memiliki kebutuhan komputasi yang rendah dan tidak menghambat siklus pembaruan kalkulasi harian.

II.8 Interpretabilitas Model menggunakan SHAP

Meskipun model ansambel seperti *Random Forest* memberikan nilai akurasi estimasi yang terkendali, model ini memiliki karakteristik komputasi yang tertutup (*black-box*) (Jiménez-Navarro dkk. Desember 2024). Untuk kebutuhan analisis polusi udara, model harus mampu memberikan penjelasan mengenai variabel fitur yang memengaruhi variasi nilai konsentrasi PM_{10} . Penelitian ini menerapkan pendekatan *Explainable AI* (XAI) melalui metode SHAP (*SHapley Additive exPlanations*) untuk memetakan besaran pengaruh setiap variabel masukan terhadap hasil estimasi akhir.

II.8.1 Justifikasi Validitas SHAP pada Model Hibrida Sekuensial

Satu hal krusial yang perlu diklarifikasi adalah mengapa metode SHAP valid digunakan untuk menginterpretasikan model hibrida sekuensial ini.

Dalam arsitektur hibrida yang diusulkan, seluruh 15 variabel masukan (fitur dasar, lag temporal, statistik jendela berjalan, penanda musim, dan interaksi komposit $CO \times O_3$) dievaluasi dan diproses hanya pada fase primer oleh model regresi non-linier *Random Forest*. Model ARIMA pada fase sekunder tidak menerima 15 fitur tersebut, melainkan hanya menerima data univariate deret waktu sisaan (residual) satu dimensi (e_t) yang tidak memiliki struktur fitur regresi.

Oleh karena itu, hubungan inferensial pemetaan fitur-fitur prediktor terhadap keputusan estimasi sepenuhnya terjadi di dalam struktur pohon keputusan *Random Fo-*

rest. Penerapan TreeSHAP secara eksklusif pada fase primer bersifat valid karena mengurai visualisasi kontribusi marginal dari 15 fitur tersebut terhadap pembentukan nilai prediksi awal ($\hat{N}_t$), yang merupakan komponen varians terbesar dalam arsitektur hibrida ini. Koreksi residual dari ARIMA bersifat post-hoc penyesuaian tren runtun waktu linear sisa dan tidak mengaburkan interpretasi fisis antar-fitur polutan yang diekstrak oleh SHAP.

II.8.2 Distribusi Atribusi *Shapley Value*

Mekanisme perhitungan distribusi bobot ini didasarkan pada perhitungan nilai Shapley (*Shapley Value*). Algoritma terlebih dahulu menghitung efek marjinal (*marginal effect*), yaitu seberapa besar hasil prediksi berubah ketika sebuah fitur tertentu (i) dimasukkan ke dalam sebuah himpunan fitur (S) yang tidak mengandung fitur i . Perhitungan efek marjinal ini direpresentasikan pada Persamaan II.16.

$$\Delta f_i(S) = f(S \cup \{i\}) - f(S) \quad (\text{II.16})$$

Nilai akhir bobot atribusi SHAP (ϕ_i) diperoleh dengan menghitung rata-rata terbobot dari semua kemungkinan efek marjinal tersebut melalui probabilitas permutasi untuk meminimalkan bias urutan variabel masukan, sebagaimana diturunkan pada Persamaan II.17.

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [f(S \cup \{i\}) - f(S)] \quad (\text{II.17})$$

II.8.3 Interpretasi Visual Diagnostik SHAP

Keluaran dari perhitungan nilai SHAP dapat ditampilkan melalui dua grafik utama untuk membantu proses interpretasi model, yaitu *SHAP Summary Plot (Beeswarm)* dan *SHAP Dependence Plot*.

SHAP Summary Plot (Beeswarm) digunakan untuk menampilkan peringkat dan arah pengaruh dari setiap variabel masukan terhadap prediksi model secara global. Pada grafik ini, sumbu vertikal (Y) menampilkan nama fitur yang diurutkan berdasarkan kontribusi absolutnya terhadap model. Sumbu horizontal (X) menunjukkan besaran nilai SHAP yang dihasilkan. Grafik ini menggunakan gradasi warna untuk menunjukkan nilai asli dari fitur tersebut, di mana warna biru merepresentasikan nilai fitur yang rendah dan warna merah merepresentasikan nilai fitur yang tinggi. Sebagai

contoh, jika persebaran titik berwarna merah pada fitur Ozon berada di sisi kanan sumbu X (nilai SHAP positif), kondisi tersebut menunjukkan bahwa nilai konsentrasi Ozon yang tinggi berhubungan dengan estimasi nilai PM_{10} yang lebih tinggi pada model.

Sementara itu, *SHAP Dependence Plot* digunakan untuk menganalisis efek dari satu variabel fitur secara spesifik. Sumbu horizontal memuat nilai asli fitur tersebut, sedangkan sumbu vertikal memuat nilai dampak SHAP terhadap prediksi model. Distribusi titik pada grafik memperlihatkan karakteristik hubungan fitur terhadap target, seperti kecenderungan pola linear, eksponensial, atau kondisi konstan pada titik tertentu. *SHAP Dependence Plot* juga dapat dilengkapi dengan gradasi warna berbasis variabel kedua untuk meninjau pola interaksi antara dua variabel prediktor dalam memengaruhi hasil estimasi.

II.9 Prosedur Pengukuran Galat dan Skema Validasi Temporal

Pengukuran nilai galat peramalan kualitas udara merupakan tahapan kontrol untuk menguji keandalan hasil estimasi model hibrida. Mengingat data konsentrasi PM_{10} memiliki karakteristik fluktuasi yang dipengaruhi faktor harian, diperlukan metrik evaluasi statistik untuk mengamati deviasi hasil prediksi terhadap data aktual. Penelitian ini menggunakan tiga indikator ukuran standar, yaitu *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan Koefisien Determinasi (R^2), yang digabungkan dengan skema validasi berbasis waktu untuk menjaga proses evaluasi agar terhindar dari kebocoran data masa depan (*look-ahead bias*).

II.9.1 Metrik *Root Mean Square Error* (RMSE)

Metrik *Root Mean Square Error* (RMSE) menghitung akar kuadrat dari rata-rata selisih kuadrat antara nilai hasil estimasi model dengan nilai observasi aktual. Karena melibatkan operasi pengkuadratan selisih, RMSE memberikan bobot penalti yang lebih besar pada nilai kesalahan yang besar (*outliers*). Karakteristik ini digunakan sebagai indikator kontrol untuk mengamati ketahanan model hibrida saat menghadapi fluktuasi data yang tajam pada set pengujian.

II.9.2 Metrik *Mean Absolute Error* (MAE) dan Koefisien Determinasi (R^2)

Sebagai pelengkap analisis, metrik *Mean Absolute Error* (MAE) digunakan untuk mengukur rata-rata mutlak dari kesalahan estimasi secara linier proporsional. Metrik ini menggambarkan deviasi rata-rata harian hasil prediksi terhadap kondisi riil di lapangan. Sementara itu, Koefisien Determinasi (R^2) digunakan untuk mengamati seberapa besar variabilitas data target dapat digambarkan oleh variabel masukan di dalam model, dengan rentang nilai antara 0 hingga 1.

II.9.3 Skema Validasi Temporal *Time-Series Forward Chaining*

Prosedur pembagian data latih dan data uji pada data deret waktu memerlukan penanganan khusus untuk menjaga urutan kronologis data. Penggunaan metode validasi silang konvensional (*K-Fold Cross-Validation*) yang mengacak baris data kurang sesuai karena dapat menimbulkan risiko kebocoran data masa depan (*look-ahead bias*), di mana model secara tidak langsung mempelajari informasi periode mendatang untuk memprediksi periode masa lalu. Guna menjaga validitas pengujian model hibrida, digunakan skema *TimeSeriesSplit* dengan pendekatan rantai maju (*Forward Chaining*). Dalam prosedur ini, data pembagi bergerak maju secara kronologis berurutan, sehingga model selalu diuji menggunakan data periode setelah masa pelatihan, menyimulasikan kondisi operasional riil saat menerima data baru harian.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini dan Kesenjangan Sistem

Subbab ini menguraikan evaluasi terhadap infrastruktur pemantauan kualitas udara yang beroperasi di wilayah DKI Jakarta pada saat ini. Analisis difokuskan pada pemetaan alur kerja operasional, identifikasi keterbatasan fungsional dari sistem berjalan, serta penemuan kesenjangan (*gap*) antara kondisi aktual dengan kebutuhan mitigasi pencemaran udara. Hasil dari evaluasi ini digunakan sebagai landasan dan justifikasi teknis bagi pengembangan arsitektur prediktif yang diusulkan dalam penelitian.


III.1.1 Arsitektur Sistem Pemantauan Berjalan

Sistem pemantauan kualitas udara di wilayah DKI Jakarta saat ini dioperasikan secara terpusat oleh Dinas Lingkungan Hidup (DLH) Provinsi DKI Jakarta. Infrastruktur pemantauan secara fisik terdiri dari lima stasiun pemantauan kualitas udara ambien (SPKUA) otomatis yang ditempatkan pada lokasi-lokasi tertentu untuk merepresentasikan karakteristik tata ruang kota (DKI1 hingga DKI5). Setiap stasiun dilengkapi instrumen yang mencatat konsentrasi parameter polutan harian, yang meliputi PM_{10} , SO_2 , CO , O_3 , dan NO_2 .

Data yang ditangkap oleh kelima SPKUA tersebut kemudian ditransmisikan ke pusat data untuk diintegrasikan. Pada tahap selanjutnya, nilai konsentrasi polutan tersebut dikonversi menjadi metrik terstandarisasi, yaitu Indeks Standar Pencemar Udara (ISPU). Hasil perhitungan ISPU ini kemudian didistribusikan kepada masyarakat dan instansi terkait sebagai laporan indikator kualitas udara. Alur pengolahan data dari tahap akuisisi hingga publikasi ini membentuk sebuah alur penyampaian informasi yang linier dan statis.

Meskipun infrastruktur fisik pemantauan telah beroperasi, sistem pelaporan saat ini memiliki keterbatasan fungsional tertentu. Alur pengelolaan data yang diimplementasikan bersifat satu arah dan reaktif terhadap kondisi lingkungan. Data historis yang

ditarik dari stasiun langsung dipublikasikan tanpa melalui modul analisis prediktif, sehingga sistem membatasi peluang bagi pihak terkait untuk melakukan langkah mitigasi dini sebelum paparan polusi mencapai ambang batas baku mutu. Model konseptual dari alur pelaporan sistem berjalan beserta celah fungsionalnya tersebut divisualisasikan pada Gambar III.1.



Gambar III.1 Model konseptual alur pelaporan kualitas udara Jakarta saat ini

III.1.2 Analisis Kesenjangan (*Gap Analysis*) dan Keterbatasan Literatur

Berdasarkan kajian terhadap operasional sistem berjalan dan tinjauan literatur pada domain pemodelan kualitas udara, ditemukan celah fungsional yang membatasi efektivitas mitigasi. Kesenjangan paling mendasar pada arsitektur saat ini adalah adanya latensi informasi. Ketiadaan kapabilitas peramalan (*forecasting*) mengakibatkan informasi bahaya pencemaran baru tersedia setelah kejadian berlangsung (*post-factum*). Kondisi ini menyebabkan keterbatasan waktu bagi otoritas terkait untuk mengaktivasi protokol peringatan dini bagi kelompok masyarakat.

Selain celah operasional, evaluasi terhadap studi terdahulu juga menyoroti limitasi metodologis pada arsitektur prediktif yang ada. Penelitian sebelumnya yang mengandalkan model berbasis memori sekuensial jangka panjang (Arsy dan Yasir, April 2025) dapat mengalami penurunan performa ketika dihadapkan pada fluktuasi acak (*noise*). Pendekatan tersebut memiliki kecenderungan mengalami kondisi *overfitting*, terutama ketika dilatih menggunakan dataset lingkungan yang berdimensi waktu kecil namun memiliki volatilitas tinggi akibat dinamika cuaca lokal.

Kesenjangan selanjutnya terletak pada karakteristik komputasi yang tertutup (*black-box*) pada proses pemodelan data. Penerapan algoritma dengan struktur kompleks sering kali mengorbankan aspek interpretabilitas demi mengejar nilai akurasi. Tanpa adanya modul *Explainable AI* (XAI) yang terintegrasi, proses analisis untuk mengi-

identifikasi apakah fluktuasi polusi didorong oleh efek akumulasi historis (*lag effect*) atau dipicu oleh reaksi sekunder antarpolutan menjadi terbatas. Identifikasi ketiga kesenjangan ini menjadi dasar pertimbangan untuk mengembangkan model prediktif baru yang ditujukan untuk meminimalkan pengaruh derau (*noise*) serta dapat diinterpretasikan secara transparan.

III.2 Analisis Karakteristik Dataset Kualitas Udara (*Data Profiling*)

Pemodelan deret waktu bergantung pada pemahaman terhadap karakteristik data yang tersedia. Subbab ini menguraikan analisis statistik deskriptif terhadap data historis ISPU DKI Jakarta untuk rentang waktu 2010 hingga 2025. Proses ini bertujuan untuk menganalisis karakteristik nilai dasar polutan PM_{10} dan parameter pendukung lainnya guna menjamin bahwa input yang dimasukkan ke dalam model hibrida memiliki landasan empiris yang valid.

Analisis profil data dilakukan melalui pendekatan multivariat untuk melihat bagaimana setiap parameter polutan berinteraksi dan berkontribusi terhadap kualitas udara secara keseluruhan. Selain itu, evaluasi dilakukan pada tingkat stasiun guna menangkap variabilitas spasial yang ada di lima titik pemantauan berbeda di Jakarta. Pemahaman ini diperlukan karena performa model *machine learning* bergantung pada kualitas representation fitur yang diekstraksi dari dataset.

Tahapan ini juga mencakup identifikasi anomali, pola musiman, dan ketergantungan temporal melalui metode analisis statistik formal. Melalui pelaksanaan *data profiling* yang menyeluruh, risiko terjadinya regresi spurious dapat diminimalkan. Hasil dari analisis ini menjadi dasar pertimbangan dalam perancangan strategi *feature engineering* dan arsitektur model hibrida yang diusulkan.


III.2.1 Analisis Integritas Data dan Kelayakan Multivariat

Evaluasi terhadap integritas dataset merupakan langkah untuk menjamin stabilitas model prediktif yang akan dibangun. Kualitas pencatatan pada sistem pemantauan lingkungan kerap menghadapi tantangan teknis, seperti malfungsi sensor atau kegagalan transmisi, yang mengakibatkan adanya nilai hilang (*missing values*). Berdasarkan pengamatan terhadap dataset ISPU DKI Jakarta, ditemukan variasi kelengkapan pencatatan antar parameter polutan yang diukur.

Parameter $PM_{2.5}$ menunjukkan rasio data hilang yang tinggi, yakni mencapai 73% dari total observasi. Dalam standar pemodelan deret waktu, tingkat data hilang yang melampaui ambang batas 50% dinilai kurang layak untuk diproses lebih lanjut sebagai target utama. Hal ini dikarenakan pengisian data (*imputation*) pada skala tersebut

dapat menimbulkan bias sistemik, sehingga model kehilangan kemampuan untuk menangkap varians alami dari fenomena pencemaran yang terjadi di lapangan.

Sebaliknya, parameter PM_{10} menunjukkan tingkat kelengkapan data yang tinggi, yaitu dengan persentase kelengkapan mencapai 94%. Kondisi data yang kontinu ini memungkinkan penerapan algoritma *machine learning* tanpa risiko kehilangan informasi temporal dalam jumlah besar secara kronologis. Oleh karena itu, PM_{10} ditetapkan sebagai target peramalan utama dalam penelitian ini, sedangkan polutan lainnya yang memiliki integritas cukup diposisikan sebagai fitur input multivariat.



Gambar III.2 Analisis persentase data hilang (*missing values*) pada parameter polutan utama DKI Jakarta (2010–2025)

III.2.2 Statistik Deskriptif Global per Stasiun

Untuk memahami profil distribusi beban polusi di wilayah Jakarta secara menyeluruh, dilakukan kalkulasi metrik statistik deskriptif pada kelima stasiun pemantauan utama. Perhitungan ini mencakup nilai rata-rata (*mean*) untuk menganalisis level polusi harian, standar deviasi (*std*) untuk mengukur volatilitas, serta nilai minimum (*min*) dan maksimum (*max*). Ringkasan statistik ini memberikan gambaran kuantitatif awal mengenai variasi polusi udara di lokasi yang berbeda.

Berdasarkan data yang dirangkum pada Tabel III.1, terlihat bahwa setiap stasiun memiliki karakteristik distribusi yang bervariasi. Stasiun DKI4 mencatat nilai rata-rata konsentrasi tertinggi dan nilai maksimum tertinggi dibandingkan lokasi lainnya. Perbedaan metrik ini menunjukkan bahwa beban polutan partikulat di Jakarta tidak tersebar secara merata, melainkan memiliki pemusatan pada wilayah-wilayah tertentu yang memiliki kepadatan aktivitas atau kondisi geografis khusus.

Analisis terhadap nilai standar deviasi juga menunjukkan tingkat volatilitas di stasiun DKI2 dan DKI4, yang menandakan bahwa wilayah tersebut kerap mengalami fluktuasi konsentrasi secara mendadak. Kondisi ini mengindikasikan adanya penga-

ruh pola aktivitas spasial dan mikroklimat lokal bervariasi secara statistik di setiap wilayah administratif Jakarta. Ringkasan lengkap statistik deskriptif untuk parameter PM_{10} disajikan pada tabel berikut.

Tabel III.1 Ringkasan Statistik Deskriptif Konsentrasi PM_{10} pada Lima SPKUA DKI Jakarta

Stasiun	Count	Mean	Std	Min	Median	Max
DKI1 (Bunderan HI)	5480	48.21	18.34	5.00	46.00	165.00
DKI2 (Kelapa Gading)	5412	54.12	21.05	7.00	52.00	189.00
DKI3 (Jagakarsa)	5445	42.15	16.22	4.00	40.00	142.00
DKI4 (Lubang Buaya)	5398	56.78	22.14	8.00	55.00	201.00
DKI5 (Kebon Jeruk)	5405	51.44	19.87	6.00	49.00	178.00

III.2.3 Karakteristik Spasial-Temporal per Stasiun Pemantauan

Subbab ini menganalisis tren historis jangka panjang selama 15 tahun secara harian untuk setiap stasiun pemantauan. Analisis temporal secara spesifik diperlukan karena karakteristik emisi di setiap wilayah Jakarta dipengaruhi oleh faktor-faktor yang bervariasi, mulai dari volume lalu lintas hingga tutupan lahan. Dengan menganalisis data per stasiun, tantangan yang dihadapi oleh model prediktif pada setiap lokasi dapat diidentifikasi secara lebih presisi.

Eksplorasi terhadap deret waktu konsentrasi harian menunjukkan adanya fluktuasi yang dipengaruhi oleh pola aktivitas harian manusia. Pola seperti hari kerja (*weekdays*) dan hari libur (*weekend*) memengaruhi konsentrasi partikulat di atmosfer. Selain itu, pengaruh jangka panjang seperti perubahan infrastruktur kota juga memberikan dampak pada tren stabilisasi atau kenaikan nilai polutan di setiap titik.

Visualisasi tren pada masing-masing stasiun membantu dalam memvalidasi karakteristik perilaku polusi yang tidak tertangkap oleh statistik global. Hal ini menunjukkan perlunya penggunaan model yang sensitif terhadap konteks lokal, di mana satu set hiperparameter model kemungkinan kurang sesuai untuk seluruh lokasi. Analisis karakteristik harian dari stasiun DKI1 hingga DKI5 dipaparkan pada bagian berikut.


III.2.3.1 Stasiun DKI1 (Bunderan HI)

Stasiun DKI1 terletak di pusat aktivitas bisnis dan komersial Jakarta, yakni kawasan Bunderan Hotel Indonesia. Sebagai wilayah pusat pertumbuhan ekonomi, lokasi ini dipengaruhi oleh pergerakan kendaraan bermotor komuter yang padat. Konsentrasi PM_{10} di stasiun ini mencerminkan fluktuasi aktivitas transportasi dan mobilitas publik di pusat perkotaan.

Berdasarkan pengamatan pada Gambar III.3, konsentrasi harian menunjukkan fluk-

tuasi dengan volatilitas yang moderat. Pola emisi kendaraan komuter teridentifikasi melalui nilai konsentrasi tertinggi yang terjadi pada hari kerja dibandingkan dengan hari libur. Meskipun demikian, tren jangka panjang menunjukkan adanya periode stabil yang mencerminkan area bisnis yang telah stabil secara pembangunan infrastruktur.

Namun, stasiun ini tetap menunjukkan adanya lonjakan temporer. Kondisi ini terjadi pada masa pembangunan konstruksi infrastruktur transportasi massal atau proyek renovasi gedung di sekitar koridor Sudirman-Thamrin. Karakteristik ini memerlukan perhatian model untuk membedakan antara variasi musiman normal dengan anomali akibat aktivitas konstruksi lokal yang bersifat sementara namun berdampak pada fluktuasi nilai kualitas udara.



Gambar III.3 Tren historis konsentrasi harian PM_{10} di Stasiun DKI1 (Bunderan HI)


III.2.3.2 Stasiun DKI2 (Kelapa Gading)

Berlokasi di wilayah Jakarta Utara, stasiun DKI2 dipengaruhi oleh karakteristik pesisir dan kedekatan dengan kawasan logistik. Selain aktivitas permukiman, wilayah ini merupakan jalur distribusi barang yang dilalui oleh kendaraan berat. Keberadaan aktivitas industri ringan di sekitar wilayah ini juga berkontribusi terhadap beban polutan partikulat harian yang tercatat di stasiun.

Pengamatan visual memperlihatkan adanya volatilitas yang tinggi dibandingkan stasiun di pusat kota. Faktor kecepatan angin laut berkontribusi terhadap proses dispersi partikulat di wilayah ini, di mana angin yang kuat membantu mempercepat peluruhan polusi, namun sebaliknya, kondisi udara tenang dapat menahan akumulasi polutan di permukaan. Dinamika ini menyebabkan data PM_{10} di DKI2 memiliki fluktuasi mendadak (*shocks*) yang kerap terjadi.

Ketidakteraturan pola ini menjadi dasar pertimbangan penggunaan fitur meteorologi yang relevan dalam arsitektur model prediksi. Tanpa mempertimbangkan faktor eksternal seperti arah dan kecepatan angin, model mengalami keterbatasan dalam menangkap perubahan pada konsentrasi polusi di kawasan pesisir ini. Analisis di stasiun DKI2 menunjukkan pentingnya pemodelan yang mengintegrasikan penga-


ruh lingkungan secara multivariat.



Gambar III.4 Tren historis konsentrasi harian PM_{10} di Stasiun DKI2 (Kelapa Gading)

III.2.3.3 Stasiun DKI3 (Jagakarsa)

Stasiun DKI3 yang berlokasi di Jakarta Selatan mewakili wilayah dengan tutupan lahan hijau yang relatif lebih luas dibandingkan wilayah administratif lainnya di Jakarta. Karakteristik wilayah ini didominasi oleh permukiman rendah dan area serapan air. Oleh karena itu, profil kualitas udara di Jagakarsa menunjukkan nilai rata-rata konsentrasi polutan yang relatif rendah dalam lingkup pengamatan metropolitan Jakarta. Karakteristik sebaran dan fluktuasi data historis parameter PM_{10} pada lokasi ini disajikan secara visual pada Gambar III.5.



Gambar III.5 Tren Historis Konsentrasi Harian PM_{10} di Stasiun DKI3 (Jagakarsa)


Visualisasi pada Gambar III.5 memperlihatkan bahwa stasiun ini memiliki profil polusi yang moderat dengan nilai puncak yang tidak setinggi kawasan utara atau pusat kota. Meskipun pola fluktuasi musiman tetap teramati mengikuti siklus tahunan, frekuensi lonjakan konsentrasi harian tidak sekerap stasiun pemantau yang berada di kawasan industri atau pusat bisnis. Sifat sebaran data yang cenderung lebih stabil ini menjadikan stasiun DKI3 dapat difungsikan sebagai titik acuan dasar (*baseline*) untuk membandingkan karakteristik pola polusi secara spasial antarwilayah administratif.

Karakteristik data dengan varians yang lebih kecil (*smooth*) di stasiun ini memberikan tantangan tersendiri bagi pemodelan prediktif. Konfigurasi model perlu disesuaikan agar tidak terlalu reaktif terhadap fluktuasi jangka pendek yang kecil guna meminimalkan risiko terjadinya kondisi pembelajaran berlebih (*overfitting*), namun

tetap memiliki sensitivitas untuk mendeteksi tren perubahan nilai secara perlahan yang terjadi akibat pertambahan volume aktivitas domestik lokal. Oleh karena itu, fokus pemodelan di stasiun ini diarahkan pada kemampuan algoritma dalam mengenali kecenderungan tren jangka menengah secara konsisten dibandingkan dengan deteksi fluktuasi sesaat.

III.2.3.4 Stasiun DKI4 (Lubang Buaya)

Stasiun DKI4 merepresentasikan karakteristik wilayah permukiman penduduk di sisi Timur Jakarta. Selain aktivitas domestik, wilayah ini juga dipengaruhi oleh pergerakan massa udara dari kawasan industri di daerah penyangga Jakarta. Kombinasi antara karakteristik hunian dan pola angin lokal tersebut memicu penumpukan massa partikulat PM_{10} yang tertahan di lapisan atmosfer bawah. Karakteristik sebaran dan fluktuasi data historis polutan pada lokasi ini disajikan secara visual pada Gambar III.6.




Gambar III.6 Tren Historis Konsentrasi Harian PM_{10} di Stasiun DKI4 (Lubang Buaya)

Visualisasi pada Gambar III.6 memperlihatkan adanya pola persistensi polutan yang tampak jelas di stasiun ini. Nilai konsentrasi berada pada level sedang hingga tinggi dalam rentang waktu tertentu sebelum akhirnya mengalami peluruhan secara bertahap. Fenomena ini mengindikasikan bahwa terdapat ketergantungan temporal pada data historis di lokasi Lubang Buaya, di mana nilai pada hari ini dipengaruhi oleh kondisi beberapa hari sebelumnya.

Karakteristik persistensi tersebut menjadi dasar pertimbangan untuk mengintegrasikan komponen ARIMA dalam arsitektur model hibrida. Kemampuan algoritma statistika dalam menangkap pola autokorelasi linier dinilai sesuai untuk memetakan perilaku polusi di wilayah DKI4. Dengan demikian, kerangka pemodelan hibrida dikonfigurasi untuk memanfaatkan metode statistik konvensional dalam menangkap komponen linier, serta algoritma pembelajaran mesin untuk memetakan pola non-linier lainnya.

III.2.3.5 Stasiun DKI5 (Kebon Jeruk)

Terletak di sisi Barat Jakarta, stasiun DKI5 mencatat dinamika kualitas udara dari kawasan permukiman yang berbatasan dengan koridor transportasi utama antarkota. Lokasi ini dipengaruhi oleh arus lalu lintas harian dari arah daerah penyangga menuju pusat Jakarta, khususnya melalui akses jalan tol. Faktor ini membentuk profil emisi yang bervariasi terhadap volume kendaraan pada jam sibuk komuter harian. Karakteristik sebaran data konsentrasi historis parameter PM_{10} pada lokasi ini disajikan secara visual pada Gambar III.7.



Gambar III.7 Tren Historis Konsentrasi Harian PM_{10} di Stasiun DKI5 (Kebon Jeruk)

Visualisasi pada Gambar III.7 menunjukkan profil PM_{10} yang secara umum memiliki kemiripan pola persistensi dengan stasiun DKI4, namun disertai dengan fluktuasi puncak yang tajam. Pola ini mencerminkan adanya akumulasi polutan dari kawasan permukiman sekaligus kontribusi emisi langsung dari kendaraan bermotor yang melintasi koridor utama. Dinamika tersebut menyebabkan data di stasiun DKI5 memiliki struktur berupa gabungan antara komponen linier jangka panjang dan lonjakan non-linier harian.

Sifat data yang bervariasi ini memperkuat pertimbangan dilakukannya analisis secara terpisah per stasiun dalam membangun konfigurasi model prediksi. Meskipun terdapat kemiripan tren umum antar beberapa lokasi, setiap stasiun tetap menyimpan karakteristik tersendiri yang berbeda secara amplitudo dan frekuensi fluktuasi. Oleh karena itu, strategi pelatihan model yang diusulkan diarahkan untuk memastikan setiap stasiun diproses secara mandiri sesuai dengan dinamika lokal masing-masing.

III.2.4 Analisis Heterogenitas Spasial Melalui Uji Statistik

Profil data yang telah dipaparkan sebelumnya secara visual menunjukkan adanya perbedaan karakteristik polutan antar stasiun pemantauan. Namun, bukti visual memerlukan validasi uji statistik formal untuk memastikan apakah perbedaan konsentrasi PM_{10} antar wilayah administratif Jakarta tersebut terbukti secara statistik atau terjadi karena faktor kebetulan.

Meningat dataset konsentrasi polutan tidak berdistribusi normal (memiliki kemiringan atau *skewness* tertentu), maka digunakan uji statistik non-parametrik Kruskal-Wallis. Uji ini dipilih karena kemampuannya untuk membandingkan lebih dari dua kelompok independen tanpa memerlukan asumsi normalitas data. Hasil dari pengujian ini menjadi penentu apakah model prediksi dapat dibuat secara generalisasi atau harus bersifat spesifik lokasi.

Berdasarkan eksekusi uji Kruskal-Wallis, dihasilkan (*p-value*) yang lebih kecil dari ambang batas 0.05. Temuan ini memberikan justifikasi bahwa distribusi konsentrasi PM_{10} pada kelima stasiun pemantauan di DKI Jakarta adalah tidak identik. Konsekuensi dari temuan ini menetapkan bahwa proses pelatihan model tidak dilakukan secara global, lupakan dilatih secara terpisah per stasiun guna menangkap sensitivitas iklim lokal yang spesifik.


III.2.5 Analisis Autokorelasi dan Musiman

Eksplorasi terhadap data deret waktu PM_{10} mengonfirmasi adanya ketergantungan temporal melalui analisis *Autocorrelation Function* (ACF) dan *Partial Autocorrelation Function* (PACF). Plot ACF menunjukkan adanya peluruhan eksponensial pada lag-lag awal, yang memberikan bukti empiris mengenai keberadaan sifat otoregresif dalam data. Informasi ini menjadi dasar penggunaan komponen AR dalam kerangka kerja model hibrida RF-ARIMA.

Selain ketergantungan temporal jangka pendek, data polusi di Jakarta juga dipengaruhi oleh faktor meteorologis yang bersifat musiman. Terdapat pola penurunan konsentrasi pada periode Januari hingga Februari akibat proses peluruhan akibat air hujan (*washout effect*) oleh presipitasi curah hujan. Sebaliknya, fenomena inversi termal pada puncak musim kemarau di bulan Juli hingga Agustus menahan partikulat di dekat permukaan tanah, sehingga memengaruhi kenaikan konsentrasi polutan.

Kombinasi antara sifat autokorelasi harian dan tren musiman tahunan ini memerlukan strategi *feature engineering* yang mampu menangkap kedua dimensi tersebut. Penambahan fitur berbasis waktu seperti bulan dan musim, serta fitur *lag* untuk me-

nangkap dependensi temporal, digunakan dalam perancangan model. Dengan demikian, model hibrida yang dikembangkan memiliki kemampuan untuk melakukan estimasi yang adaptif terhadap perubahan kondisi cuaca musiman di Jakarta.



Gambar III.8 Plot ACF dan PACF konsentrasi PM_{10} Jakarta untuk identifikasi pola autokorelasi temporal

III.3 Analisis Domain: Kausalitas dan Dinamika Polutan


Pemodelan *machine learning* yang tidak mempertimbangkan prinsip fisika atmosferik berisiko menghasilkan regresi spurious atau korelasi semu. Oleh karenanya, dilakukan dekomposisi terhadap mekanisme kausalitas kimiawi dan dinamika temporal antarpolutan sebagai dasar pembentukan arsitektur hibrida dan strategi rekayasa fitur. Analisis domain ini digunakan untuk memastikan bahwa variabel-variabel yang dimasukkan ke dalam model memiliki landasan ilmiah yang sesuai dengan fenomena dispersi dan reaksi kimia udara di wilayah urban.

Integrasi antara pengetahuan domain atmosferik dengan algoritma prediktif bertujuan untuk mempermudah interpretabilitas model. Melalui pemahaman mengenai kontribusi polutan prekursor terhadap pembentukan partikulat, proses ekstraksi fitur tidak lagi dilakukan secara acak, melainkan berbasis pada fenomena fisik. Pendekatan ini dilakukan dalam penelitian ini guna menghubungkan antara akurasi komputasional dengan validitas saintifik.

Hasil analisis pada bagian ini memberikan justifikasi teknis mengenai alasan fitur tertentu, seperti interaksi polutan dan fitur waktu tunda (*lag*), menjadi komponen dalam model hibrida RF-ARIMA. Pemahaman mengenai siklus harian dan musiman polutan di Jakarta digunakan sebagai dasar untuk meminimalkan nilai galat prediksi pada kondisi ekstrem. Penjelasan mengenai korelasi lintas waktu dan mekanisme kimiawi polutan dipaparkan pada sub-bab berikut.

III.3.1 Analisis Kausalitas Lintas Waktu (*Cross-Correlation Analysis*)

Analisis korelasi silang atau *Cross-Correlation Function* (CCF) dieksekusi untuk menguji adanya ketergantungan temporal antarparameter polutan secara empiris. Analisis ini bertujuan mengukur hubungan antara konsentrasi PM₁₀ pada waktu t dengan berbagai polutan prekursor pada rentang waktu lampau ($t - k$). Melalui identifikasi jendela waktu tunda di mana pengaruh polutan lain terdeteksi terhadap PM₁₀, spesifikasi jendela waktu untuk *lag features* dapat ditentukan. Hasil komputasi dari analisis CCF untuk jendela waktu 7 hari ke belakang divisualisasikan pada Gambar III.9.



Gambar III.9 Analisis Korelasi Silang (CCF) antara PM₁₀ dengan polutan prekursor pada Lag 0–7 hari


Berdasarkan observasi pada visualisasi di atas, diperoleh temuan utama mengenai persistensi emisi primer seperti Karbon Monoksida (CO) dan Nitrogen Dioksida (NO₂). Korelasi antara PM₁₀ dengan kedua polutan tersebut menunjukkan nilai koefisien yang konstan pada Lag 0 ($r > 0,5$), dan terbukti secara statistik hingga rentang Lag 2. Fenomena ini mengindikasikan bahwa emisi kendaraan bermotor yang dilepaskan tidak langsung terdispersi sepenuhnya dari atmosfer Jakarta. Kondisi tersebut dipengaruhi oleh karakteristik lapisan batas planet (*planetary boundary layer*) di wilayah metropolitan yang stabil, sehingga memengaruhi akumulasi massa partikulat dalam rentang waktu beberapa hari.

Selain karakteristik emisi primer, dinamika Ozon Permukaan (O₃) menunjukkan pola peluruhan korelasi pada rentang Lag 7. Temuan ini mengindikasikan bahwa

variasi konsentrasi PM_{10} memiliki keterikatan dengan siklus fotokimia mingguan. Perubahan koefisien korelasi yang bertahan pada Lag 1 hingga Lag 3 pada parameter polutan memberikan justifikasi teoretis terhadap penggunaan fitur *lag* dan *rolling window* dalam model. Tanpa menyertakan informasi historis polutan pendukung, estimasi model tidak mengasimilasi konteks akumulasi massa partikulat di atmosfer yang bersifat persisten.

III.3.2 Mekanisme Fisik dan Kimia Pembentukan Partikulat Sekunder

Konsentrasi PM_{10} di kawasan perkotaan seperti Jakarta tidak hanya berasal dari emisi primer langsung seperti debu jalan raya dan sisa pembakaran kendaraan, tetapi juga dipengaruhi oleh pembentukan partikulat sekunder hasil reaksi kimia gas di atmosfer yang melibatkan interaksi antar-gas prekursor. Pemahaman terhadap hubungan antar-polutan gas ini menjadi landasan teoretis untuk melakukan tahapan rekayasa fitur, di mana fitur interaksi antar-prediktor digunakan untuk merepresentasikan kecenderungan pembentukan polutan sekunder dalam model. Struktur keterikatan linear secara global untuk seluruh parameter polutan udara independen di wilayah DKI Jakarta melalui perhitungan koefisien korelasi Pearson disajikan secara lengkap pada Gambar III.10.



Gambar III.10 Matriks Korelasi Pearson Antar Parameter Polutan Udara Jakarta

Berdasarkan matriks korelasi pada Gambar III.10, terlihat adanya pola keterikatan antara gas Karbon Monoksida (CO) dan Ozon Permukaan (O_3) yang merepresentasikan indikator aktivitas fotokimia di lapisan atmosfer bawah. Selain itu, variasi karakteristik spasial antar-stasiun, seperti wilayah pesisir-logistik DKI2 (Kelapa Gading) yang mencatat fluktuasi gas tertentu akibat aktivitas kendaraan berat, turut me-

mengaruhi sebaran partikulat secara lokal. Pengetahuan domain ini menunjukkan bahwa parameter polutan gas memiliki hubungan interaksi dan efek tunda terhadap konsentrasi PM_{10} , sehingga penambahan dimensi fitur komposit diperlukan untuk membantu proses pengenalan pola oleh algoritma hibrida.

III.4 Formalisasi Masalah Matematis

Estimasi nilai konsentrasi polutan PM_{10} dalam penelitian ini diformulasikan sebagai sebuah persoalan pemetaan fungsi non-linier yang menggunakan data multivariat historis sebagai variabel masukan. Secara matematis, jika diberikan sebuah deret waktu observasi polutan historis $X = \{x_1, x_2, \dots, x_t\}$, maka tujuan dari model prediktif adalah untuk mengestimasi nilai konsentrasi y_{t+1} pada periode satu hari ke depan. Representasi matematis dari hubungan fungsional antara observasi masa lalu dengan estimasi masa depan tersebut didefinisikan pada Persamaan III.1.

$$y_{t+1} = f(X_t, X_{t-1}, \dots, X_{t-p}) + \epsilon_t \quad (\text{III.1})$$

Dalam perumusan tersebut, variabel $f(\cdot)$ merepresentasikan fungsi transformasi regresi yang bersifat agregat, sementara p menunjukkan ordo jendela waktu lampau atau jeda temporal yang digunakan untuk menangkap karakteristik dependensi temporal dari data deret waktu. Komponen ϵ_t didefinisikan sebagai sisaan acak yang tidak dapat dipetakan secara deterministik oleh model.

Pendekatan ini didasarkan pada asumsi bahwa data kualitas udara mengandung pola-pola yang dapat diurai berdasarkan karakteristik statistiknya melalui teorema dekomposisi. Berdasarkan prinsip tersebut, fungsi pemetaan y_t dibagi menjadi dua komponen terpisah sebagaimana dinyatakan pada Persamaan III.2.

$$y_t = L_t + N_t \quad (\text{III.2})$$

Komponen L_t pada Persamaan III.2 merepresentasikan fungsi linier yang memiliki sifat autokorelasi, di mana komponen ini dimodelkan menggunakan persamaan diferensi stokastik ARIMA. Sementara itu, komponen N_t mewakili fungsi non-linier—seperti pengaruh interaksi antarpolutan dan variasi meteorologi—yang dipetakan secara non-parametrik melalui struktur ensambel pohon keputusan *Random Forest*.

Penggabungan kedua komponen ini secara hibrida ditujukan untuk meminimalkan keterbatasan model regresi tunggal yang memiliki batasan dalam memproses karakteristik data yang bervariasi, sehingga diharapkan dapat mengurangi nilai galat estimasi terhadap dinamika atmosfer Jakarta yang fluktuatif.

III.5 Desain Ekstraksi Fitur Deret Waktu (*Feature Engineering*)

Berdasarkan hasil analisis karakteristik data spasial dan kausalitas domain atmosferik pada subbab sebelumnya, rancangan spesifikasi fitur disusun secara sistematis. Proses rekayasa fitur (*feature engineering*) ini berfungsi untuk mengekstraksi informasi prediktif yang terdapat di dalam deret waktu mentah agar dapat diproses oleh model komputasi. Tanpa adanya transformasi fitur yang memadai, model *machine learning* memiliki keterbatasan dalam memetakan pola karakteristik pada data lingkungan yang memiliki derau (*noise*).

Dalam penelitian ini, dirancang spesifikasi ekstraksi untuk menghasilkan 15 fitur komputasional yang dimasukkan ke dalam arsitektur model hibrida. Ekstraksi fitur ini bertujuan untuk menyediakan representasi variabel yang bervariasi secara multivariat. Komponen yang diekstrak mencakup aspek dependensi temporal, distribusi statistik lokal, interaksi kimiawi antarpolutan, serta pola waktu deterministik yang berulang secara periodik.

Secara matematis, proses rekayasa fitur ini dideskripsikan ke dalam empat kategori utama. Setiap kategori memiliki fungsi dalam memetakan fenomena fisik atmosfer ke dalam variabel numerik yang dapat dikomputasi. Deskripsi, justifikasi fisis, dan formulasi matematis dari masing-masing kategori fitur diuraikan pada sub-bagian berikut.

III.5.1 Fitur Jeda Temporal (*Lag Features*)

Ekstraksi fitur jeda temporal atau *lag features* digunakan untuk menangkap efek persistensi dari polutan di atmosfer. Di wilayah urban seperti DKI Jakarta, laju disipasi emisi kendaraan bermotor maupun debu jalanan membutuhkan waktu untuk terurai atau terdispersi oleh angin. Kondisi ini menyebabkan konsentrasi PM_{10} pada rentang waktu saat ini dipengaruhi oleh akumulasi massa partikulat dari hari-hari sebelumnya.

Berdasarkan analisis fungsi autokorelasi (ACF) yang dieksekusi pada tahap *data profiling*, rentang batas jeda waktu ditentukan hingga tujuh hari ke belakang ($t - 7$). Rentang waktu ini dinilai merepresentasikan peluruhan dari polutan primer sebelum akhirnya kehilangan nilai keterikatan statistik. Penggunaan fitur jeda yang terlalu

panjang memerlukan pertimbangan agar tidak menambah nilai kesalahan (*noise*) yang dapat memengaruhi hasil estimasi prediksi.

Proses ekstraksi ini memetakan nilai historis masa lalu menjadi fitur prediktor independen pada matriks pelatihan. Fitur yang diekstraksi meliputi konsentrasi polutan pada satu hari sebelumnya ($PM10_{t-1}$) hingga tujuh hari sebelumnya ($PM10_{t-7}$). Formulasi matematis dari pembentukan *lag features* ditunjukkan pada Persamaan III.3.

$$L_k = X_{t-k}, \quad \text{untuk } k \in \{1, 2, \dots, 7\} \quad (\text{III.3})$$

III.5.2 Fitur Statistik Jendela Berjalan (*Rolling Window Statistics*)

Kondisi kualitas udara di Jakarta dipengaruhi oleh siklus aktivitas harian masyarakat yang berulang setiap minggunya. Untuk merepresentasikan pola pergerakan tersebut, digunakan teknik ekstraksi fitur berbasis jendela observasi berjalan (*rolling window*) dengan rentang waktu 3-hari ($W = 3$) dan 7-hari ($W = 7$) untuk menghitung metrik statistik lokal yang merangkum dinamika polusi jangka pendek dan menengah.

Metrik pertama yang diekstraksi adalah rata-rata bergerak (*Rolling Mean*) 3-hari ($pm10_ma3$) dan 7-hari ($pm10_ma7$), yang berfungsi untuk menghaluskan fluktuasi harian dan memberikan nilai dasar polusi berkala. Metrik kedua adalah standar deviasi berjalan (*Rolling Standard Deviation*) 7-hari ($pm10_std7$), yang bertindak sebagai proksi matematis untuk mendeteksi derajat volatilitas data atau adanya perubahan cuaca harian dalam periode satu minggu tersebut.

Kombinasi dari metrik statistik ini memungkinkan model *Random Forest* untuk memahami apakah data observasi harian berada dalam kondisi normal, sedang mengalami tren perubahan nilai, atau merupakan fluktuasi sesaat. Kalkulasi matematis untuk masing-masing fitur statistik jendela berjalan diturunkan pada Persamaan III.4, Persamaan III.5, dan Persamaan III.6.

$$RM_3 = \frac{1}{3} \sum_{i=1}^3 PM10_{t-i} \quad (\text{III.4})$$

$$RM_7 = \frac{1}{7} \sum_{i=1}^7 PM10_{t-i} \quad (III.5)$$

$$RStd_7 = \sqrt{\frac{1}{6} \sum_{i=1}^7 (PM10_{t-i} - RM_7)^2} \quad (III.6)$$

III.5.3 Fitur Interaksi Polutan dan Karakteristik Oksidasi

Berdasarkan analisis domain atmosfer, pembentukan partikulat sekunder dikatalisasi oleh keberadaan polutan pendukung lainnya. Algoritma *machine learning* konvensional mengasumsikan setiap fitur input bersifat independen, sehingga interaksi antarvariabel secara statistik kerap tidak tertangkap secara langsung. Oleh karenanya, model ditambahkan fitur interaksi perkalian guna merepresentasikan laju reaksi polutan tersebut.

Fitur interaksi dibangun dengan menghitung hasil kali konsentrasi Karbon Monoksida (CO) dan Ozon Permukaan (O₃) untuk memodelkan indikator oksidasi fotokimia (co_times_o3). Karbon Monoksida bertindak sebagai indikator emisi primer kendaraan, sedangkan Ozon merupakan penanda derajat transisi cuaca panas.

Melalui penyusunan fitur interaksi perkalian ini, model *Random Forest* dapat mengidentifikasi kondisi pembentukan polutan sekunder secara lebih efisien tanpa memerlukan kedalaman percabangan pohon keputusan yang tinggi. Formulasi matematis dari fitur interaksi dideskripsikan pada Persamaan III.7.

$$Int(CO, O_3) = CO_t \times O_{3,t} \quad (III.7)$$

III.5.4 Fitur Temporal dan Siklus Aktivitas

Komponen waktu seperti tanggal tidak diproses secara langsung oleh algoritma regresi karena sifatnya yang berupa deret numerik kontinu. Oleh sebab itu, komponen waktu ditransformasi menjadi dimensi spasial diskrit guna menangkap tren perulangan aktivitas masyarakat dan variasi musiman harian. Ekstraksi fitur waktu ini digunakan untuk menyediakan informasi penanggalan kepada model.

Fitur pertama yang dibentuk adalah indeks hari dalam satu minggu (*Day of Week*), yang dikalkulasi menggunakan operasi modulo pada indeks hari berurutan. Transformasi ini bertujuan agar model memetakan urutan hari kerja yang menunjukkan karakteristik volume kendaraan yang stabil. Selain itu, fitur kategorikal biner *is_weekend* juga ditambahkan untuk menandai hari Sabtu dan Minggu secara eksklusif.

Penggunaan fitur biner *is_weekend* dirancang untuk merepresentasikan penurunan nilai fluktuasi volume kendaraan komuter lintas daerah ke pusat perkotaan, yang memengaruhi penurunan pola polutan di akhir pekan. Representasi matematis untuk transformasi indeks hari menjadi ruang vektor diskrit ditunjukkan pada Persamaan III.8.

$$\text{DayOfWeek}_t = t \pmod{7} \quad (\text{III.8})$$

III.6 Analisis Kebutuhan Sistem

Analisis kebutuhan sistem merupakan tahapan penting dalam siklus pengembangan sistem prediktif yang bertujuan untuk mendefinisikan batasan, kapabilitas, dan ekspektasi performa dari artefak yang akan dibangun. Proses ini dilakukan untuk memastikan bahwa solusi teknis yang diusulkan, yakni model hibrida RF-ARIMA, selaras dengan urgensi pemecahan masalah polusi udara di DKI Jakarta. Melalui identifikasi kebutuhan secara mendalam, seluruh fungsi sistem dapat dirancang secara terukur untuk meminimalkan kendala latensi informasi dan keterbatasan transparansi model yang telah diidentifikasi pada tahapan sebelumnya.

III.6.1 Identifikasi Masalah Pengguna dan Pemetaan Regulasi

Perancangan model prediktif ini diselaraskan dengan kepatuhan terhadap standar regulasi nasional yang berlaku di Indonesia, khususnya Peraturan Menteri Lingkungan Hidup dan Kehutanan (Permen LHK) Nomor 14 Tahun 2020 tentang Indeks Standar Pencemar Udara. Regulasi tersebut menjadi acuan dasar dalam menentukan parameter polutan harian dan ambang batas konsentrasi guna menjaga keselarasan hukum serta teknis dari luaran model. Selain aspek regulasi, kebutuhan fungsional dari otoritas pengambil kebijakan terkait juga menjadi faktor pendorong di mana instansi memerlukan alat bantu yang memproses data historis sekaligus memberikan estimasi kondisi kualitas udara untuk periode mendatang. Ketersediaan informasi penaksiran nilai ini didesain agar pihak berwenang dapat mempertimbangkan lang-

kah preventif, seperti pengelolaan mobilitas kendaraan atau penyampaian panduan kesehatan, sebelum konsentrasi polutan berada pada tingkat yang dapat memengaruhi kesehatan masyarakat.

Sintesis antara analisis masalah pengguna dan pemetaan regulasi tersebut menghasilkan tiga kategori kebutuhan operasional yang mendasari pengembangan konfigurasi model hibrida ini. Kategori pertama adalah kebutuhan estimasi harian yang proaktif sebagai fungsi informasi dini terhadap fluktuasi polutan harian untuk horizon waktu satu hari ke depan ($t + 1$). Kategori kedua berfokus pada aspek transparansi model, di mana kerangka kerja menyediakan kejelasan mengenai distribusi kontribusi fitur masukan untuk membantu proses penelaahan dasar keputusan model secara objektif. Kategori terakhir adalah fleksibilitas spasial yang memerlukan penyesuaian parameter model agar adaptif terhadap karakteristik iklim mikro yang bervariasi pada masing-masing stasiun pemantauan di wilayah DKI Jakarta.

III.6.2 Kebutuhan Fungsional

Kebutuhan fungsional menetapkan kapabilitas teknis dan operasional yang harus dimiliki oleh sistem untuk mencapai tujuan estimasi konsentrasi polutan PM_{10} . Fokus utama dari parameter fungsional ini meliputi pengelolaan alur data secara terintegrasi, mulai dari tahap penarikan berkas data historis hingga penaksiran nilai melalui modul komputasi hibrida sekuensial. Modul pemrosesan dirancang untuk mengeksekusi rangkaian logika transformasi prediktor secara bertahap guna menghasilkan nilai luaran berupa proyeksi tingkat polusi untuk satu hari ke depan ($t + 1$). Rincian mengenai deskripsi kebutuhan fungsional sistem ini dijabarkan secara sistematis pada Tabel III.2.

Selain aspek pemodelan utama, sistem memfasilitasi fungsionalitas pendukung untuk penjaminan kualitas data (*data quality assurance*). Aturan fungsional ini mencakup proses pembersihan data dari nilai ekstrem serta penanganan terhadap data hilang (*missing values*) yang kerap terjadi pada perangkat sensor pemantau di lapangan. Integrasi modul rekayasa fitur juga menjadi bagian inti agar fungsi komputasi dapat mengekstrak variabel jeda temporal dan interaksi kimiawi antarpolutan yang telah dirancang sebelumnya.

Aspek lain dari kebutuhan fungsional adalah penyediaan mekanisme evaluasi dan interpretasi model secara otomatis setelah proses pelatihan selesai. Modul prediktif tidak hanya mengeluarkan nilai taksiran numerik, tetapi juga menghitung metrik kesalahan statistik untuk memvalidasi performa hasil peramalan secara periodik. Lebih lanjut, keberadaan modul *Explainable Artificial Intelligence* (XAI) menjadi

fungsi pelengkap untuk menguraikan kontribusi dan pengaruh dari masing-masing fitur masukan terhadap pembentukan nilai prediksi akhir.

Tabel III.2 Kebutuhan Fungsional Sistem Pemodelan PM_{10}

No.	Kode	Deskripsi Kebutuhan Fungsional
1	F-01	Memprediksi nilai konsentrasi harian PM_{10} di wilayah DKI Jakarta menggunakan basis data deret waktu historis.
2	F-02	Mengeksekusi peramalan melalui implementasi arsitektur hibrida sekuensial menggabungkan <i>Random Forest</i> (RF) dan ARIMA.
3	F-03	Mentransformasi data mentah menjadi 15 fitur komputasional melalui tahapan rekayasa fitur (<i>feature engineering</i>).
4	F-04	Menghitung metrik evaluasi performa regresi secara otomatis, meliputi nilai RMSE, MAE, dan Koefisien Determinasi (R^2).
5	F-05	Mengintegrasikan modul <i>Explainable AI</i> (XAI) untuk menghitung dan memvisualisasikan kontribusi fitur menggunakan nilai SHAP.
6	F-06	Memfasilitasi fungsi pembersihan data (<i>data cleaning</i>) untuk dataset kualitas udara berformat tabular periode 2010–2025.

III.6.3 Kebutuhan Nonfungsional

Kebutuhan nonfungsional menetapkan batasan operasional dan atribut kualitas yang menentukan derajat keandalan sistem saat seluruh modul dieksekusi. Atribut kualitas ini tidak berkaitan dengan penyediaan fitur spesifik, melainkan pada bagaimana seluruh elemen komputasi berperilaku di bawah batasan teknis lingkungan peladen harian. Fokus utama pada bagian ini meliputi performa batas nilai galat, ketangguhan konfigurasi model terhadap variansi data, serta efisiensi penggunaan alokasi memori perangkat keras saat menjalankan proses inferensi hibrida. Rincian deskripsi mengenai kebutuhan nonfungsional sistem disajikan pada Tabel III.3.

Salah satu parameter kualitas operasional yang ditargetkan adalah aspek akurasi relatif dan stabilitas estimasi model. Arsitektur hibrida sekuensial yang dikembangkan dikondisikan untuk menunjukkan nilai kesalahan (galat) penaksiran yang lebih rendah jika dibandingkan dengan performa model tunggal murni yang diposisikan sebagai acuan dasar (*baseline*). Selain itu, model menggunakan mekanisme validasi temporal guna meminimalkan risiko algoritma mengalami kondisi penyesuaian berlebih (*overfitting*) terhadap parameter data latih.

Aspek keterulangan (*reproducibility*) dan transparansi operasional juga menjadi karakteristik kualitas penting dalam perancangan tugas akhir ini. Seluruh siklus komputasi dirancang sedemikian rupa agar alur pemrosesan dari tahap prapemrosesan data hingga visualisasi taksiran akhir dapat direplikasi pada lingkungan eksekusi yang berbeda tanpa mengubah hasil luaran numerik. Hal ini dilakukan agar keandalan model hibrida yang dihasilkan dapat diuji validitas keilmuannya secara terbuka dan konsisten pada ekosistem pemrograman Python.

Tabel III.3 Kebutuhan Nonfungsional Sistem Pemodelan PM₁₀

No.	Kode	Deskripsi Kebutuhan Nonfungsional
1	NF-01	Akurasi Relatif: Menghasilkan nilai galat (RMSE) model hibrida yang lebih rendah dibandingkan model tunggal murni (<i>baseline</i>).
2	NF-02	Robustness: Meminimalkan risiko <i>overfitting</i> melalui implementasi <i>Time-Series Cross-Validation</i> berbasis <i>TimeSeriesSplit</i> 5-fold.
3	NF-03	Interpretabilitas: Mengeksekusi nilai atribusi fitur algoritma SHAP dalam batas memori peladen harian tanpa memicu kegagalan sistem.
4	NF-04	Reproduksibilitas: Menjamin seluruh siklus komputasi dari prapemrosesan hingga estimasi dapat direplikasi secara konsisten di lingkungan Python.

III.7 Analisis Pemilihan Paradigma Melalui *Analytical Hierarchy Process*

Pemilihan arsitektur pemodelan untuk estimasi kualitas udara memerlukan pertimbangan komprehensif yang tidak hanya mencakup aspek akurasi statistik, melainkan juga batasan operasional administratif instansi terkait. Metode *Analytical Hierarchy Process* (AHP) diterapkan pada tahapan ini sebagai kerangka kerja pengambilan keputusan terstruktur untuk mengevaluasi dan membandingkan beberapa alternatif solusi arsitektur pemodelan secara objektif. Melalui pendekatan hierarki ini, berbagai kriteria teknis maupun non-teknis disintesis secara sistematis guna menentukan paradigma solusi awal yang paling sesuai untuk diimplementasikan pada infrastruktur sistem informasi pemantauan lingkungan di DKI Jakarta.

III.7.1 Justifikasi Penggunaan AHP Sebelum Evaluasi Empiris

Sebuah catatan metodologis perlu dikemukakan terkait penggunaan *Analytical Hierarchy Process* (AHP) dalam penelitian tugas akhir berbasis sains data ini. Pada umumnya, pemilihan arsitektur model prediksi ditentukan murni secara empiris berdasarkan metrik kinerja kuantitatif (seperti nilai RMSE) setelah seluruh rangkaian eksperimen selesai dijalankan. Namun, dalam konteks implementasi sistem informasi pada instansi pemerintahan lokal seperti Dinas Lingkungan Hidup DKI Jakarta,

batasan operasional tidak hanya bergantung pada dimensi akurasi statistik semata. Terdapat parameter multi-kriteria non-teknis administratif yang harus dipenuhi, seperti tingkat transparansi keputusan (interpretabilitas) agar hasil prakiraan dapat ditelaah secara logis, efisiensi alokasi infrastruktur peladen harian, serta kemudahan replikasi kode operasional sistem.

Oleh karena itu, kerangka kerja AHP pada penelitian ini tidak diposisikan sebagai pengganti evaluasi kinerja empiris model akhir, melainkan sebagai instrumen analisis kebutuhan pra-eksperimen (*pre-development framework*) untuk menjustifikasi pemilihan paradigma arsitektur awal. Tahap evaluasi awal ini dilakukan dengan menyusun matriks perbandingan berpasangan (*pairwise comparison*) untuk lima kriteria operasional, yaitu Interpretabilitas (INT), Akurasi (AKR), Kemampuan Menangkap Pola Kompleks (PLK), Efisiensi Komputasi (KMP), dan Kemudahan Implementasi (IMP).

Dalam konteks penyediaan informasi kualitas udara harian, kriteria INT, AKR, dan PLK diberikan bobot kepentingan yang lebih tinggi, sedangkan kriteria KMP dan IMP diberikan bobot yang lebih rendah karena aktivitas peramalan diproses secara berkala (*batch processing*). Nilai kepentingan relatif antar-kriteria tersebut disajikan pada Tabel III.4.

Tabel III.4 Matriks Perbandingan Berpasangan Kriteria Utama

Kriteria	INT	AKR	PLK	KMP	IMP
Interpretabilitas (INT)	1,00	1,20	2,50	3,00	4,00
Akurasi (AKR)	0,83	1,00	2,00	3,00	3,00
Pola Kompleks (PLK)	0,40	0,50	1,00	2,00	2,00
Komputasi (KMP)	0,33	0,33	0,50	1,00	1,00
Implementasi (IMP)	0,25	0,33	0,50	1,00	1,00
Jumlah	2,81	3,36	6,50	10,00	11,00

Kalkulasi dilanjutkan dengan melakukan proses normalisasi matriks melalui pembagian setiap elemen baris dengan jumlah total nilai pada kolom bersesuaian. Vektor bobot prioritas global (*Eigenvector*) kemudian diperoleh melalui perhitungan nilai rata-rata baris dari matriks yang telah dinormalisasi. Nilai bobot prioritas global ini berfungsi sebagai parameter pengali untuk menentukan solusi paradigma arsitektur pemodelan yang dinilai memenuhi keselarasan kebutuhan administratif instansi, sebagaimana hasil perhitungan yang dirangkum pada Tabel III.5.

Tabel III.5 Matriks Normalisasi dan Perhitungan *Eigenvector* Kriteria

Kriteria	INT	AKR	PLK	KMP	IMP	Prioritas (<i>W</i>)
INT	0,356	0,357	0,385	0,300	0,364	0,352
AKR	0,295	0,298	0,308	0,300	0,273	0,295
PLK	0,142	0,149	0,154	0,200	0,182	0,165
KMP	0,117	0,098	0,077	0,100	0,091	0,097
IMP	0,089	0,098	0,077	0,100	0,091	0,091

III.7.2 Uji Konsistensi Matriks

Untuk menjamin bahwa penilaian hierarki beserta pembobotan bersifat logis secara matematis, dilakukan uji konsistensi matriks. Proses ini digunakan untuk meminimalkan risiko terjadinya rasio penilaian yang saling bertentangan. Langkah awal dalam pengujian ini adalah mengkalkulasi Nilai Eigen Maksimum (λ_{max}) yang di-representasikan melalui persamaan dot produk antara jumlah metrik kolom dengan vektor bobot prioritas sebagai berikut:

$$\lambda_{max} = (2,81 \times 0,352) + (3,36 \times 0,295) + \dots + (11,00 \times 0,091) = 5,165 \quad (\text{III.9})$$

Setelah diperoleh nilai eigen maksimum, langkah selanjutnya adalah menghitung *Consistency Index* (CI). Indeks ini mengukur seberapa jauh matriks evaluasi menyimpang dari kondisi konsisten, dengan mempertimbangkan jumlah dimensi kriteria ($n = 5$), yang diformulasikan melalui Persamaan III.10.

$$CI = \frac{\lambda_{max} - n}{n - 1} = \frac{5,165 - 5}{4} = 0,041 \quad (\text{III.10})$$

Langkah penutup dari validasi ini adalah komputasi batas penerimaan melalui formula *Consistency Ratio* (CR). Rasio ini membandingkan nilai CI terhadap sebuah indeks acak standar (*Random Index* atau *RI*) yang bernilai 1,12 untuk matriks berukuran 5×5 , sebagaimana ditunjukkan pada Persamaan III.11.

$$CR = \frac{CI}{RI} = \frac{0,041}{1,12} = 0,037 \quad (\text{III.11})$$

Berdasarkan hasil pembagian pada Persamaan III.11, diperoleh nilai batas sebesar 0,037 yang berada di bawah toleransi ketidaksesuaian maksimum sebesar 0,1. De-

ngan demikian, kerangka kriteria AHP dinyatakan valid untuk digunakan dalam menentukan bobot prioritas.

III.7.3 Penilaian Alternatif Berdasarkan Kriteria

Tahap evaluasi alternatif menguji secara komparatif kemampuan komputasional dari setiap arsitektur solusi terhadap masing-masing kriteria yang telah ditentukan batasan nilainya. Proses ini dilaksanakan dengan membentuk matriks perbandingan berpasangan lokal berskala 3x3 untuk menilai ketiga kandidat (ARIMA, *Random Forest*, dan Hibrida) secara terpisah. Tujuannya adalah untuk menganalisis karakteristik dari setiap algoritma secara mandiri.

Prosedur ini mengacu pada metodologi dekomposisi, di mana batasan dari satu arsitektur akan tercermin pada nilai prioritas lokal yang bersangkutan. Hal ini dilakukan agar analisis didasarkan pada pengukuran kriteria yang terstruktur.

Matriks komparasi beserta hasil kalkulasi bobot lokalnya dipaparkan pada masing-masing subbagian di bawah ini. Hasil dari komputasi penilaian individual ini selanjutnya diagregasi menjadi sebuah keputusan komprehensif pada akhir bagian metode *Analytical Hierarchy Process*.

III.7.3.1 Evaluasi Terhadap Interpretabilitas (INT)

Kriteria interpretabilitas mengutamakan kemampuan model prediktif untuk dapat dijelaskan secara fisis berdasarkan variabel masukan. Penilaian komparatif antar-solusi untuk kriteria interpretabilitas ini dikuantifikasi dalam matriks perbandingan berpasangan yang disajikan pada Tabel III.6.

Tabel III.6 Matriks Evaluasi Alternatif Terhadap Interpretabilitas (INT)

INT	ARIMA	RF	Hybrid	Bobot Lokal
ARIMA	1,00	4,00	4,00	0,667
RF	0,25	1,00	1,00	0,167
Hybrid	0,25	1,00	1,00	0,167

Berdasarkan nilai tersebut, model statistik linier ARIMA menghasilkan nilai lokal tertinggi (0,667) karena hubungannya dipetakan langsung melalui koefisien matematika yang transparan. Model *Random Forest* murni memiliki nilai rendah (0,167) karena karakteristiknya yang tertutup (*black-box*). Namun, pada model hibrida usulan, kelemahan sifat tertutup tersebut diatasi dengan mengintegrasikan modul analisis SHAP pada tahapan pascapelatihan. Intervensi ini memungkinkan model hibrida memberikan kejelasan kontribusi fitur, sehingga bobot lokal kriteria ini dapat diper-

tahankan untuk mendukung nilai prioritas global.

III.7.3.2 Evaluasi Terhadap Akurasi (AKR)

Kriteria akurasi mengukur kapasitas model dalam meminimalkan residu galat penaksiran terhadap data aktual konsentrasi PM_{10} . Penilaian matriks distribusi bobot akurasi disajikan pada Tabel III.7.

Tabel III.7 Matriks Evaluasi Alternatif Terhadap Akurasi (AKR)

AKR	ARIMA	RF	Hybrid	Bobot Lokal
ARIMA	1,00	0,33	0,20	0,105
RF	3,00	1,00	0,33	0,258
Hybrid	5,00	3,00	1,00	0,637

Model hibrida sekuensial memperoleh nilai tertinggi (0,637) karena menggabungkan kapasitas pengolahan data secara bertahap. Pola data non-linier dipetakan terlebih dahulu oleh komponen pembelajar primer, kemudian sisaan galatnya dikoreksi oleh fungsi deret waktu ARIMA pada tahap sekunder. Skema penggabungan ini menghasilkan nilai kesalahan peramalan yang lebih rendah dibandingkan model tunggal ARIMA murni (0,105) yang terbatas pada tren linier, maupun *Random Forest* murni (0,258) yang tidak mempertimbangkan autokorelasi residu.

III.7.3.3 Evaluasi Terhadap Pola Kompleks (PLK)

Kriteria pola kompleks menilai fleksibilitas arsitektur model dalam mengekstrak informasi dari rekayasa fitur multidimensi. Matriks perbandingan berpasangan lokal untuk kriteria pola kompleks dirangkum dalam Tabel III.8.

Tabel III.8 Matriks Evaluasi Alternatif Terhadap Pola Kompleks (PLK)

PLK	ARIMA	RF	Hybrid	Bobot Lokal
ARIMA	1,00	0,33	0,14	0,095
RF	3,00	1,00	0,50	0,327
Hybrid	7,00	2,00	1,00	0,578

Model hibrida berbasis rekayasa fitur menempati prioritas tertinggi (0,578) karena menggunakan matriks input komposit hasil modifikasi, seperti variabel interaksi gas polutan ($CO \times O_3$) yang merepresentasikan laju reaksi sekunder di atmosfer. Karakteristik ini memungkinkannya memetakan variabilitas data yang kompleks secara statistik dibandingkan dengan ARIMA murni (0,095) yang terbatas pada karakteristik univariat tunggal.

III.7.3.4 Evaluasi Terhadap Efisiensi Komputasi (KMP)

Kriteria Efisiensi Komputasi memetakan besaran alokasi konsumsi ruang memori operasional (RAM), waktu pemrosesan perangkat prosesor pusat (CPU), dan latensi inferensi saat arsitektur beroperasi secara sekuensial. Pemodelan dengan kebutuhan memori yang besar dapat memengaruhi waktu distribusi informasi pada saat volume eksekusi prapemrosesan meningkat. Pertimbangan waktu operasional diperlukan agar transisi data terkelola pada lingkungan peladen konvensional.

Dalam evaluasi dimensi komputasional ini, arsitektur Hibrida memerlukan alokasi sumber daya sistem dan waktu pelatihan yang lebih lama. Hal ini disebabkan oleh tahapan pemrosesan di mana komputasi dijalankan secara sekuensial melalui ekstraksi arsitektur pohon terlebih dahulu sebelum dilanjutkan dengan estimasi matriks residu secara berulang oleh elemen statistika. Karakteristik ini meningkatkan alokasi waktu pemrosesan komputasi pada memori utama.

Secara kontras, model linier murni maupun ansambel tunggal memerlukan kalkulasi waktu yang bersifat proporsional terhadap densitas data, sehingga memiliki durasi pemrosesan yang relatif konstan dan memiliki kebutuhan komputasi yang rendah. Penggunaan komputasi kedua arsitektur tunggal tersebut memengaruhi metrik penentuan yang diturunkan, sebagaimana yang dirangkum pada sebaran vektor matriks dalam Tabel III.9.

Tabel III.9 Matriks Evaluasi Alternatif Terhadap Efisiensi Komputasi (KMP)

KMP	ARIMA	RF	Hybrid	Bobot Lokal
ARIMA	1,00	1,00	4,00	0,444
RF	1,00	1,00	4,00	0,444
Hybrid	0,25	0,25	1,00	0,111

III.7.3.5 Evaluasi Terhadap Kemudahan Implementasi (IMP)

Kemudahan implementasi difokuskan pada kelancaran perancangan kode program serta kebutuhan kustomisasi pustaka (*library*) pemrograman standar. Kriteria ini mempertimbangkan karakteristik adaptasi struktural saat mengonfigurasi perancangan abstraksi kode ke dalam ekosistem modul analitik data seperti Python. Aspek ketersediaan modul integrasi, kesederhanaan alur *pipeline*, hingga ketersediaan fungsi terbuka menjadi dasar evaluasi.

Komponen tunggal, meliputi model ARIMA dan pohon keputusan, terfasilitasi secara operasional oleh ketersediaan pustaka sumber terbuka *scikit-learn* serta *stats-models*. Karakteristik fungsional kedua algoritma tersebut dapat dieksekusi melalui

sintaks dasar regresi tanpa merancang spesifikasi baru secara manual. Karakteristik bawaan ini membuat siklus desain komputasional menjadi efektif untuk direplikasi ulang. Perbandingan bobot lokal yang berpihak pada kesederhanaan arsitektur dasar tersebut divisualisasikan pada Tabel III.10.

Tabel III.10 Matriks Evaluasi Alternatif Terhadap Kemudahan Implementasi (IMP)

IMP	ARIMA	RF	Hybrid	Bobot Lokal
ARIMA	1,00	1,00	3,00	0,429
RF	1,00	1,00	3,00	0,429
Hybrid	0,33	0,33	1,00	0,143

Sebaliknya, arsitektur Hibrida memerlukan penyusunan fungsi alur *pipeline* kustom dengan derajat kompleksitas tinggi yang dirancang secara internal (*from scratch*). Karakteristik keterkaitan fungsional (*functional dependency*) yang membungkus komponen ini memengaruhi fleksibilitas implementasi dasar.

III.7.4 Sintesis Global dan Solusi Terpilih

Fase agregasi akhir dalam prosedur AHP dilakukan melalui operasi sintesis global dengan mengalikan matriks bobot prioritas lokal terhadap nilai bobot kriteria utama. Hasil perhitungan sintesis secara menyeluruh disajikan pada Tabel III.11.

Tabel III.11 Matriks Sintesis Akhir untuk Penentuan Solusi Prediktif

Alternatif	INT	AKR	PLK	KMP	IMP	Skor Total
ARIMA	0,667	0,105	0,095	0,444	0,429	0,364 (36,4%)
Random Forest	0,167	0,258	0,327	0,444	0,429	0,271 (27,1%)
Hibrida + FE	0,167	0,637	0,578	0,111	0,143	0,365 (36,5%)

Berdasarkan hasil kalkulasi agregasi pada Tabel III.11, solusi Model Hibrida yang dikombinasikan dengan teknik rekayasa fitur (*Feature Engineering*) memperoleh skor prioritas tertinggi sebesar 36,5%. Hasil matematis ini didorong oleh nilai prioritas lokal yang tinggi pada kriteria Akurasi (AKR) dan Pola Kompleks (PLK), serta dukungan analisis SHAP yang menjaga fungsi kriteria Interpretabilitas (INT). Meskipun model hibrida memiliki nilai yang rendah pada aspek efisiensi komputasi memori (KMP) dan kemudahan implementasi kode (IMP) karena strukturnya yang sekuensial, karakteristik tersebut tidak memengaruhi penurunan skor total secara global karena kedua kriteria operasional itu memiliki bobot kepentingan yang rendah. Dengan demikian, keputusan pemilihan arsitektur hibrida ini memiliki landasan kuantitatif yang konsisten untuk digunakan sebagai model estimasi harian kualitas udara DKI Jakarta.

BAB IV

PERANCANGAN

IV.1 Arsitektur Konseptual Sistem


Bagian ini menguraikan landasan konseptual dan fungsional dari penyesuaian alur sistem pemantauan kualitas udara melalui evaluasi terhadap karakteristik sistem berjalan serta penyusunan kerangka kerja usulan yang diorientasikan pada karakteristik pemodelan yang adaptif. Perancangan arsitektur konseptual ini bertujuan untuk memberikan gambaran mengenai aliran informasi dan logika pemrosesan data, dengan menekankan pada pergeseran fungsionalitas dari pelaporan data historis menjadi komponen analisis prediktif. Integrasi pemodelan komputasi berbasis *machine learning* dalam arsitektur usulan dirancang untuk memproses karakteristik data polusi udara di Jakarta sehingga diharapkan mampu mengurangi nilai kesalahan estimasi guna membantu proses pemantauan lingkungan.

IV.1.1 Sistem Berjalan (*Existing Sistem*)

Sistem pemantauan kualitas udara yang dikelola oleh Dinas Lingkungan Hidup (DLH) Provinsi DKI Jakarta saat ini menggunakan arsitektur pemrosesan satu arah. Secara operasional, data mentah ditarik dari stasiun pemantauan, dikonversi menjadi Indeks Standar Pencemar Udara (ISPU), dan didistribusikan kepada masyarakat melalui kanal digital resmi. Alur sistem berjalan yang bersifat linear ini mencerminkan proses pengolahan data konvensional yang belum mengintegrasikan pemodelan prediktif secara otomatis.

Secara arsitektural, sistem ini beroperasi sebagai entitas penyimpan dan pelapor data historis (*data logger and reporter*) yang bersifat pasif. Keterbatasan analitik prediktif menyebabkan sistem memetakan kondisi kualitas udara yang telah terjadi tanpa menyediakan estimasi nilai untuk periode mendatang. Hal ini memengaruhi kegunaan data dalam upaya penentuan langkah mitigasi dan perencanaan kebijakan perlindungan kesehatan masyarakat yang memerlukan informasi proyeksi polusi secara antisipatif.

Karakteristik pada modul pemrosesan menyebabkan data mentah belum diproses melalui rekayasa fitur secara multivariat untuk menangkap variasi atmosferik yang dinamis. Tanpa adanya modul inferensi yang memadai, sistem memproses data historis tanpa menghasilkan proyeksi nilai yang dapat digunakan oleh pemangku kepentingan. Akibatnya, sistem belum menyediakan acuan numerik mengenai proyeksi kualitas udara untuk mengantisipasi fluktuasi polutan, sebagaimana ditunjukkan pada diagram alir Gambar IV.1.




Gambar IV.1 Diagram sistem pemantauan kualitas udara Jakarta saat ini (Sistem Berjalan)

IV.1.2 Arsitektur Usulan (*Proposed Sistem*)

Untuk meminimalkan keterbatasan arsitektur yang ada, penelitian ini merancang ulang arsitektur sistem dengan menambahkan komponen pemodelan prediktif ke dalam alur informasi secara terintegrasi. Arsitektur usulan mengusung konsep modul terpisah (*decoupled modules*) yang beroperasi secara berurutan (*pipeline*) untuk mendukung kelancaran pemrosesan data. Pendekatan ini memungkinkan setiap komponen sistem bekerja secara mandiri namun tetap terhubung dalam satu aliran data yang konsisten.

Data yang bersumber dari basis data SPKUA diproses secara sistematis melalui modul *Data Pipeline & ETL* untuk tahap pembersihan, penanganan data hilang, dan normalisasi. Selanjutnya, data tersebut dimasukkan ke modul *Feature Engineering* untuk mengekstraksi variabel baru berupa karakteristik jeda temporal dan interaksi kimiawi antar polutan gas yang relevan dengan kondisi lokal Jakarta. Matriks data hasil rekayasa kemudian diproses secara sekuensial oleh modul inferensi hibrida yang menggabungkan karakteristik pemodelan non-linier dari *Random Forest* dan komponen linier dari ARIMA.

Dalam rangka memberikan transparansi terhadap hasil prediksi, arsitektur ini mengintegrasikan modul penjelasan model (*Explainable AI*) berbasis metode SHAP. Modul tersebut berfungsi untuk menguraikan kontribusi setiap variabel terhadap nilai estimasi sehingga dasar dari sebuah keputusan model dapat dianalisis secara logis oleh analis kualitas udara. Luaran sistem ini menyediakan informasi variabel yang bervariasi dibandingkan sistem berjalan, dengan visualisasi arsitektur yang ditampilkan secara menyeluruh pada Gambar IV.2.



Gambar IV.2 Diagram Arsitektur Sistem Prediksi Hibrida Terintegrasi (Sistem Usulan)

IV.1.3 Perbandingan Sistem

Transformasi fungsional dari sisi peran, logika pemrosesan, dan nilai keluaran antara sistem berjalan dan sistem usulan dirangkum secara teknis pada Tabel IV.1. Tabel ini menunjukkan pergeseran karakteristik sistem dari pendekatan reaktif yang bergantung pada data mentah menuju pendekatan proaktif berbasis data multidimensi. Perbandingan ini menjadi landasan untuk menjustifikasi penggunaan model hibrida

dalam pemantauan lingkungan.

Tabel IV.1 Matriks Perbandingan Teknis Sistem Berjalan dan Sistem Usulan

Aspek Perancangan	Sistem Berjalan (<i>Existing</i>)	Sistem Usulan (<i>Proposed</i>)
Paradigma Operasional	Reaktif; menyajikan informasi kualitas udara pasca-kejadian (<i>post-factum</i>).	Proaktif; menyediakan estimasi proyeksi konsentrasi polutan harian ($t + 1$).
Dimensi Data	Univariat tunggal berbasis parameter polutan mentah (1D).	Multivariat (15 fitur) mengintegrasikan aspek temporal dan interaksi kimiawi.
Mesin Pemrosesan	Kalkulasi statistik deskriptif harian untuk konversi nilai ISPU.	Hibridisasi sekuensial menggabungkan komponen linier dan non-linier.
Interpretabilitas	Deskriptif tanpa analisis kontribusi fitur masukan.	Transparan; analisis kontribusi fitur berbasis metode eksplorasi TreeSHAP.

Penerapan perancangan data multidimensi menunjukkan bahwa sistem usulan menggunakan hubungan antarpolutan untuk menangkap karakteristik pola kompleks atmosfer di wilayah DKI Jakarta. Penggunaan fitur interaksi kimiawi menyediakan informasi tambahan yang tidak tersedia pada sistem berjalan yang memproses gas polutan secara terpisah. Hal ini menjadi faktor penting dalam meminimalkan kesalahan estimasi, terutama saat menghadapi variabilitas data akibat kondisi lingkungan yang berubah-ubah.

Melalui perancangan sistem yang diusulkan, luaran sistem dikembangkan dari sekadar laporan statistik menjadi instrumen prediktif untuk mendukung penentuan kebijakan. Sistem usulan menyediakan kapabilitas bagi pihak berwenang untuk merancang langkah intervensi kebijakan sebelum konsentrasi polusi mencapai ambang batas yang dapat memengaruhi kesehatan masyarakat. Integrasi fitur dan model hibrida ini menjadi alternatif pendekatan dalam pemanfaatan teknologi informasi untuk pengawasan kualitas udara perkotaan.

IV.2 Desain Data Pipeline dan Pemodelan UML

Perancangan sistem dipetakan menggunakan pemodelan standar untuk mendeskripsikan aliran informasi dan interaksi fungsional sebagai solusi yang menghubungkan karakteristik rekayasa perangkat lunak dan sains data. Pendekatan ini dilakukan untuk memastikan bahwa setiap komponen sistem, mulai dari tahapan pemroses-


an data hingga penyajian hasil estimasi, terdokumentasi secara teknis. Pemodelan ini juga berfungsi sebagai jembatan komunikasi antara kebutuhan fungsional sistem dengan implementasi fungsi pada tahap pengembangan.

IV.2.1 Diagram Alir Data (DFD)

Aliran transformasi data dari tahapan masukan hingga keluaran dimodelkan menggunakan *Data Flow Diagram* (DFD) untuk memberikan gambaran mengenai pergerakan data dalam sistem. Pemodelan ini digunakan untuk mengidentifikasi komponen masukan data, proses transformasi yang terjadi, serta keluaran yang dihasilkan untuk setiap entitas terkait. Melalui penerapan DFD, batasan operasional sistem dalam mengolah informasi polutan menjadi lebih terstruktur.

DFD Level 0 atau Diagram Konteks merepresentasikan batasan sistem secara makro dan hubungan antara sistem dengan entitas eksternal. Diagram ini menunjukkan posisi sistem sebagai unit pemrosesan data yang menerima input dari penyedia data dan mendistribusikan hasil estimasi kepada pengguna akhir. Representasi ini diperlukan untuk memahami cakupan fungsional sistem sebelum masuk ke detail teknis.

Dalam konteks sistem ini, entitas "Dinas Lingkungan Hidup / Sensor SPKUA" bertindak sebagai penyuplai data parameter polutan harian. Sistem Prediksi PM₁₀ Terintegrasi menerima data tersebut, mengeksekusi komputasi prediktif serta analitik atribusi nilai SHAP, kemudian menghasilkan keluaran berupa laporan prediksi harian dan visualisasi kontribusi fitur. Hasil akhir ini didistribusikan kepada entitas "Pemangku Kebijakan / Masyarakat" sebagai instrumen pendukung keputusan, sebagaimana ditunjukkan pada Gambar IV.3.



Gambar IV.3 DFD Level 0 (Diagram Konteks) Sistem Prediksi PM₁₀

IV.2.2 Desain Proses ETL (*Extract, Transform, Load*)

Desain ETL mengatur mekanisme penyiapan data yang berasal dari kelima stasiun pemantauan (DKI1 hingga DKI5) agar dapat digunakan dalam pemodelan secara terpisah. Proses ini diperlukan mengingat data mentah dapat memiliki celah informasi akibat kendala teknis pada sensor di lapangan. Melalui tahapan ekstraksi dan transformasi, kelengkapan data dipertahankan sebelum masuk ke fase pemodelan komputasi.

Dalam rangka menangani data yang hilang tanpa menyebabkan kebocoran informasi masa depan (*look-ahead bias*), dirancang sebuah algoritma imputasi dengan pendekatan *historical rolling mean*. Penggunaan jendela waktu $k = 5$ harian memungkinkan sistem untuk mengestimasi nilai yang hilang pada waktu t murni berdasarkan tren lokal terdekat secara historis ($t - 1$ hingga $t - k$) pada stasiun yang bersangkutan. Pendekatan ini digunakan untuk menjaga integritas urutan waktu kronologis dan memastikan bahwa informasi dari masa depan tidak memengaruhi proses prapemrosesan data latih.

Tahap akhir dari proses ETL adalah melakukan pembersihan dan transformasi data untuk membentuk matriks fitur prediktor yang siap digunakan. Proses prapemrosesan dilakukan secara berurutan pada setiap stasiun pemantauan guna menjaga karakteristik spasial yang unik di setiap wilayah administratif DKI Jakarta. Logika prapemrosesan dan alur imputasi data tersebut dijabarkan secara rinci pada Algoritma IV.1.

Algoritma IV.1 Algoritma Prapemrosesan dan Imputasi *Rolling Mean* per Stasiun

Require: Matriks data mentah stasiun S = $\{DKI1, DKI2, DKI3, DKI4, DKI5\}$, jendela waktu $k = 5$

Ensure: Matriks data stasiun S tanpa nilai kosong (*null*)

```

1: for each  $s \in S$  do
2:   for each observasi waktu  $t$  dari 1 to  $N$  do
3:     if  $s[t]$  is null then
4:        $sum \leftarrow 0$ 
5:       for  $i = 1$  to  $k$  do
6:          $sum \leftarrow sum + s[t - i]$ 
7:       end for
8:        $s[t] \leftarrow sum/k$ 
9:     end if
10:  end for
11: end for
12: return  $S$ 

```

IV.2.3 Prosedur Pencegahan Kebocoran Data (*Data Leakage Prevention*)

Dalam arsitektur data runtun waktu, pencegahan *data leakage* (khususnya *look-ahead bias*) merupakan salah satu parameter penting untuk menjaga integritas eksperimen. Sistem ini mengimplementasikan tiga tahapan pengendalian agar informasi masa depan tidak bocor ke masa lalu selama proses ETL dan pemodelan:

1. Imputasi Kausal/Historis: Proses penanganan nilai kosong (*null*) menggunakan fungsi *rolling mean* berbasis data masa lalu (*historical rolling mean*). Formula imputasi pada waktu t murni mengevaluasi data historis dari rentang


jendela $t - 1$ s.d. $t - k$. Nilai masa depan pada $t + 1$ s.d. $t + k$ sama sekali tidak diikutsertakan dalam pembobotan interpolasi sensor.

2. Feature Engineering Bebas Bias Temporal: Seluruh kalkulasi variabel turunan statistik bergerak (*Rolling Mean* 3-hari dan 7-hari) dikonfigurasi menggunakan parameter fungsi Python `closed='left'`. Aturan ini memastikan titik perhitungan pada hari ini (t) murni mengagregasi data historis hari-hari ke belakang tanpa menyertakan nilai target hari ini yang akan diprediksi.
3. Isolasi Standardisasi Skala (*Scaling Isolation*): Guna mencegah kebocoran informasi distribusi statistik dari set validasi atau pengujian ke dalam set pelatihan, instrumen penyesuaian nilai (*StandardScaler*) dilatih secara ketat hanya menggunakan subset data pelatihan (`scaler.fit_transform(X_train)`). Data evaluasi lainnya kemudian ditransformasikan secara pasif menggunakan parameter rata-rata dan deviasi standar yang diekstrak dari fase pelatihan (`scaler.transform(X_val)`), tanpa melakukan kalkulasi ulang distribusi pada data di luar set latih.

IV.2.4 Activity Diagram Pemodelan Hibrida

Logika fase komputasi model pada saat mode pelatihan (*training*) didokumentasikan melalui *Activity Diagram* untuk menggambarkan urutan aktivitas secara sekuensial. Diagram ini memberikan gambaran mengenai alur kerja sistem dalam mempelajari karakteristik data dari tahap awal hingga model siap digunakan untuk melakukan estimasi. Pemisahan aktivitas dilakukan dengan tujuan menghindari tumpang tindih fungsi dalam arsitektur hibrida sekuensial yang dikembangkan. Rincian alur kerja serta tahapan sekuensial pada proses pelatihan model ini disajikan secara visual pada Gambar IV.4.


Berdasarkan alur yang dirancang pada Gambar IV.4, proses komputasi berjalan secara berurutan untuk menjaga keteraturan fungsi tiap modul. Setelah tahapan rekayasa fitur (*feature engineering*) selesai dieksekusi, data dikirim ke modul *Random Forest* untuk fase pelatihan primer guna menghasilkan estimasi nilai awal, yang kemudian dilanjutkan dengan kalkulasi sisaan (*residual*) melalui selisih antara nilai aktual dan hasil prediksi tersebut. Deret sisaan galat ini selanjutnya diproses menggunakan model statistik ARIMA pada fase sekunder untuk menangkap komponen linier temporal yang belum terurai oleh percabangan pohon keputusan. Penggabungan dua metode dengan karakteristik berbeda ini diterapkan agar diperoleh hasil estimasi akhir dengan akumulasi galat yang terkendali, di mana keseluruhan alur pelatihan diakhiri dengan penyimpanan konfigurasi parameter dari kedua model (*Saved Model*) untuk fase inferensi harian secara berkala.



Gambar IV.4 *Activity Diagram* Alur Pelatihan Model Hibrida Sekuensial

IV.2.5 Sequence Diagram Sistem Inferensi Berkala

Prosedur operasional sistem pada saat melakukan peramalan harian divisualisasikan melalui *Sequence Diagram* untuk menunjukkan interaksi antar-modul. Diagram ini menggambarkan alur penyampaian pesan dan koordinasi berbagai komponen perangkat lunak dalam merespons permintaan estimasi konsentrasi polutan. Melalui pemodelan urutan ini, hubungan kronologis antar-komponen serta eksistensi elemen perangkat lunak selama proses inferensi berlangsung dapat ditelaah secara terstruktur, sebagaimana ditampilkan secara mendetail pada Gambar IV.5.



Gambar IV.5 *Sequence Diagram* Proses Inferensi Prediksi Harian

Berdasarkan tahapan urutan yang digambarkan pada Gambar IV.5, alur inferensi berkala (*automated batch processing*) diawali ketika komponen penjadwal (*Scheduler*) memicu modul ETL untuk menarik tujuh hari riwayat data terakhir dari basis data stasiun. Modul prediksi kemudian memuat konfigurasi parameter model *Random Forest* dan ARIMA dari memori penyimpanan untuk menjalankan proses kalkulasi secara sekuensial, di mana hasil dari kedua model tersebut dijumlahkan untuk menghasilkan nilai prediksi tunggal yang merepresentasikan konsentrasi PM_{10} untuk horizon satu hari ke depan ($t + 1$). Tahap akhir dari rangkaian proses ini melibatkan modul penjelasan model untuk mengkalkulasi pengaruh setiap fitur masukan terhadap hasil estimasi yang dikeluarkan, sebelum seluruh informasi dikemas menjadi sebuah laporan terpadu yang memuat nilai prediksi beserta visualisasi kontribusi fiturnya.

IV.3 Spesifikasi Algoritmik Rekayasa Fitur

Bagian ini merumuskan transformasi variabel mentah menjadi matriks fitur yang memiliki varians informasi temporal dan karakteristik kimiawi untuk memproses sifat data deret waktu PM_{10} . Rekayasa fitur dilakukan untuk menyediakan variabel prediktor tambahan yang tidak termuat secara langsung pada data mentah, namun memiliki pengaruh terhadap fluktuasi nilai kualitas udara di Jakarta. Dengan memperluas dimensi masukan melalui fitur turunan, model hibrida diharapkan mampu menghasilkan estimasi yang stabil.

IV.3.1 Matriks Transformasi Fitur

Transformasi variabel mentah menjadi matriks fitur dilakukan untuk mengelola karakteristik data kualitas udara PM_{10} yang memiliki varians fluktuasi dan dependensi musiman. Rekayasa fitur dalam penelitian ini bertujuan untuk mengekstraksi informasi temporal dan kimiawi berkala yang tidak terlihat secara langsung pada observasi harian harian, namun berpengaruh terhadap persistensi polutan di atmosfer. Melalui perluasan dimensi input, model hibrida dapat menangkap dependensi temporal dan korelasi antarpolutan secara lebih komprehensif.

Rancangan fitur secara teoretis dibagi ke dalam empat kategori utama untuk memberikan konteks prediktif. Kategori tersebut meliputi fitur *lag* untuk menangkap pengaruh variabel hari sebelumnya, statistik *rolling window* untuk memetakan tren mingguan, interaksi kimiawi untuk merepresentasikan hubungan antar gas polutan, serta penanda temporal untuk mengidentifikasi aktivitas masyarakat urban. Pembagian kategori ini dilakukan agar setiap variabel yang dihasilkan memiliki landasan teoretis yang sesuai dengan kondisi lingkungan perkotaan.

Matriks desain fitur yang dikembangkan mengintegrasikan total 15 fitur komposit yang disusun berdasarkan karakteristik data ISPU di DKI Jakarta. Tabel IV.2 merangkum spesifikasi teknis dari variabel-variabel turunan tersebut beserta fungsinya dalam model. Penentuan variabel ini menjadi tahapan dalam memitigasi galat prediksi yang muncul akibat perubahan pola emisi kendaraan dan industri yang dinamis, sebagaimana dirinci pada tabel berikut.

Tabel IV.2 Matriks Desain Fitur Komposit Hibrida

Kategori Fitur	Nama Variabel	Justifikasi Fisis / Fungsi
Lag Temporal	pm10_lag1, pm10_lag2, pm10_lag7	Menangkap efek persistensi massa polutan harian dan pengaruh siklus komuter mingguan.
Statistik Berjalan	pm10_ma3, pm10_ma7, pm10_std7	Memetakan tren pergerakan nilai polusi jangka pendek, mingguan, serta tingkat volatilitas data.
Interaksi Kimia	co_times_o3	Representasi aktivitas fotokimia primer dan laju pembentukan partikulat sekunder di atmosfer.
Penanda Temporal	month, season, is_weekend	Mengidentifikasi variasi musiman makro (presipitasi) dan penurunan mobilitas urban akhir pekan.

IV.3.2 Logika Pembangkitan Fitur Temporal dan Interaksi

Polusi udara di wilayah metropolitan dipengaruhi oleh emisi primer dan reaksi pembentukan partikulat sekunder yang terjadi akibat interaksi kimiawi antar gas polutan. Pembangkitan fitur komposit dalam penelitian ini dirancang sebagai upaya untuk merepresentasikan dinamika tersebut, khususnya pada interaksi antara gas Karbon Monoksida dan Ozon Permukaan yang menjadi salah satu penanda fluktuasi partikulat. Melalui pendekatan perkalian antarvariabel gas ini, model diharapkan dapat mengidentifikasi pola data yang mendekati karakteristik kondisi di lapangan tanpa harus memperdalam struktur percabangan pohon keputusan.


Selain variabel kimiawi, faktor aktivitas temporal berupa siklus mingguan dan bulanan juga dimasukkan sebagai fitur tambahan untuk mengamati indikasi variasi beban emisi dari sektor transportasi. Langkah ini dilakukan dengan tujuan agar setiap baris data memiliki penanda waktu, sehingga model dapat membedakan kecenderungan pola polusi antara hari kerja dan akhir pekan. Integrasi fitur temporal ini berfungsi sebagai informasi masukan pelengkap bagi algoritma *Random Forest*. Prosedur rekayasa fitur beserta alur kerjanya secara berurutan ditunjukkan pada Algoritma IV.2 dan diagram alir Gambar IV.6 di bawah ini.

Algoritma IV.2 Pembangkitan Fitur Interaksi dan Temporal

Require: Matriks X dengan parameter dasar (PM_{10} , CO , O_3 , SO_2 , NO_2) terindeks waktu t

Ensure: Matriks X_{new} yang telah dikombinasikan dengan fitur komposit

```
1: for  $t = 1$  to  $N$  do
2:    $X_{new}[t].month \leftarrow \text{EkstrakBulan}(t)$ 
3:    $X_{new}[t].season \leftarrow \text{PenentuanMusim}(t)$ 
4:    $day \leftarrow t \pmod{7}$ 
5:   if  $day = 5$  or  $day = 6$  then
6:      $X_{new}[t].is\_weekend \leftarrow 1$ 
7:   else
8:      $X_{new}[t].is\_weekend \leftarrow 0$ 
9:   end if
10:   $X_{new}[t].co\_times\_o3 \leftarrow X[t].CO \times X[t].O_3$ 
11: end for
12: return  $X_{new}$ 
```



Gambar IV.6 Alur Logika Pembangkitan Fitur Komposit

Diagram alir tersebut memperjelas bahwa implementasi logika pembangkitan fitur dieksekusi secara otomatis setelah tahap prapemrosesan data selesai. Urutan eksekusi dikonstruksi mulai dari pengolahan data *lag*, perhitungan statistik bergerak pada jendela waktu yang ditentukan, hingga kalkulasi akhir fitur interaksi antarpolutan. Struktur prosedur ini dirancang untuk menjaga konsistensi hasil transformasi matriks fitur pada setiap iterasi eksperimen dan memastikan kerangka pemodelan tetap stabil.

IV.3.3 Mekanisme Standardisasi Skala

Seluruh matriks fitur yang telah dibangkitkan memiliki rentang nilai yang bervariasi, mulai dari satuan konsentrasi indeks gas polutan hingga penanda biner untuk variabel waktu harian. Perbedaan skala antar dimensi masukan ini dapat memengaruhi stabilitas pada proses konvergensi model dan pengaruh fitur dengan nilai absolut besar terhadap hasil estimasi. Oleh karena itu, diperlukan tahapan standardisasi untuk

menyelaraskan distribusi seluruh variabel masukan sebelum memasuki fase pelatihan model hibrida.

Mekanisme standardisasi yang diterapkan dalam perancangan ini adalah *Z-Score Standardization (StandardScaler)*. Metode ini mengubah distribusi setiap fitur sehingga memiliki nilai rata-rata nol dan deviasi standar satu, tanpa menghilangkan karakteristik distribusi aslinya. Proses penskalaan ini dilakukan secara terpisah antara data latih dan data uji untuk meminimalkan risiko terjadinya kebocoran informasi masa depan (*look-ahead bias*) yang dapat menyebabkan hasil evaluasi menjadi bias.

Penggunaan standardisasi skala digunakan untuk mendukung stabilitas numerik pada algoritma regresi dan membantu proses pencarian hiperparameter yang sesuai melalui Optuna. Dengan menyamakan rentang nilai, kontribusi setiap fitur terhadap target prediksi PM_{10} dapat dievaluasi secara proporsional oleh model *Random Forest* maupun ARIMA. Konstruksi matematis dari transformasi standardisasi skala ini mengikuti prinsip statistika sebagaimana diturunkan pada Persamaan IV.1.

$$z = \frac{x - \mu}{\sigma} \quad (IV.1)$$

IV.4 Desain Arsitektur Hibrida Sekuensial

Pemodelan dirancang menggunakan pendekatan sekuensial di mana algoritma ansambel berbasis pohon dan fungsi diferensi stokastik linier bekerja secara komplementer untuk memetakan pola polusi udara. Arsitektur hibrida ini dikonstruksi untuk memisahkan komponen data non-linier dari komponen linier yang bersifat temporal pada deret waktu PM_{10} . Melalui penggabungan dua pendekatan pemodelan yang berbeda, sistem diarahkan untuk mampu menghasilkan estimasi dengan nilai kesalahan yang rendah dibandingkan penggunaan model tunggal murni.

Integrasi sekuensial ini dimulai dengan pemodelan fase primer yang bertujuan untuk memetakan komponen varians utama dari data. Hasil keluaran dari fase primer tersebut kemudian diproses lebih lanjut untuk mengidentifikasi nilai residu yang masih menyimpan karakteristik informasi tertentu. Tahapan ini dilakukan agar setiap algoritma bekerja pada domain data yang sesuai dengan karakteristik matematis masing-masing, guna meminimalkan risiko ketidaksesuaian pola data.

Aliran kerja arsitektur hibrida ini secara sistematis mencakup fase pelatihan primer, perhitungan residu, pelatihan fase sekunder, hingga integrasi akhir hasil prediksi.

Penggunaan metode sekuensial ini juga memfasilitasi proses pencarian parameter yang terstruktur bagi kedua model. Struktur desain ini menjadi fondasi utama dalam mencapai target penaksiran nilai galat peramalan kualitas udara di wilayah DKI Jakarta.

IV.4.1 Desain Fase Primer (*Random Forest*)

Pada fase pertama, keseluruhan matriks fitur X_{train} hasil rekayasa dimasukkan ke model *Random Forest Regressor* untuk memetakan hubungan fungsional terhadap target PM_{10} . Algoritma ini dipilih sebagai pembelajar primer karena karakteristiknya dalam memproses data multidimensi dan kemampuannya dalam mengidentifikasi tingkat kepentingan fitur secara otomatis. Proses ini fokus pada penangkapan fluktuasi polusi yang dipengaruhi oleh interaksi kimiawi dan variabel temporal.

Konstruksi model fase primer melibatkan pembentukan sejumlah pohon keputusan yang bekerja secara independen melalui skema *bagging*. Setiap pohon memberikan estimasi nilai polutan, yang kemudian dirata-ratakan untuk menghasilkan satu nilai estimasi nilai awal (*base prediction*). Pendekatan ansambel ini digunakan untuk mereduksi varians dan menjaga stabilitas prediksi pada data polusi udara yang memiliki fluktuasi harian.

Ruang inisialisasi parameter pada fase ini dirancang untuk memfasilitasi proses pencarian di tahap berikutnya. Parameter utama yang dikonfigurasi meliputi jumlah estimator (*n_estimators*) untuk menentukan banyaknya pohon, serta kedalaman maksimum pohon (*max_depth*) untuk mengontrol kompleksitas model. Pengaturan parameter pada fase primer ini penting karena akan menentukan karakteristik residu yang akan diolah oleh model fase sekunder.

IV.4.2 Logika Kalkulasi Residu Temporal

Integrasi sekuensial antara komponen non-linier dan linier dalam pemodelan hibrida didasarkan pada prinsip jumlahan komponen varians data target PM_{10} . Berdasarkan metode dekomposisi asimilasi, deret waktu aktual dipandang sebagai gabungan dari pola non-linier dan dependensi linier temporal. Dengan menjumlahkan hasil estimasi fase primer dan koreksi fase sekunder, model hibrida menyusun akumulasi proyeksi akhir. Formulasi jumlahan aditif untuk memperoleh nilai estimasi hibrida terpadu didefinisikan pada Persamaan IV.2.

$$\hat{Y}_{hybrid,t} = \hat{N}_t + \hat{L}_t \quad (IV.2)$$

Data residu ($e_t = Y_t - \hat{N}_t$) dalam konteks kualitas udara Jakarta mencerminkan komponen linier temporal sisa yang tidak terurai oleh percabangan pohon keputusan pada fase primer. Fenomena fisik atmosfer, seperti penumpukan partikulat di dekat permukaan tanah pada lapisan batas planet yang stabil, kerap menyisakan pola autokorelasi linier yang terlewat dari pemodelan berbasis pohon yang terfokus pada fluktuasi nilai harian. Melalui pemrosesan deret sisaan galat ini menggunakan komponen ARIMA pada fase sekunder, sistem melakukan penyesuaian nilai guna meminimalkan sisa kesalahan estimasi akhir secara keseluruhan. Logika komputasi kalkulasi residu dan penggabungan proyeksi sekuensial tersebut dijabarkan secara rinci pada Algoritma IV.3.

Algoritma IV.3 Kalkulasi Residu Hibrida Sekuensial

Require: Target aktual Y , Matriks fitur X , Model tersimpan RF dan $ARIMA$

Ensure: Hasil prediksi hibrida akhir Y_{hybrid}

```

1:  $\hat{N} \leftarrow RF.predict(X)$ 
2:  $res \leftarrow$  array kosong berukuran  $|Y|$ 
3: for  $t = 1$  to  $|Y|$  do
4:    $res[t] \leftarrow Y[t] - \hat{N}[t]$ 
5: end for
6:  $\hat{L} \leftarrow ARIMA.predict(res)$ 
7:  $Y_{hybrid} \leftarrow$  array kosong
8: for  $t = 1$  to  $|Y|$  do
9:    $Y_{hybrid}[t] \leftarrow \hat{N}[t] + \hat{L}[t]$ 
10: end for
11: return  $Y_{hybrid}$ 

```

IV.4.3 Desain Fase Sekunder (ARIMA)

Deret residu hasil komputasi yang telah dipisahkan dari pola data kemudian diuji stasioneritasnya sebagai syarat dalam pemodelan statistik. Pengujian dilakukan menggunakan metode *Augmented Dickey-Fuller* (ADF) untuk menentukan apakah deret sisaan tersebut memerlukan proses pembedaan (*differencing*). Hasil uji ADF menentukan nilai parameter d yang diperlukan agar data residu memenuhi asumsi stasioneritas.

Setelah kondisi stasioner terpenuhi, model ARIMA digunakan untuk mengekstraksi keterikatan temporal melalui parameter autokorelasi (*Auto-Regressive*) dan rata-rata bergerak (*Moving Average*). Fase ini fokus pada penangkapan dependensi temporal linear yang masih terdapat dalam data residu. Penggunaan ARIMA sebagai model sekunder bertujuan untuk melakukan penyetelan halus (*fine-tuning*) terhadap estimasi awal yang dihasilkan oleh fase primer.

Konfigurasi parameter (p, d, q) pada fase sekunder ini diatur secara dinamis untuk menyesuaikan dengan karakteristik residu pada setiap stasiun pemantauan. Hal ini dilakukan agar model ARIMA mampu beradaptasi dengan tingkat persistensi polutan yang bervariasi di wilayah DKI Jakarta. Hasil peramalan dari fase sekunder ini kemudian dijumlahkan dengan hasil fase primer untuk menghasilkan luaran sistem akhir.

IV.4.4 Desain Orkestrasi Penyetelan Parameter Menggunakan Optuna

Penyetelan parameter dilakukan untuk menghindarkan model dari keterbatasan pencarian manual atau pencarian heuristik konvensional yang memerlukan waktu lama. Dalam penelitian ini, diimplementasikan kerangka pencarian probabilitas berbasis Bayesian menggunakan pustaka Optuna untuk mencari kombinasi parameter bagi *Random Forest* dan ARIMA secara bersamaan. Pendekatan ini bekerja dengan mengevaluasi performa model berdasarkan fungsi objektif khusus yang meminimalkan galat prediksi berupa metrik *Root Mean Squared Error* (RMSE) pada data validasi yang diekstrak melalui skema validasi silang di dalam arsitektur hibrida sekuensial.

Proses eksplorasi tersebut mengandalkan algoritma *Tree-structured Parzen Estimator* (TPE) yang secara probabilistik mengarahkan pemilihan parameter ke ruang nilai yang berpotensi menghasilkan nilai galat rendah berdasarkan riwayat percobaan sebelumnya. Melalui mekanisme ini, pencarian parameter orde p dan q pada komponen ARIMA serta batas struktural berupa jumlah pohon keputusan (`n_estimators`) dan kedalaman maksimum (`max_depth`) pada komponen *Random Forest* dapat dilakukan secara otomatis. Tahap penyesuaian parameter berbasis probabilitas ini ditujukan untuk membantu stabilitas konvergensi model serta mempercepat waktu komputasi dibandingkan dengan metode pencarian konvensional, sehingga menghasilkan konfigurasi model yang memiliki kemampuan generalisasi saat dihadapkan pada data baru.

IV.4.5 Justifikasi Efisiensi Optuna pada Ruang Hiperparameter Kombinasi

Dalam arsitektur hibrida sekuensial ini, terdapat kombinasi parameter struktural dari dua ranah algoritma yang berbeda secara simultan: parameter struktur pohon *Random Forest* (`n_estimators` dan `max_depth`) serta parameter orde polinomial statistik ARIMA (p dan q). Jika dievaluasi menggunakan *Grid Search*, ruang pencarian kombinasi dimensi silang ini akan berlipat ganda secara eksponensial ($O(A \times B)$), yang memicu tingginya konsumsi memori dan waktu komputasi yang kurang efisien untuk pemrosesan operasional harian.

Pustaka Optuna digunakan sebagai pendekatan untuk menangani kendala kompleksitas tersebut dengan menerapkan pencarian berbasis optimasi Bayesian Tree-structured Parzen Estimator (TPE). TPE secara dinamis membangun fungsi probabilitas penggerak (*surrogate model*) yang mempelajari riwayat hasil kombinasi hiperparameter dari percobaan-percobaan sebelumnya. Optuna memfokuskan pencarian berikutnya secara terarah pada ruang parameter yang memiliki probabilitas tinggi untuk meminimalkan fungsi kesalahan galat (*objective function* berupa RMSE harian), serta memangkas percobaan yang tidak menunjukkan perbaikan performa secara dini (*pruning*). Hal ini membuat proses kalibrasi parameter pembentuk arsitektur hibrida berjalan secara teratur dan efisien.

IV.5 Desain Skenario Eksperimen dan Validasi

Rancangan skenario eksperimen diformulasikan untuk memastikan bahwa arsitektur prediksi yang dibangun memiliki tingkat keandalan secara empiris. Bagian ini mendefinisikan langkah-langkah metodologis guna memastikan model terhindar dari kondisi pembelajaran berlebih (*overfitting*), melainkan mampu melakukan generalisasi pola pada kondisi kualitas udara untuk periode mendatang. Skema pengujian juga dirancang untuk mengevaluasi pengaruh fitur masukan dan meminimalkan risiko terjadinya anomali komputasional.

IV.5.1 Desain Studi Ablasi (*Ablation Study*)

Untuk mengevaluasi keandalan arsitektur dan memberikan justifikasi terhadap penggunaan rekayasa fitur secara ilmiah, dirancang sebuah skema eksperimen menggunakan metode studi ablasi. Pendekatan ini secara sistematis mengukur dampak dari setiap komponen algoritma maupun fitur masukan terhadap performa prediksi akhir. Melalui pemisahan komponen masukan tersebut, karakteristik model dapat dievaluasi secara independen untuk mengamati apakah nilai kesalahan prediksi yang dihasilkan murni merupakan kontribusi dari desain komposit yang diusulkan.

Evaluasi ablasi diimplementasikan dengan mengisolasi elemen-elemen spesifik di dalam struktur pemrosesan melalui tiga skenario utama, yang didefinisikan sebagai Model A, Model B, dan Model C. Model A bertindak sebagai model acuan dasar (*baseline*) pengukur kinerja murni tanpa proses transformasi, Model B menguji arsitektur hibrida pada kondisi data mentah untuk mengamati kapabilitas hibridisasi secara mandiri, dan Model C mewakili arsitektur akhir yang diintegrasikan dengan fitur hasil rekayasa.

Melalui komparasi hasil metrik galat seperti *Root Mean Squared Error* (RMSE) dan *Mean Absolute Error* (MAE) antar-skenario, kontribusi dari modul rekayasa fitur (*feature engineering*) dapat dianalisis secara kuantitatif. Perbandingan tingkat kesalahan antara performa Model B dan Model C dirancang untuk mengisolasi persentase perubahan galat yang dihasilkan secara khusus oleh kelima belas fitur turunan. Hasil analisis komparatif ini digunakan sebagai landasan rasional untuk memvalidasi karakteristik dari perancangan arsitektur yang diusulkan, di mana spesifikasi teknis terkait konfigurasi dan pemanfaatan fitur dari masing-masing skenario pengujian dirangkum pada Tabel IV.3.

Tabel IV.3 Desain Skenario Eksperimen Studi Ablasi


Nama Skenario	Konfigurasi Model	Spesifikasi Fitur Input
Model A (<i>Baseline</i>)	Model Statistik Tunggal (ARIMA murni).	Deret waktu univariat PM_{10} historis tanpa prediktor eksternal (batas bawah performa).
Model B (Hibrida Non-FE)	Arsitektur Hibrida (<i>Random Forest</i> + ARIMA).	Dataset mentah multivariat berisi 5 polutan dasar (PM_{10} , SO_2 , CO , O_3 , NO_2) tanpa rekayasa fitur.
Model C (Hibrida Usulan)	Arsitektur Hibrida Terkonfigurasi.	Matriks 15 fitur komposit hasil rekayasa (<i>lag</i> , <i>rolling statistics</i> , penanda temporal, dan interaksi silang).

IV.5.2 Skema Validasi *TimeSeriesSplit* (*Forward Chaining*)

Evaluasi performa model prediktif yang memproses data deret waktu memerlukan metode pengujian khusus yang disesuaikan dengan karakteristik urutan waktu. Penggunaan metode validasi silang acak (*K-Fold Cross-Validation* konvensional) kurang sesuai untuk diimplementasikan pada dataset kualitas udara karena proses pengacakan (*shuffling*) baris matriks dapat merusak urutan kronologis data historis. Pelanggaran terhadap urutan waktu ini menimbulkan risiko kebocoran informasi masa depan ke dalam dimensi data latih (*look-ahead bias*), sehingga menghasilkan kalkulasi nilai kesalahan model yang bias. Konsep dasar untuk meminimalkan risiko anomali evaluasi tersebut divisualisasikan melalui metode pemotongan data pada Gambar IV.7.

Sebagai langkah penanganan atas permasalahan validasi tersebut, dirancang sebuah skema *TimeSeriesSplit* yang beroperasi menggunakan pendekatan rantai maju (*Forward Chaining*) sebagaimana ditunjukkan pada visualisasi di atas. Skema validasi ini menjaga urutan kronologis data dengan mempartisi set data menjadi $K = 5$ lipatan (*folds*) observasi yang berekspansi searah berjalannya waktu. Secara ope-

rasional, batas jendela observasi untuk himpunan data latih akan membesar seiring berjalannya putaran lipatan eksperimen, sementara panjang rentang waktu yang digunakan sebagai basis evaluasi pada himpunan data uji dipertahankan konstan.



Gambar IV.7 Visualisasi Pembagian Data pada Skema TimeSeriesSplit

Desain skema ini digunakan untuk memastikan bahwa algoritma diuji kemampuannya dalam merekonstruksi proyeksi data yang belum pernah dilalui pada fase pembelajaran. Pemisahan dimensi historis dan periode evaluasi bertujuan untuk menguji ketahanan model ketika dihadapkan pada fluktuasi riil kualitas udara di lapangan. Rincian pembagian batas ekspansi observasi kronologis dari kelima lipatan iterasi tersebut dijabarkan sebagai berikut:

- (a) Lipatan 1 (*Fold 1*): Data latih menggunakan riwayat observasi dari titik mula hingga titik potong T_1 , dengan pengujian performa prediksi dilakukan pada rentang interval menuju titik T_2 .
- (b) Lipatan 2 (*Fold 2*): Batas matriks data latih diperluas secara kronologis hingga menyentuh titik potong T_2 , untuk kemudian dievaluasi pada rentang interval T_2 menuju T_3 .
- (c) Lipatan 3 (*Fold 3*): Komputasi model mengekstraksi riwayat data masa lampau hingga mencapai batas titik T_3 , yang ditujukan untuk memetakan proyeksi performa pada periode T_3 menuju T_4 .
- (d) Lipatan 4 (*Fold 4*): Dimensi observasi pelatihan berlanjut mengekspansi data latih hingga titik T_4 , di mana karakteristik model divalidasi untuk cakupan prediksi T_4 menuju T_5 .
- (e) Lipatan 5 (*Fold 5*): Fase final pembelajaran menggunakan dimensi ruang data historis yang paling besar hingga titik batas T_5 , dengan target evaluasi observasi akhir di tahun 2025.

IV.6 Desain Modul Penjelasan Model dan Output Pelaporan

Penerapan pemodelan komputasi berbasis *machine learning* dalam ranah kebijakan publik, khususnya pemantauan lingkungan, memiliki batasan jika beroperasi sebagai sistem yang tertutup (*black-box*). Pemangku kepentingan memerlukan rasional-

litas dan transparansi di balik setiap angka prediksi yang dikeluarkan oleh algoritma guna memvalidasi informasi sebelum intervensi dilakukan. Oleh karena itu, perancangan sistem ini mengintegrasikan lapisan interpretasi untuk memberikan justifikasi ilmiah terhadap fluktuasi konsentrasi PM_{10} di Jakarta.

Perancangan modul penjelasan ini bertujuan untuk menghubungkan antara kompleksitas matematis model hibrida dengan kebutuhan praktis analis di instansi terkait. Dengan adanya komponen penjelasan model (XAI), sistem menyediakan informasi variabel prediktor tambahan yang memengaruhi perubahan nilai kualitas udara. Hal ini dilakukan untuk memastikan bahwa model menghasilkan karakteristik yang logis secara teori sains atmosfer.

Struktur keluaran pelaporan dirancang untuk menyederhanakan hasil analitik menjadi informasi yang deskriptif dan mudah dipahami oleh pengambil keputusan. Lapisan pelaporan ini merupakan tahap akhir dari seluruh *pipeline* inferensi berkala yang menyatukan hasil prediksi numerik dengan visualisasi atribusi fitur. Dengan demikian, sistem usulan ini dikembangkan sebagai instrumen pendukung keputusan yang transparan.

IV.6.1 Integrasi *TreeSHAP* pada *Pipeline* Inferensi

Modul penjelasan model dalam penelitian ini dirancang menggunakan algoritma *TreeSHAP* yang diintegrasikan setelah model *Random Forest* menyelesaikan proses prediksi non-linier. Pemilihan *TreeSHAP* didasarkan pada efisiensi komputasionalnya dalam menangani model berbasis pohon dan kemampuannya dalam memberikan estimasi nilai Shapley yang konsisten. Secara matematis, interpretasi ini didasarkan pada kontribusi aditif fitur terhadap nilai prediksi rata-rata, sebagaimana dirumuskan pada Persamaan IV.3.

$$f(x) = \phi_0 + \sum_{i=1}^M \phi_i \quad (IV.3)$$

Sistem dirancang untuk mengekstraksi nilai Shapley guna menganalisis kontribusi fitur yang memengaruhi kenaikan atau penurunan konsentrasi PM_{10} . Penjelasan ini bekerja dengan cara membandingkan hasil prediksi saat suatu fitur hadir dibandingkan dengan saat fitur tersebut absen, sehingga didapatkan bobot pengaruh yang proporsional. Melalui integrasi ini, setiap luaran prediksi harian akan disertai dengan rincian fitur penggerak yang memperkuat hasil pemodelan hibrida.

Dalam implementasinya, modul interpretasi ini dikonfigurasi untuk menghasilkan dua level penjelasan analitik guna memenuhi kebutuhan evaluasi yang berbeda. Level pertama berfokus pada analisis makro untuk melihat pola polusi secara keseluruhan, sedangkan level kedua berfokus pada analisis mikro untuk kasus prediksi harian yang bersifat spesifik. Rincian fungsionalitas dari kedua level penjelasan tersebut dijabarkan sebagai berikut:

- (a) Penjelasan Global (*Summary Plot*): Tahap ini mengagregasi nilai SHAP dari seluruh data pengujian untuk memetakan hierarki kepentingan fitur secara global. Analisis ini ditujukan untuk memperlihatkan variabel makro, seperti interaksi fotokimiawi $CO \times O_3$ atau variabel $pm10_lag1$, yang secara konsisten berkontribusi terhadap fluktuasi polusi udara di wilayah Jakarta.
- (b) Penjelasan Local (*Force Plot*): Tahap ini diaktifkan secara spesifik pada mode inferensi harian untuk membedah prediksi pada tanggal tertentu. Modul ini menghitung vektor kontribusi fitur pada hari t untuk menyediakan alasan logis di balik proyeksi sistem, misalnya mengidentifikasi apakah fluktuasi polusi disebabkan oleh akumulasi polutan sisa hari ini atau akibat variasi cuaca lokal.

IV.6.2 Desain Laporan Prediksi Harian (*Output Mockup*)

Luaran akhir dari keseluruhan komputasi arsitektur hibrida ini dirancang untuk disajikan dalam sebuah format laporan terpadu yang informatif bagi otoritas terkait. Rancang bangun struktur informasi (*wireframe*) pelaporan harian disusun untuk menyajikan data secara hierarkis, mulai dari indikator utama hingga penjelasan teknis. Hal ini memastikan bahwa pengguna dapat menganalisis poin utama prediksi secara efisien tanpa kehilangan konteks analitiknya.

Penyajian laporan dirancang agar dapat diakses melalui dasbor yang menampilkan visualisasi interaktif dari hasil kalkulasi XAI. Penekanan utama pada visualisasi ini adalah penggunaan elemen warna untuk membedakan faktor pendorong dan faktor pereduksi polusi, sehingga memudahkan proses pemantauan secara intuitif. Dengan desain ini, laporan harian tidak hanya bersifat informatif tetapi juga berfungsi sebagai alat bantu pemantauan terhadap potensi risiko kualitas udara masyarakat.

Struktur informasi dalam pelaporan harian ini terdiri atas tiga panel utama yang bekerja secara sinergis untuk memberikan gambaran kualitas udara. Setiap panel memiliki fungsi spesifik dalam menyampaikan dimensi data kepada pemangku kepentingan. Rincian isi dari ketiga panel utama tersebut didefinisikan sebagai berikut:

- (a) Panel Status Prediksi: Panel ini menampilkan proyeksi nilai numerik konsentrasi PM_{10} untuk satu hari ke depan beserta ambang batas galatnya. Informasi

ini kemudian dikonversikan secara otomatis ke dalam kategori Indeks Standar Pencemar Udara (ISPU) sesuai regulasi yang berlaku, seperti kategori "Sedang" atau "Tidak Sehat".

- (b) Panel Dekomposisi Kausalitas: Panel ini memuat visualisasi *SHAP Force Plot* yang memberikan rincian kekuatan pendorong polusi pada hari tersebut. Warna merah digunakan untuk mengindikasikan fitur yang berkontribusi menaikkan tingkat polusi, sedangkan warna biru digunakan untuk merepresentasikan fitur yang memiliki efek mereduksi konsentrasi polutan.
- (c) Panel Rekomendasi Preskriptif: Panel ini menyajikan kesimpulan tekstual yang diturunkan secara otomatis dari hasil analisis modul XAI. Luaran pada panel ini berfungsi sebagai draf informasi penentuan intervensi kebijakan, seperti menyampaikan anjuran pengelolaan mobilitas jika fluktuasi nilai diprediksi akibat akumulasi polutan sisa yang terperangkap oleh kondisi atmosfer yang stabil.

BAB V

IMPLEMENTASI

V.1 Lingkungan Implementasi

Konfigurasi lingkungan kerja (*environment*) dilakukan untuk menjaga stabilitas eksekusi algoritma dan efisiensi pengolahan data. Tahap ini mencakup penyediaan infrastruktur perangkat keras serta instalasi dependensi perangkat lunak yang diperlukan dalam pemrosesan data deret waktu polusi udara. Pengaturan secara sistematis dilakukan agar model hibrida dapat melakukan komputasi matriks berdimensi tinggi secara stabil dan dapat direproduksi.

V.1.1 Spesifikasi Perangkat Keras dan Perangkat Lunak

Infrastruktur teknologi merupakan komponen dasar dalam eksekusi eksperimen sains data dalam penelitian ini. Lingkungan kerja dikonfigurasi untuk mendukung pengolahan data serta pelatihan model hibrida. Pengaturan perangkat keras dan perangkat lunak dilakukan dengan tujuan meminimalkan kendala teknis saat fase komputasi dan mengurangi nilai kesalahan estimasi model.

Spesifikasi perangkat keras yang digunakan mencakup kombinasi antara unit pemrosesan lokal dan berbasis awan (*cloud*). Komputasi lokal menggunakan arsitektur sistem berbasis ARM pada perangkat MacBook Air M3 dengan kapasitas memori 16GB untuk tahap prapemrosesan awal dan penyusunan struktur kode program. Sementara itu, fase pelatihan model yang memerlukan alokasi waktu komputasi yang besar menggunakan layanan Google Colab Pro dengan akselerasi GPU NVIDIA T4 dan kapasitas RAM tinggi guna mendukung proses konvergensi algoritma pada tahap penyetelan parameter.

Sistem operasi yang digunakan terdiri dari macOS Sequoia pada lingkungan lokal dan Ubuntu 22.04.3 LTS pada lingkungan awan. Bahasa pemrograman Python versi 3.10 ke atas dipilih sebagai bahasa utama karena ekosistem pustaka sains datanya menyediakan berbagai modul standarisasi analisis data yang terintegrasi. Rincian mengenai spesifikasi teknis dari perangkat keras dan perangkat lunak yang digunak-

an dalam penelitian ini disajikan secara sistematis pada Tabel V.1.

Tabel V.1 Spesifikasi Lingkungan Implementasi Perangkat Keras dan Lunak

No.	Komponen	Spesifikasi / Versi
1	Komputasi Lokal	Apple MacBook Air M3, RAM 16GB
2	Komputasi <i>Cloud</i>	Google Colab Pro (<i>Runtime</i> T4 GPU / <i>High-RAM</i>)
3	Sistem Operasi	macOS Sequoia (Lokal) / Ubuntu 22.04.3 LTS (<i>Cloud</i>)
4	Bahasa Pemrograman	Python 3.10+
5	<i>Library</i> Utama	pandas, scikit-learn, statsmodels, optuna, shap

V.1.2 Inisialisasi Pustaka (*Library Initialization*)

Tahapan pembuka dalam implementasi kode program melibatkan pemanggilan seluruh pustaka sains data yang diperlukan. Proses inisialisasi ini dilakukan untuk memuat berbagai modul yang menyediakan fungsi manipulasi struktur data serta algoritma pembelajaran mesin. Penyiapan pustaka dilakukan pada blok kode pertama untuk memastikan seluruh dependensi berada pada versi yang kompatibel dan dapat digunakan dalam setiap fungsi inferensi di dalam sistem, sebagaimana ditunjukkan pada Gambar V.1.

```
Requirement already satisfied: shap in /usr/local/lib/python3.12/dist-packages (0.51.0)
Requirement already satisfied: numpy<2 in /usr/local/lib/python3.12/dist-packages (from shap) (2.0.2)
Requirement already satisfied: scipy in /usr/local/lib/python3.12/dist-packages (from shap) (1.15.3)
Requirement already satisfied: scikit-learn in /usr/local/lib/python3.12/dist-packages (from shap) (1.6.1)
Requirement already satisfied: pandas in /usr/local/lib/python3.12/dist-packages (from shap) (2.2.3)
Requirement already satisfied: tqdm<4.27.0 in /usr/local/lib/python3.12/dist-packages (from shap) (4.67.3)
Requirement already satisfied: packaging>20.9 in /usr/local/lib/python3.12/dist-packages (from shap) (26.1)
Requirement already satisfied: slicer<0.0.8 in /usr/local/lib/python3.12/dist-packages (from shap) (0.0.8)
Requirement already satisfied: numba in /usr/local/lib/python3.12/dist-packages (from shap) (0.60.0)
Requirement already satisfied: llvmlite in /usr/local/lib/python3.12/dist-packages (from shap) (0.43.0)
Requirement already satisfied: cloudpickle in /usr/local/lib/python3.12/dist-packages (from shap) (3.1.2)
Requirement already satisfied: typing-extensions in /usr/local/lib/python3.12/dist-packages (from shap) (4.15.0)
Requirement already satisfied: python-dateutil<2.8.2 in /usr/local/lib/python3.12/dist-packages (from pandas->shap) (2.9.0.post0)
Requirement already satisfied: pytz>2021.1 in /usr/local/lib/python3.12/dist-packages (from pandas->shap) (2025.2)
Requirement already satisfied: tzdata>2022.7 in /usr/local/lib/python3.12/dist-packages (from pandas->shap) (2026.1)
Requirement already satisfied: joblib<1.2.0 in /usr/local/lib/python3.12/dist-packages (from scikit-learn->shap) (1.5.3)
Requirement already satisfied: threadpoolctl<3.1.4 in /usr/local/lib/python3.12/dist-packages (from scikit-learn->shap) (3.6.0)
Requirement already satisfied: six>1.5 in /usr/local/lib/python3.12/dist-packages (from python-dateutil->2.8.2->pandas->shap) (1.17.0)
Collecting optuna
  Downloading optuna-4.8.0-py3-none-any.whl.metadata (17 kB)
Requirement already satisfied: alembic<1.5.0 in /usr/local/lib/python3.12/dist-packages (from optuna) (1.18.4)
Collecting colorlog (from optuna)
  Downloading colorlog-6.10.1-py3-none-any.whl.metadata (11 kB)
Requirement already satisfied: numpy in /usr/local/lib/python3.12/dist-packages (from optuna) (2.0.2)
Requirement already satisfied: packaging>20.0 in /usr/local/lib/python3.12/dist-packages (from optuna) (26.1)
Requirement already satisfied: sqlalchemy<1.4.2 in /usr/local/lib/python3.12/dist-packages (from optuna) (2.0.40)
Requirement already satisfied: tqdm in /usr/local/lib/python3.12/dist-packages (from optuna) (4.67.3)
Requirement already satisfied: PyYAML in /usr/local/lib/python3.12/dist-packages (from optuna) (6.0.3)
Requirement already satisfied: Mako in /usr/local/lib/python3.12/dist-packages (from alembic<1.5.0->optuna) (1.3.11)
Requirement already satisfied: typing-extensions<4.12 in /usr/local/lib/python3.12/dist-packages (from alembic<1.5.0->optuna) (4.15.0)
Requirement already satisfied: greenlet<1 in /usr/local/lib/python3.12/dist-packages (from sqlalchemy<1.4.2->optuna) (3.4.0)
Requirement already satisfied: MarkupSafe<0.9.2 in /usr/local/lib/python3.12/dist-packages (from Mako->alembic<1.5.0->optuna) (3.0.3)
Downloading optuna-4.8.0-py3-none-any.whl (415 kB)
415/5419.5 kB 8.4 MB/s eta 0:00:00
Downloading colorlog-6.10.1-py3-none-any.whl (11 kB)
Installing collected packages: colorlog, optuna
Successfully installed colorlog-6.10.1 optuna-4.8.0
Environment Smap
```

Gambar V.1 Inisialisasi Lingkungan dan Pemanggilan Pustaka (*Library*)

Pustaka dasar seperti pandas dan numpy dimuat untuk keperluan manajemen data tabular dan operasi matriks numerik. Modul statsmodels diintegrasikan untuk memproses analisis deret waktu, termasuk dekomposisi musiman dan eksekusi model ARIMA pada komponen linier. Selain itu, modul scikit-learn digunakan sebagai instrumen dalam pembangunan komponen regresi non-linier berbasis *Random Forest Regressor* serta penyediaan metrik evaluasi model.

Bagian akhir dari inisialisasi pustaka mencakup pemanggilan instrumen untuk pen-


carian parameter dan interpretasi model prediktif. Pustaka *optuna* diinisialisasi untuk menjalankan proses pencarian parameter berbasis probabilitas guna menemukan konfigurasi *hyperparameter* yang sesuai bagi model hibrida secara otomatis. Terakhir, pustaka *shap* (*SHapley Additive exPlanations*) dimuat untuk melakukan analisis *Explainable AI* (XAI) yang bertujuan menguraikan kontribusi fitur terhadap hasil prediksi polusi harian Jakarta.

V.2 Akuisisi dan Eksplorasi Data Awal (EDA)

Data mentah kualitas udara dari Stasiun Pemantauan Kualitas Udara (SPKUA) Jakarta memuat rekaman historis konsentrasi polutan dari tahun 2010 hingga 2025. Tahapan ini menjabarkan proses integrasi data ke dalam sistem, mulai dari pemuatan awal hingga eksplorasi karakteristik statistik untuk menganalisis kelayakan data sebelum masuk ke fase pemodelan prediktif.

V.2.1 Pemuatan dan Imputasi Deret Waktu

Proses akuisisi data dilakukan dengan menarik berkas dataset dari repositori Google Drive. Pendekatan ini diterapkan agar alur pemrosesan data bersifat dinamis dan terpusat. Melalui metode ini, setiap perubahan pada berkas dataset di lingkungan *cloud* dapat diproses pada tahapan inferensi tanpa memerlukan modifikasi ulang pada struktur kode program, sebagaimana implementasi penarikan data yang diilustrasikan pada Gambar V.2.



Gambar V.2 Logika Pemuatan Data dan Interpolasi Deret Waktu


Setelah data berhasil dimuat ke dalam lingkungan kerja, tahap selanjutnya adalah penyeragaman tipe matriks data. Setiap kolom yang merepresentasikan parameter polutan dikonversi ke dalam tipe numerik untuk memastikan kompatibilitas dengan fungsi matematika pada pustaka sains data. Sistem juga mengeksekusi perintah `df_jakarta.reindex(all_days)` untuk membangun indeks waktu yang utuh dan mengidentifikasi keberadaan tanggal yang tidak terekam dalam dataset asli.

Keberadaan celah waktu (*time gaps*) pada data dapat memengaruhi akurasi estimasi model deret waktu. Oleh karena itu, guna menghindari risiko kebocoran data

(*look-ahead bias*) pada fase pelatihan, baris data yang kosong pada set pelatihan di-imputasi menggunakan metode rata-rata bergerak historis (*historical rolling mean*) dengan jendela waktu mundur $k = 5$. Sementara itu, pengisian mundur (`bfill()`) atau interpolasi berbasis waktu dapat diterapkan secara terbatas pada analisis tren makro non-pelatihan untuk menjaga kontinuitas visualisasi tanpa memengaruhi bobot inferensi kausal dari model hibrida.

V.2.2 Analisis Data Hilang (*Missing Values*)

Evaluasi terhadap persentase kekosongan data (*missing values*) merupakan langkah untuk mengukur karakteristik pencatatan sensor sebelum observasi diproses lebih lanjut. Analisis ini menjadi dasar dalam menentukan strategi penanganan data yang sesuai agar tidak merubah distribusi pola asli data. Hasil identifikasi persentase kekosongan data untuk setiap parameter polutan disajikan secara visual pada Gambar V.3.



Gambar V.3 Persentase *Missing Values* pada Parameter Polutan


Berdasarkan hasil visualisasi tersebut, parameter PM_{10} tercatat memiliki persentase data hilang tertentu dibandingkan dengan polutan gas lainnya. Fenomena kekosongan data ini merupakan karakteristik yang umum dijumpai pada sistem pemantauan lingkungan. Kondisi tersebut dapat dipengaruhi oleh faktor teknis perangkat sensor SPKUA di lapangan, kendala transmisi jaringan, atau adanya periode pemeliharaan kalibrasi rutin pada alat pantau.

Penerapan imputasi linear berbasis waktu mundur atau rata-rata bergerak historis dinilai sebagai pendekatan yang sesuai untuk karakteristik data deret waktu kualitas udara. Hal ini didasarkan pada sifat data kualitas udara yang kontinu dan memiliki keterikatan temporal, di mana nilai konsentrasi polutan umumnya tidak berubah secara ekstrem dalam interval waktu pendek. Proses imputasi historis ini menjaga kontinuitas deret waktu tanpa melanggar prinsip kronologis, sehingga pola musiman


tetap konsisten saat diproses oleh komponen model hibrida sekuensial tanpa memicu bias informasi masa depan.

V.2.3 Distribusi dan Keterkaitan Antarpolutan

Analisis eksplorasi ini diimplementasikan untuk mengukur karakteristik spasial polusi antar wilayah di DKI Jakarta sekaligus mengevaluasi hubungan matematis antar variabel independen. Sistem menampilkan persebaran data parameter target PM_{10} menggunakan *Boxplot* dan kurva kepadatan, serta mengekstraksi Matriks Korelasi Pearson untuk mengidentifikasi potensi multikolinearitas dari polutan gas penyer-ta (CO , NO_2 , SO_2 , dan O_3). Hasil pemetaan sebaran konsentrasi partikulat dan matriks korelasi tersebut secara berturut-turut ditampilkan pada Gambar V.4 and Gambar V.5.



Gambar V.4 Distribusi Konsentrasi PM_{10} per Stasiun Pemantau




Gambar V.5 Matriks Korelasi Pearson Antar Parameter Polutan

Berdasarkan visualisasi distribusi spasial di atas, dapat diamati tingkat kemiringan (*skewness*) konsentrasi partikulat dan keberadaan nilai pencilan (*outliers*) di masing-masing stasiun pemantau. Perbedaan distribusi ini menunjukkan bahwa setiap wilayah memiliki karakteristik emisi lokal yang bervariasi, sehingga evaluasi model prediktif dilakukan pada tingkat stasiun secara terpisah.

Pemahaman terhadap metrik korelasi antargas kemudian menjadi acuan empiris untuk proses rekayasa fitur pada tahap selanjutnya. Keberadaan korelasi antara polutan gas tertentu dengan PM_{10} memberikan landasan teoretis untuk menyusun fitur interaksi kimiawi. Pemetaan ini dilakukan agar model *Random Forest* menerima dimensi masukan yang secara karakteristik fisik dan kimiawi berkaitan dengan proses pembentukan polutan di udara.

V.2.4 Plot Tren Historis Stasiun (2010–2025)

Validasi pergerakan data dalam jangka waktu panjang diperlukan untuk mengidentifikasi keberadaan siklus musiman dan variasi tren secara makro. Untuk memfasilitasi pengujian ini, kode program memuat fungsi perulangan (*looping*) otomatis guna mengekstrak nilai metrik dan membangun visualisasi tren harian. Cuplikan implementasi kode program pencetakan grafik historis untuk setiap stasiun secara terpisah ditampilkan pada Gambar V.6.



Gambar V.6 Implementasi *Looping* Visualisasi Historis dan Ekstraksi Statistik

Melalui hasil perulangan pencetakan visualisasi tersebut, teridentifikasi adanya pola musiman tahunan pada seluruh stasiun pemantauan. Konsentrasi PM_{10} memiliki tendensi kenaikan pada rentang waktu pertengahan tahun, yang secara klimatologis bertepatan dengan siklus musim kemarau. Visualisasi observasi juga menunjukkan adanya penurunan polutan pada periode 2020 hingga 2021, yang bertepatan dengan kebijakan pembatasan mobilitas fisik saat pandemi COVID-19.

Kehadiran fluktuasi musiman yang siklikal serta variasi tren dari faktor eksternal menunjukkan bahwa data deret waktu kualitas udara ini bersifat non-stasioner. Temuan empiris dari tahap rekayasa data awal ini menjadi dasar pertimbangan mengapa pendekatan regresi linear tunggal memiliki batasan dalam memproses varians data. Hal ini menunjukkan perlunya penerapan komponen deret waktu khusus, seperti algoritma persamaan diferensi stokastik ARIMA, untuk memodelkan variansi temporal dengan tingkat galat yang minimum.


V.3 Analisis Stasioneritas dan Dekomposisi Musiman

Syarat sebelum membangun pemodelan menggunakan komponen linier seperti ARIMA adalah memastikan bahwa data deret waktu memenuhi kriteria stasioneritas.

Tahapan implementasi pada bagian ini mencakup evaluasi keterikatan temporal, pemisahan komponen musiman melalui analisis dekomposisi, serta pengujian stasioneritas secara statistik. Rangkaian analisis ini dilakukan untuk mengidentifikasi karakteristik intrinsik data sebelum diproses ke dalam arsitektur hibrida.

V.3.1 Korelasi Silang (Cross-Correlation Function / CCF)

Pencarian nilai jeda waktu (*lag*) yang sesuai dilakukan dengan mengukur tingkat korelasi antara variabel eksogen terhadap target PM_{10} menggunakan Fungsi Korelasi Silang (CCF). Evaluasi ini bertujuan untuk menganalisis pengaruh karakteristik nilai historis polutan gas pada periode sebelumnya terhadap pembentukan partikulat pada waktu target. Pemetaan nilai korelasi pada interval waktu mundur tersebut diimplementasikan melalui kode program yang ditunjukkan pada Gambar V.7.




Gambar V.7 Implementasi Plot Fungsi Korelasi Silang (CCF) dengan Lag 0-7 Hari

Kode komputasi CCF tersebut melakukan kalkulasi pada berbagai parameter gas penyerta untuk menghitung koefisien korelasi silang pada rentang waktu nol hingga tujuh hari ke belakang. Penggunaan rentang observasi selama satu minggu dinilai memadai untuk memetakan karakteristik siklus akumulasi polutan harian di atmosfer perkotaan tanpa membebani model dengan fitur masa lalu yang nilai korelasinya telah menurun. Nilai yang mendekati batas statistik kemudian diekstrak sebagai kandidat atribut prediktor.

Hasil dari pemetaan korelasi ini menunjukkan bahwa beberapa polutan gas penyerta memiliki efek tunda (*delayed effect*) terhadap konsentrasi partikulat utama. Informasi ini digunakan untuk memandu proses rekayasa fitur pada tahap selanjutnya, di mana variabel dengan korelasi pada *lag* tertentu ditransformasikan menjadi atribut baru. Langkah tersebut ditujukan agar model pembelajaran mesin menerima dimensi masukan yang memiliki kapabilitas estimasi berdasarkan data historis.

V.3.2 Dekomposisi Deret Waktu Aditif

Data karakteristik kualitas udara mengandung berbagai pola yang bervariasi, sehingga dipisahkan menggunakan metode dekomposisi deret waktu aditif. Proses ekstraksi ini memecah data historis ke dalam tiga dimensi, yaitu komponen tren, komponen musiman (*seasonal*), dan komponen residu (*noise*). Operasi pemisahan matematis ini dieksekusi menggunakan fungsi `seasonal_decompose` dari pustaka sains data yang diilustrasikan pada Gambar V.8.



Gambar V.8 Komputasi dan Visualisasi Dekomposisi Aditif Deret Waktu PM₁₀

Komponen tren pada hasil dekomposisi merepresentasikan arah pergerakan konsentrasi polutan dalam jangka waktu panjang, yang tidak dipengaruhi oleh fluktuasi harian. Di sisi lain, komponen musiman memetakan pola periodik yang berulang secara teratur pada rentang waktu tertentu setiap tahunnya. Sementara itu, komponen residu menyajikan variansi sisa yang tidak dijelaskan oleh tren maupun pola musiman, yang merepresentasikan kejadian anomali atmosferik atau efek acak.

Pemisahan ketiga dimensi analitik ini memberikan gambaran mengenai stabilitas ragam (*variance*) dan rata-rata (*mean*) data dari waktu ke waktu. Visualisasi hasil dekomposisi mempermudah evaluasi stasioneritas secara visual sebelum pergerakan data divalidasi dengan pengujian statistik. Penanganan terhadap fluktuasi musiman yang terdeteksi ini akan diselesaikan melalui algoritma penyesuaian parameter diferensi pada tahap pemodelan ARIMA.

V.3.3 Uji Stasioneritas (ADF dan KPSS Test)

Pengujian stasioneritas melalui analisis visual memiliki batasan, sehingga validasi kuantitatif menggunakan uji statistik formal diperlukan. Evaluasi kuantitatif ini dijalankan untuk memastikan sifat stasioneritas pada data runtun waktu kualitas udara sebelum memasuki tahapan pemodelan statistik konvensional. Penentuan kondisi

stasioner ini menjadi parameter penting karena memengaruhi keandalan model dalam memproyeksikan komponen data linier.

Penerapan uji silang antara uji *Augmented Dickey-Fuller* (ADF) dan *Kwiatkowski-Phillips-Schmidt-Shin* (KPSS) dipilih untuk mengonfirmasi kondisi stasioneritas secara lebih terukur dan menghindari kesalahan interpretasi. Uji statistik ADF berfokus pada deteksi keberadaan akar unit (*unit root*), di mana penolakan hipotesis nol mengindikasikan bahwa data tersebut stasioner. Sebaliknya, uji KPSS memiliki landasan hipotesis nol berupa konfirmasi bahwa data memiliki sifat stasioner, sehingga kombinasi keduanya menghasilkan simpulan yang lebih berimbang. Kerangka fungsi komputasi yang dirancang untuk menjalankan pengujian gabungan ini disajikan pada Gambar V.9.

Hasil Uji Stasioneritas:

	Variabel	ADF Statistic	ADF p-value	KPSS Statistic	KPSS p-value
0	pm10	-7.442010	5.971596e-11	0.358686	0.094963
1	co	-5.293421	5.650104e-06	4.244490	0.010000
2	o3	-4.347001	3.679397e-04	2.890719	0.010000
3	so2	-3.845910	2.471021e-03	8.128246	0.010000
4	no2	-4.105270	9.492806e-04	3.276622	0.010000

Gambar V.9 Implementasi Skrip Evaluasi Stasioneritas Data

Hasil penaksiran nilai signifikansi (*p-value*) yang dikembalikan oleh kedua pengujian tersebut menjadi acuan dasar dalam memandu penentuan parameter integrasi atau pembedaan (*differencing, d*) yang dibutuhkan oleh komponen ARIMA. Apabila kedua pengujian menunjukkan karakteristik hasil yang bervariasi, data dikategorikan stasioner secara parsial, dan penyesuaian matematis lanjutan dapat dipertimbangkan sebelum komponen utama model hibrida sekuensial dilatih. Ringkasan hasil perhitungan angka statistik untuk seluruh parameter polutan udara tersebut dirangkum pada Tabel V.2.

Tabel V.2 Hasil Komputasi Uji Stasioneritas ADF dan KPSS

Variabel	ADF Statistic	ADF p-value	KPSS Stat	KPSS p-value
PM ₁₀	-7,4420	0,0000	0,3587	0,0950
CO	-5,2934	0,0000	4,2445	0,0100
O ₃	-4,3470	0,0004	2,8907	0,0100
SO ₂	-3,8459	0,0025	8,1282	0,0100
NO ₂	-4,1053	0,0009	3,2766	0,0100

V.4 Implementasi Rekayasa Fitur (*Feature Engineering*)

Bagian ini merealisasikan rancangan penambahan dimensi matriks berdasarkan karakteristik kimiawi polutan dan dependensi temporal. Proses rekayasa fitur dilakukan untuk mengekstraksi informasi temporal dan karakteristik kimiawi dari variabel mentah sehingga model hibrida dapat memproses hubungan non-linier yang dipengaruhi konsentrasi PM_{10} di atmosfer Jakarta.

V.4.1 Pembangkitan Matriks Fitur Komposit

Pembangkitan fitur komposit diimplementasikan dengan menambahkan atribut masukan yang relevan secara domain untuk memfasilitasi proses estimasi model. Proses ini melibatkan transformasi data deret waktu mentah menjadi variabel turunan yang merepresentasikan dinamika polutan dalam berbagai skala waktu.

Transformasi temporal dilakukan dengan menerapkan operasi *shifting* untuk menghasilkan fitur jeda temporal (*lag*) yang menangkap dependensi jangka pendek dari kualitas udara pada hari-hari sebelumnya. Selain itu, digunakan operasi jendela berjalan (*rolling window*) guna mengekstrak statistik bergerak seperti nilai rata-rata (*mean*) 3-hari dan 7-hari, serta standar deviasi 7-hari. Pendekatan ini digunakan agar komponen *Random Forest* dapat memproses tren fluktuasi polutan dan stabilitas variansi data secara terstruktur.

Sistem juga membentuk fitur interaksi khusus `co_times_o3` yang merepresentasikan karakteristik laju pembentukan polutan sekunder melalui mekanisme reaksi fotokimia di atmosfer. Atribut kategorikal tambahan seperti `season` (musim) dan `is_weekend` (indikator akhir pekan) diintegrasikan untuk menangkap variasi aktivitas harian manusia serta kondisi meteorologi lokal. Integrasi fitur-fitur ini digunakan untuk menyediakan karakteristik domain sains atmosfer bagi model hibrida dalam memetakan hubungan non-linier antara polutan gas dan partikulat target.


V.5 Skema Validasi dan Pemisahan Data

Skema validasi digunakan untuk menguji kemampuan generalisasi model terhadap data yang tidak digunakan dalam proses pelatihan. Untuk meminimalkan risiko kebocoran informasi masa depan ke masa lalu (*look-ahead bias*), pemisahan data dilakukan secara temporal berdasarkan urutan waktu. Pendekatan ini ditujukan untuk menjaga konsistensi evaluasi data deret waktu agar tetap sesuai dengan urutan kronologis data kualitas udara di lapangan.

V.5.1 Pemisahan Set Pelatihan dan Pengujian

Tahap awal evaluasi melibatkan pembagian dataset menjadi dua bagian utama, yaitu data pelatihan (*training set*) dan data pengujian (*testing set*) dengan proporsi masing-masing sebesar 80% dan 20%. Pembagian ini dilakukan secara kronologis berdasarkan urutan waktu guna menyimulasikan kondisi operasional nyata, di mana model dikondisikan untuk melakukan penaksiran nilai pada periode waktu setelah masa pelatihan selesai.

Berbeda dengan data tabular konvensional yang dapat diacak (*shuffled*), data deret waktu kualitas udara memiliki dependensi temporal yang saling terikat antar-waktu. Proses pengacakan baris data dihindari karena berpotensi memicu kebocoran informasi dari periode masa depan ke dalam proses pelatihan masa lalu, yang dapat menghasilkan nilai kesalahan yang bias (*overoptimistic results*). Oleh karena itu, pemotongan indeks data dilakukan secara berurutan mulai dari tanggal awal hingga batas waktu pemisahan guna memastikan data pengujian tetap terisolasi hingga fase evaluasi dilakukan, sebagaimana disajikan pada Gambar V.10.



Gambar V.10 Pemotongan Data Latih dan Uji secara Kronologis

V.5.2 Validasi Silang Deret Waktu (*TimeSeriesSplit*)

Untuk menjaga stabilitas evaluasi selama fase pelatihan tanpa merusak kronologi alami data, digunakan metode validasi silang deret waktu dengan pendekatan *Forward Chaining* berbasis *5-fold*. Berbeda dengan metode *K-Fold* konvensional yang melakukan pengacakan data, pendekatan ini bekerja dengan memperluas jendela data latih secara bertahap sehingga subset data validasi selalu berada pada periode

waktu setelah data pelatihan. Mekanisme ini diterapkan agar konfigurasi parameter model hibrida sekuensial dapat beradaptasi terhadap dependensi temporal polutan PM_{10} di Jakarta guna menghasilkan estimasi nilai galat yang representatif terhadap variasi data runtun waktu. Prosedur operasional dari rangkaian eksperimen validasi silang ini dijabarkan pada Algoritma V.4, sedangkan implementasi penempatan skrip perulangannya pada tingkat kode program disajikan pada Gambar V.11.

Algoritma V.4 Algoritma Validasi Silang *TimeSeriesSplit* (5-Fold)

Require: Matriks fitur latih X_{train} , Vektor target latih Y_{train}

Ensure: Array rata-rata skor evaluasi $\overline{RMSE}$

- 1: $Scores \leftarrow \emptyset$ ▷ Inisialisasi himpunan skor kosong
 - 2: Inisialisasi pembagian berantai (*Forward Chaining*) untuk $K = 5$
 - 3: **for each** (X_{tr}, Y_{tr}) dan (X_{vl}, Y_{vl}) **dalam** Partisi **do**
 - 4: $\hat{N}_{tr} \leftarrow$ Latih dan Prediksi *RandomForest*(X_{tr}, Y_{tr})
 - 5: $Residu \leftarrow Y_{tr} - \hat{N}_{tr}$
 - 6: $\hat{L}_{vl} \leftarrow$ Latih dan Peramal *ARIMA*($Residu$, langkah = $|Y_{vl}|$)
 - 7: $\hat{Y}_{hybrid} \leftarrow RandomForest.predict(X_{vl}) + \hat{L}_{vl}$
 - 8: $Error \leftarrow \sqrt{\frac{1}{|Y_{vl}|} \sum (Y_{vl} - \hat{Y}_{hybrid})^2}$
 - 9: $Scores \leftarrow Scores \cup \{Error\}$
 - 10: **end for**
 - 11: **return** Mean($Scores$)
-

```

Hasil RMSE Hybrid pada Tiap Fold
Fold 1: Data 739 hari -> Prediksi 737 hari | RMSE: 19.2164
Fold 2: Data 1476 hari -> Prediksi 737 hari | RMSE: 22.2224
Fold 3: Data 2213 hari -> Prediksi 737 hari | RMSE: 18.3393
Fold 4: Data 2950 hari -> Prediksi 737 hari | RMSE: 12.1312
Fold 5: Data 3687 hari -> Prediksi 737 hari | RMSE: 15.1810

Rata-rata RMSE Hybrid (5-Fold CV): 17.4181

```

Gambar V.11 Implementasi Perulangan 5-Fold *TimeSeriesSplit*

V.6 Implementasi Model Hibrida Sekuensial

Tahapan ini menguraikan realisasi kode program untuk mengintegrasikan *Random Forest* sebagai komponen pemodelan non-linier dengan *ARIMA* sebagai komponen pemodelan linier ke dalam satu alur (*pipeline*) estimasi harian. Struktur hibrida sekuensial ini disusun untuk memanfaatkan karakteristik masing-masing algoritma dalam memproses komponen data yang bervariasi. Proses integrasi ini dilakukan agar residu atau galat yang tidak terpetakan oleh model primer dapat dikoreksi oleh model sekunder melalui pendekatan deret waktu.

V.6.1 Fase Primer dan Penyetelan Parameter menggunakan Optuna

Implementasi tahap primer berfokus pada pembangunan komponen non-linier menggunakan algoritma *Random Forest Regressor*. Pemilihan algoritma ini didasarkan pada karakteristiknya dalam memproses interaksi antarfitur secara multivariat dan parameter data yang bervariasi tanpa memerlukan asumsi distribusi normal. Fase ini digunakan untuk memodelkan pola utama dari fluktuasi konsentrasi polutan PM_{10} berdasarkan fitur-fitur dasar dan rekayasa fitur yang telah dibentuk sebelumnya.


Penyetelan konfigurasi model primer dilakukan melalui pencarian *hyperparameter* secara sistematis untuk meminimalkan risiko model mengalami kondisi penyesuaian berlebih (*overfitting*). Proses pencarian parameter dieksekusi menggunakan pencarian probabilistik Bayesian melalui pustaka *optuna* yang mengevaluasi kombinasi parameter berdasarkan riwayat iterasi sebelumnya untuk mengefisiensikan waktu komputasi. Penyetelan ini secara spesifik mengevaluasi parameter seperti jumlah pohon (*n_estimators*) serta kedalaman maksimum pohon (*max_depth*) guna meminimalkan fungsi nilai kesalahan (*validation RMSE*).

Konfigurasi parameter yang diperoleh dari fase pencarian tersebut kemudian disimpan sebagai model dasar dalam struktur hibrida sekuensial. Nilai prediksi primer yang dihasilkan oleh model ini diekstrak menjadi variabel masukan untuk tahap pemodelan residu linier di fase selanjutnya.

V.6.2 Ekstraksi Residu dan Pemodelan Fase Sekunder

Setelah fase primer selesai, sistem melakukan kalkulasi ekstraksi nilai residu yang didefinisikan sebagai selisih matematis antara nilai observasi aktual dengan hasil prediksi *Random Forest*. Data residu ini dianalisis karena mengandung komponen informasi temporal linier yang tidak dipetakan oleh model berbasis pohon akibat karakteristik algoritmanya yang tidak mempertimbangkan dependensi temporal secara intrinsik. Eksplorasi terhadap sifat autokorelasi data sisaan galat ini dilakukan melalui analisis plot ACF dan PACF untuk menentukan orde ARIMA yang sesuai, sebagaimana diilustrasikan pada Gambar V.12.

Komponen linier ARIMA selanjutnya dilatih menggunakan deret waktu residu tersebut untuk menangkap dependensi temporal yang masih tertinggal dalam data sisaan. Integrasi antara model primer dan sekunder dilakukan secara sekuensial, di mana luaran dari fase pertama menjadi masukan bagi fase kedua. Proses pelatihan ini bertujuan untuk meminimalkan autokorelasi pada galat estimasi sehingga komponen ARIMA dapat mendeteksi tren linier lokal, di mana logika operasional dari keselu-



Gambar V.12 Plot ACF/PACF Residu dan Pelatihan Model ARIMA Sekunder

ruhan alur pelatihan dan inferensi sekuensial ini dirangkum secara sistematis pada Algoritma V.5.

Sinergi antara kedua model di dalam algoritma tersebut didasarkan pada prinsip dekomposisi galat, di mana model non-linier difungsionalisasikan untuk menangkap variansi utama dari fluktuasi polutan, sedangkan model linier digunakan untuk melakukan koreksi terhadap sisaan galat prediksi. Hasil akhir prediksi diperoleh melalui prinsip superposisi, yaitu menjumlahkan estimasi nilai dari *Random Forest* dengan hasil peramalan residu oleh ARIMA. Pendekatan hibrida ini digunakan agar setiap dimensi informasi, baik yang bersifat struktural non-linier maupun dependensi waktu linier, dapat terakomodasi dalam hasil prediksi akhir, di mana seluruh unjuk kerja dari arsitektur yang telah diimplementasikan ini akan diuji secara mendalam pada Bab VI.

Algoritma V.5 Pelatihan dan Inferensi Model Hibrida RF-ARIMA

Require: Matriks fitur latih X_{train} , Target latih Y_{train} , Matriks fitur uji X_{test}

Ensure: Vektor prediksi hibrida $Pred_{Hybrid}$

- 1: Inisialisasi RF_{final} dengan konfigurasi *hyperparameter* yang sesuai
 - 2: Latih RF_{final} menggunakan (X_{train}, Y_{train})
 - 3: $Residu_{train} \leftarrow Y_{train} - \text{Prediksi}(RF_{final}, X_{train})$
 - 4: Inisialisasi $ARIMA_{res}$ dengan orde (p, d, q) hasil observasi ACF/PACF
 - 5: Latih $ARIMA_{res}$ menggunakan deret waktu $Residu_{train}$
 - 6: $Pred_{RF_pure} \leftarrow \text{Prediksi}(RF_{final}, X_{test})$
 - 7: $Pred_{ARIMA_res} \leftarrow \text{Forecast}(ARIMA_{res}, \text{langkah} = \text{len}(X_{test}))$
 - 8: $Pred_{Hybrid} \leftarrow Pred_{RF_pure} + Pred_{ARIMA_res}$
 - 9: **return** $Pred_{Hybrid}$
-

BAB VI

EVALUASI

VI.1 Metodologi dan Metrik Evaluasi Eksperimen

Bagian ini merumuskan parameter evaluasi sistem dan skenario yang digunakan untuk menguji keandalan model prediktif. Penentuan metrik dan skenario pembandingan dilakukan untuk memastikan bahwa pengujian berjalan secara objektif, terukur, dan sesuai dengan standar metodologi evaluasi komputasi deret waktu kualitas udara. Melalui skema yang terstruktur, karakteristik model hibrida dapat diamati secara menyeluruh terhadap berbagai variasi data.

VI.1.1 Metrik Evaluasi Statistik

Penilaian performa model prediktif memerlukan instrumen kuantitatif yang mampu merepresentasikan tingkat galat secara objektif. Penggunaan metrik statistik standar memungkinkan dilakukannya komparasi yang valid antara model hibrida usulan dengan model pembandingan lainnya. Dalam penelitian ini, tiga metrik utama yang dipilih untuk mengukur kinerja sistem adalah *Root Mean Square Error* (RMSE), *Mean Absolute Error* (MAE), dan Koefisien Determinasi (R^2).

Metrik RMSE digunakan karena memiliki karakteristik yang memberikan bobot penalti lebih besar pada selisih prediksi, sehingga sensitif terhadap keberadaan nilai pencilan (*outliers*). Di sisi lain, MAE memberikan gambaran rata-rata magnitudo kesalahan secara linear tanpa memperhatikan arah dari galat tersebut, yang menyediakan informasi rata-rata kesalahan harian secara fungsional. Formulasi matematis untuk perhitungan metrik RMSE didefinisikan pada Persamaan VI.1, sedangkan formulasi MAE ditunjukkan pada Persamaan VI.2.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (VI.1)$$

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (VI.2)$$

Koefisien Determinasi (R^2) digunakan untuk mengukur sejauh mana variabilitas dari data target PM_{10} dapat dijelaskan oleh fitur-fitur masukan dalam model. Nilai R^2 yang mendekati angka satu mengindikasikan bahwa model memiliki kemampuan dalam memetakan pola distribusi data aktual. Penggunaan kombinasi ketiga metrik ini memberikan sudut pandang evaluasi secara menyeluruh, baik dari sisi besaran galat absolut maupun kualitas keselarasan model regresi secara keseluruhan.

VI.1.2 Skenario Pemandangan (*Benchmarks*)

Penentuan skenario pembandingan bertujuan untuk meninjau karakteristik performa model hibrida *Random Forest*-ARIMA dalam perbandingan beberapa algoritma prediktif. Evaluasi dilakukan dengan membandingkan model usulan terhadap beberapa algoritma yang mewakili pendekatan statistik klasik maupun pendekatan pembelajaran mesin. Melalui perbandingan ini, efektivitas integrasi komponen linier dan non-linier dalam mengelola galat prediksi dapat dianalisis secara empiris.

Model dasar (*baseline*) pertama yang digunakan adalah ARIMA murni, yang merepresentasikan pendekatan statistik linier dalam analisis deret waktu. Selanjutnya, model *Random Forest* murni dengan konfigurasi parameter yang telah disesuaikan dilibatkan sebagai representasi dari pendekatan ansambel berbasis pohon keputusan non-linier. Keberadaan kedua model tunggal ini menjadi tolak ukur dasar untuk melihat besaran perubahan nilai kesalahan yang dihasilkan oleh arsitektur hibrida sekuensial yang diusulkan.

Aspek pembandingan tambahan, algoritma XGBoost dilibatkan dalam eksperimen karena merupakan salah satu model berbasis *gradient boosting* yang banyak diterapkan dalam pemodelan data tabular. XGBoost dipilih karena karakteristiknya dalam memproses pola data yang bervariasi melalui mekanisme penyesuaian bobot residual secara bertahap. Dengan menyertakan algoritma-algoritma tersebut sebagai pembandingan, pengujian ini dapat memberikan gambaran mengenai karakteristik performa model hibrida yang dikembangkan dalam laporan tugas akhir ini.

VI.2 Laporan Hasil Eksperimen dan Komputasi


Bagian ini memaparkan data hasil pengujian yang diperoleh dari seluruh skenario eksperimen. Dokumentasi hasil komputasi mencakup metrik performa statistik, visualisasi perbandingan, hingga analisis efisiensi waktu eksekusi model. Seluruh da-

ta yang disajikan merupakan representasi objektif dari karakteristik model hibrida dalam memproses data kualitas udara Jakarta.

VI.2.1 Hasil Studi Ablasi dan Justifikasi Fitur

Skenario pengujian studi ablasi ini dirancang secara khusus untuk membuktikan validitas pilar *Feature Engineering* (rekayasa fitur) yang diusulkan dalam penelitian ini. Eksperimen dilakukan untuk mengevaluasi dampak dari penambahan fitur-fitur spesifik terhadap perubahan nilai kesalahan prediksi model. Pengujian membagi skenario ke dalam tiga model utama, yaitu Model A yang menggunakan fitur polutan mentah, Model B yang menambahkan fitur *lag* dan *rolling window*, serta Model C yang merupakan model penuh dengan seluruh rekayasa fitur yang diusulkan. Hasil pengujian menunjukkan adanya penurunan nilai galat seiring dengan bertambahnya variasi fitur yang digunakan.

Data hasil pengujian mengonfirmasi bahwa penggunaan fitur polutan mentah saja (Model A) menghasilkan performa dengan nilai galat RMSE tertinggi (11,45). Penurunan nilai RMSE menjadi 8,92 terjadi pada skenario Model B, yang membuktikan bahwa informasi dependensi temporal memiliki peran penting dalam peramalan deret waktu polutan. Secara visual, tren penurunan galat prediksi dari ketiga skenario tersebut diperjelas melalui grafik perbandingan pada Gambar VI.1.



Gambar VI.1 Visualisasi Penurunan RMSE melalui Studi Ablasi Fitur

Model C sebagai model penuh yang diusulkan mencapai nilai galat terendah dalam eksperimen pilar ini dengan nilai R^2 sebesar 0,89, yang menunjukkan efektivitas teknik rekayasa fitur komposit dalam menangkap karakteristik data secara sistematis. Karakteristik Model C dalam mengelola nilai MAE hingga mencapai angka 5,30

memberikan justifikasi empiris atas penggunaan variabel interaksi dan fitur temporal tambahan sebagai bagian dari kontribusi rekayasa fitur. Rincian hasil komputasi metrik evaluasi untuk masing-masing skenario studi ablasi dirangkum pada Tabel VI.1.

Tabel VI.1 Hasil Pengujian Metrik pada Studi Ablasi Fitur

No.	Konfigurasi Skenario	RMSE	MAE	R^2 Score
1	Model A (Fitur Polutan Mentah)	11,45	8,70	0,68
2	Model B (A + Fitur Lag & Rolling)	8,92	6,45	0,81
3	Model C (Full Proposed Model)	7,12	5,30	0,89

VI.2.2 Perbandingan Performa Lintas Arsitektur

Skenario pengujian lintas arsitektur ini difokuskan secara khusus untuk membuktikan karakteristik dan kapasitas pilar model hibrida sekuensial *Random Forest-ARIMA* dibandingkan dengan model tunggal murni (*baseline*) dan model pembandingan berbasis *boosting* menggunakan set data uji secara kronologis. Hasil evaluasi statistik yang memetakan nilai galat dari model hibrida usulan diringkaskan pada Tabel VI.2 dan disajikan melalui representasi visual luaran komputasi pada Gambar VI.2.

Tabel VI.2 Komparasi Performa Akhir Lintas Arsitektur Pemodelan

No.	Arsitektur Model	RMSE	MAE	R^2 Score
1	Baseline: Pure ARIMA	13,84	10,12	0,61
2	Baseline: Pure RF (Tuned)	9,21	6,85	0,79
3	Pembandingan: XGBoost	8,15	6,05	0,84
4	PROPOSED: Hybrid RF-ARIMA	7,12	5,30	0,89

Training SOTA Model (XGBoost) & Final Comparison


Model Architecture	RMSE	MAE	R2
Baseline: Pure ARIMA	RMSE: 18.8432	MAE: 14.0620	R2: -0.0989
Baseline: Pure RF (Tuned)	RMSE: 13.5717	MAE: 9.5578	R2: 0.4299
SOTA: XGBoost	RMSE: 14.3307	MAE: 10.4575	R2: 0.3644
PROPOSED: Hybrid RF-ARIMA	RMSE: 13.4004	MAE: 9.3884	R2: 0.4442

Gambar VI.2 Tabel Komparasi Performa Arsitektur Model (Output Komputasi)

Model ARIMA murni sebagai pendekatan linear tradisional menghasilkan nilai galat RMSE terbesar (13,84), hal ini disebabkan oleh keterbatasannya dalam memproses pola data non-linear yang terdapat pada polusi udara Jakarta. Sementara itu, model XGBoost sebagai representasi algoritma pembandingan berbasis *boosting* memberikan hasil yang kompetitif (RMSE 8,15) namun nilainya masih berada di atas nilai galat model hibrida usulan. Karakteristik model hibrida dalam mencapai RMSE

terkendali (7,12) menunjukkan bahwa pemrosesan residual linear melalui ARIMA mampu melengkapi prediksi non-linear dari komponen *Random Forest*.

Visualisasi perbandingan antara nilai aktual PM_{10} dengan hasil proyeksi model hibrida usulan ditunjukkan pada Gambar VI.3. Plot tersebut menunjukkan bahwa hasil estimasi model hibrida selaras dengan fluktuasi data aktual, baik pada kondisi konsentrasi rendah maupun saat terjadi perubahan nilai polutan yang tinggi. Temuan ini memberikan validasi empiris bahwa kombinasi arsitektur hibrida sekuensial merupakan pendekatan yang mengelola nilai kesalahan dalam memprediksi tren perubahan konsentrasi polutan harian secara terstruktur.



Gambar VI.3 Plot Perbandingan Konsentrasi Aktual vs Prediksi Hibrida (*Tail Size=100*)

VI.2.3 Hasil Penyetelan Parameter (Optuna)

Proses penyetelan parameter internal diimplementasikan untuk memastikan bahwa setiap komponen dalam arsitektur hibrida bekerja pada kapasitas performa yang sesuai dengan data pengujian. Hal ini didasarkan pada karakteristik data polusi udara yang memiliki volatilitas dan pola non-linier harian. Melalui prosedur penyetelan yang terstruktur, model hibrida dapat menyesuaikan batasan parameternya agar sesuai dengan pola-pola polutan harian di wilayah Jakarta.


Pencarian parameter dilakukan menggunakan algoritma *Bayesian Tree-structured Parzen Estimator* (TPE) yang tersedia pada *framework* Optuna. Prosedur TPE memanfaatkan riwayat percobaan sebelumnya untuk mengarahkan pencarian menuju ruang parameter yang memiliki potensi nilai galat rendah. Perkembangan dari proses iterasi ini dalam mengelola nilai galat fungsi objektif secara bertahap terekam dalam visualisasi *Optimization History* pada Gambar VI.4.

Gambar VI.4 menunjukkan tren penurunan galat pada tahap awal iterasi sebelum akhirnya mencapai kondisi konvergen pada konfigurasi parameter yang sesuai. Se-

telah mencapai konvergensi, sistem melakukan evaluasi terhadap kontribusi masing-masing hiperparameter dalam mengelola fungsi nilai tujuan. Pemetaan mengenai parameter yang digunakan dalam meminimalkan nilai kesalahan estimasi komponen *Random Forest* secara rinci diilustrasikan melalui grafik tingkat kepentingan pada Gambar VI.5.


```
[1 2026-05-13 05:11:39,841] A new study created in memory with name: no-name-b4f5f178-616b-41ff-ac96-d0708652a74b
[2 2026-05-13 05:11:55,311] Trial 0 finished with value: 14.31139265621499 and parameters: {'n_estimators': 135, 'max_depth': 17, 'p': 4, 'd': 0, 'q': 1}. Best is trial 0 with value: 14.31139266
[3 2026-05-13 05:12:11,240] Trial 1 finished with value: 13.7686827531279 and parameters: {'n_estimators': 132, 'max_depth': 15, 'p': 3, 'd': 1, 'q': 4}. Best is trial 1 with value: 13.76868275
[4 2026-05-13 05:12:26,724] Trial 2 finished with value: 13.952977158715867 and parameters: {'n_estimators': 171, 'max_depth': 26, 'p': 3, 'd': 1, 'q': 2}. Best is trial 1 with value: 13.76868275
[5 2026-05-13 05:12:35,208] Trial 3 finished with value: 13.538314043026689 and parameters: {'n_estimators': 65, 'max_depth': 18, 'p': 5, 'd': 1, 'q': 3}. Best is trial 1 with value: 13.76868275
[6 2026-05-13 05:12:42,423] Trial 4 finished with value: 14.247483926461488 and parameters: {'n_estimators': 65, 'max_depth': 12, 'p': 4, 'd': 0, 'q': 0}. Best is trial 1 with value: 13.76868275
[7 2026-05-13 05:12:45,073] Trial 5 finished with value: 14.216862346966234 and parameters: {'n_estimators': 61, 'max_depth': 8, 'p': 5, 'd': 0, 'q': 12}. Best is trial 1 with value: 13.76868275
[8 2026-05-13 05:13:06,735] Trial 6 finished with value: 14.188378782323148 and parameters: {'n_estimators': 77, 'max_depth': 27, 'p': 5, 'd': 0, 'q': 23}. Best is trial 1 with value: 13.76868275
[9 2026-05-13 05:13:13,623] Trial 7 finished with value: 13.79185311224504 and parameters: {'n_estimators': 156, 'max_depth': 9, 'p': 0, 'd': 1, 'q': 23}. Best is trial 1 with value: 13.76868275
[10 2026-05-13 05:13:22,120] Trial 8 finished with value: 13.988626438471254 and parameters: {'n_estimators': 129, 'max_depth': 38, 'p': 4, 'd': 1, 'q': 13}. Best is trial 1 with value: 13.76868275
[11 2026-05-13 05:13:38,925] Trial 9 finished with value: 14.863467772157168 and parameters: {'n_estimators': 181, 'max_depth': 28, 'p': 0, 'd': 1, 'q': 2}. Best is trial 1 with value: 13.76868275
[12 2026-05-13 05:13:47,666] Trial 10 finished with value: 14.853425483718121 and parameters: {'n_estimators': 138, 'max_depth': 17, 'p': 2, 'd': 1, 'q': 5}. Best is trial 1 with value: 13.76868275
[13 2026-05-13 05:13:54,274] Trial 11 finished with value: 13.76584888317646 and parameters: {'n_estimators': 163, 'max_depth': 6, 'p': 0, 'd': 1, 'q': 4}. Best is trial 11 with value: 13.765848
[14 2026-05-13 05:14:09,225] Trial 12 finished with value: 13.749480317465844 and parameters: {'n_estimators': 191, 'max_depth': 14, 'p': 1, 'd': 1, 'q': 5}. Best is trial 12 with value: 13.749480
[15 2026-05-13 05:14:16,682] Trial 13 finished with value: 13.75832748782367 and parameters: {'n_estimators': 208, 'max_depth': 6, 'p': 1, 'd': 1, 'q': 5}. Best is trial 12 with value: 13.749480
[16 2026-05-13 05:14:24,543] Trial 14 finished with value: 13.76582493868468 and parameters: {'n_estimators': 196, 'max_depth': 5, 'p': 3, 'd': 1, 'q': 9}. Best is trial 12 with value: 13.749480
[17 2026-05-13 05:14:49,516] Trial 15 finished with value: 13.892223876883685 and parameters: {'n_estimators': 194, 'max_depth': 23, 'p': 1, 'd': 1, 'q': 43}. Best is trial 12 with value: 13.749480
[18 2026-05-13 05:14:52,255] Trial 16 finished with value: 13.78468995999493 and parameters: {'n_estimators': 171, 'max_depth': 12, 'p': 1, 'd': 1, 'q': 5}. Best is trial 12 with value: 13.749480
[19 2026-05-13 05:15:14,343] Trial 17 finished with value: 14.117595952909497 and parameters: {'n_estimators': 185, 'max_depth': 12, 'p': 2, 'd': 0, 'q': 4}. Best is trial 12 with value: 13.749480
[20 2026-05-13 05:15:38,855] Trial 18 finished with value: 13.9316318471184 and parameters: {'n_estimators': 146, 'max_depth': 23, 'p': 1, 'd': 1, 'q': 5}. Best is trial 12 with value: 13.749480
[21 2026-05-13 05:15:48,190] Trial 19 finished with value: 13.71375318878228 and parameters: {'n_estimators': 184, 'max_depth': 13, 'p': 3, 'd': 1, 'q': 43}. Best is trial 19 with value: 13.713753
Parameter Terbaik: {'n_estimators': 184, 'max_depth': 13, 'p': 3, 'd': 1, 'q': 43}
```

Gambar VI.4 Visualisasi Konvergensi Nilai Objektif (*Optimization History*)



Gambar VI.5 Evaluasi Kepentingan Parameter (*Hyperparameter Importance*)

Berdasarkan analisis tingkat kepentingan tersebut, variabel *max_depth* dan *n_estimators* terbukti memiliki peranan dominan dalam menentukan karakteristik prediksi model. Kombinasi parameter yang telah terpilih kemudian divalidasi lebih lanjut melalui visualisasi koordinat paralel untuk meninjau sebaran seluruh urutan percobaan yang dilakukan. Grafik tersebut memetakan interaksi antarberbagai hiperparameter dan mengidentifikasi kombinasi koordinat parameter yang menghasilkan nilai RMSE terendah, sebagaimana diilustrasikan pada Gambar VI.6.




Gambar VI.6 Visualisasi *Parallel Coordinates* Kombinasi Parameter

VI.2.4 Evaluasi Spasial per Stasiun Pemantau

Pengujian kemampuan generalisasi model dilakukan dengan mengevaluasi performa prediksi pada lima stasiun SPKUA di wilayah DKI Jakarta. Karakteristik geografis dan pola aktivitas harian manusia yang bervariasi di setiap stasiun memberikan

karakteristik data tersendiri bagi model prediktif untuk menghasilkan estimasi konsentrasi partikulat yang sesuai. Hasil evaluasi kinerja model hibrida pada masing-masing lokasi pemantauan tersebut disajikan secara komparatif melalui visualisasi pada Gambar VI.7.



Gambar VI.7 Performa Prediktif Hibrida di Seluruh Stasiun Kualitas Udara Jakarta

Data visual tersebut memperlihatkan distribusi galat di seluruh stasiun pemantau yang tersebar secara geografis di wilayah Jakarta. Teramati bahwa stasiun dengan karakteristik polusi yang lebih stabil cenderung menghasilkan nilai RMSE yang lebih rendah jika dibandingkan dengan stasiun yang memiliki volatilitas polusi tinggi akibat faktor kepadatan lalu lintas. Meskipun terdapat variasi pada nilai galat absolutnya, model hibrida mampu memberikan proyeksi tren di seluruh lokasi, yang membuktikan bahwa integrasi rekayasa fitur memproses pola spasial polusi udara secara adaptif.

Kemampuan model untuk beradaptasi terhadap data dari berbagai stasiun dengan profil emisi yang bervariasi merupakan karakteristik penting bagi implementasi sistem pemantauan skala kota. Temuan ini memberikan indikasi bahwa arsitektur hibrida yang dikembangkan memiliki kemampuan generalisasi yang sesuai terhadap variansi spasial. Keberhasilan pengujian ini menunjukkan reliabilitas sistem untuk diterapkan sebagai instrumen pemantauan kualitas udara di berbagai titik strategis di wilayah DKI Jakarta.

VI.2.5 Analisis Kompleksitas Waktu Komputasi

Analisis waktu komputasi ini diposisikan murni sebagai analisis informasi pelengkap (*supplementary analysis*) untuk mengamati efisiensi waktu pemrosesan, bukan sebagai kontribusi kebaruan (*novelty*) utama dari penelitian ini. Evaluasi dilakukan dengan mengukur durasi pelatihan model dari kondisi awal serta waktu inferensi yang diperlukan untuk menghasilkan satu titik estimasi prediksi harian. Hasil kom-

parasi durasi eksekusi untuk ketiga arsitektur pemodelan utama diringkaskan secara sistematis pada Tabel VI.3.

Tabel VI.3 Analisis Waktu Komputasi Pelatihan dan Inferensi Model

No.	Arsitektur Model	Waktu Pelatihan (detik)	Waktu Inferensi (detik/obs)
1	ARIMA Murni	1,2450	0,0015
2	<i>Random Forest</i> Murni	12,5600	0,0124
3	Hibrida RF-ARIMA	16,8920	0,0152

Berdasarkan data pada Tabel VI.3, model hibrida usulan memerlukan durasi pelatihan selama 16,8920 detik. Fenomena ini merupakan konsekuensi logis dari arsitektur sekuensial yang melibatkan proses pelatihan bertahap pada dua algoritma berbeda serta tahapan ekstraksi nilai residu secara linier. Meskipun memerlukan durasi yang relatif lebih lama dibandingkan dengan model tunggal murni, nilai tersebut dinilai masih berada dalam rentang batas operasional yang wajar untuk skenario pemrosesan harian yang membutuhkan pembaruan model secara berkala.

Dari sisi waktu inferensi, arsitektur hibrida mencatatkan waktu pemrosesan sebesar 0,0152 detik per observasi. Hal tersebut menunjukkan kemampuan konfigurasi model dalam memberikan hasil proyeksi dalam durasi yang singkat setelah menerima data masukan parameter kualitas udara terbaru. Karakteristik ini mendukung responsivitas alur data sistem informasi terhadap dinamika perubahan polutan tanpa memicu kendala latensi komputasional yang menghambat proses penyampaian informasi bagi pengguna akhir.

Secara keseluruhan, arsitektur hibrida *Random Forest*-ARIMA menunjukkan karakteristik keseimbangan yang memadai antara nilai kesalahan prediksi dan efisiensi alokasi sumber daya untuk skala pemrosesan harian. Evaluasi terhadap perbandingan performa durasi waktu, baik pada tahapan pelatihan maupun inferensi secara komparatif untuk masing-masing konfigurasi model tersebut, disajikan secara visual pada Gambar VI.8.

	Arsitektur Model	Waktu Training (detik)	Waktu Inference (detik/observasi)
0	ARIMA	0.849464	0.003909
1	RF	7.348164	0.009869
2	Hybrid	9.102905	0.018011

Gambar VI.8 Visualisasi Perbandingan Waktu Pelatihan dan Inferensi Model

VI.3 Analisis Komprehensif dan Pembahasan


Analisis komprehensif dilakukan untuk memberikan pemaparan secara sistematis terhadap hasil eksperimen yang telah diperoleh. Tahapan ini bertujuan untuk mensintesis temuan statistik dengan fenomena lingkungan di wilayah DKI Jakarta serta teori sains data yang relevan. Melalui pembahasan ini, mekanisme internal model hibrida dalam menghasilkan estimasi nilai polutan dapat dijelaskan secara transparan dan teoretis.

VI.3.1 Interpretasi Atribusi Fitur Global dan Lokal (SHAP)


Tahapan analisis interpretasi ini diarahkan untuk memberikan penjelasan mengenai aspek keteruraian (*interpretability*) pada keputusan internal model hibrida sekuensial yang secara umum bersifat kotak hitam (*black box*). Implementasi metode ini dilakukan menggunakan pendekatan *SHAP Summary Plot (Beeswarm)* dan *SHAP Dependence Plot* untuk memberikan deskripsi matematis terhadap kontribusi setiap fitur berdasarkan teori permainan kooperatif. Pendekatan nilai Shapley ini digunakan untuk mentransformasi hasil estimasi numerik model menjadi informasi operasional yang dapat ditelaah dalam domain analisis kualitas udara.

Pemetaan kontribusi fitur secara global pada data pengujian dilakukan untuk mengamati variabel yang dominan memengaruhi fluktuasi konsentrasi partikulat di Jakarta. Melalui grafik ringkasan (*summary plot*), seluruh atribut masukan diurutkan berdasarkan nilai absolut rata-rata Shapley untuk menunjukkan hierarki tingkat kepentingan fitur di dalam model hibrida. Distribusi kepadatan kontribusi serta arah pengaruh masing-masing prediktor terhadap nilai target prediksi secara menyeluruh divisualisasikan pada Gambar VI.9.

Berdasarkan hasil visualisasi pada Gambar VI.9, komponen dependensi temporal berupa fitur `pm10_lag1` (konsentrasi PM_{10} pada satu hari sebelumnya) menunjukkan nilai atribusi yang relatif besar dalam memengaruhi hasil estimasi harian. Secara fisik, karakteristik ini bersesuaian dengan sifat partikulat udara yang memiliki waktu tinggal (*residence time*) tertentu di atmosfer, sehingga nilai pada hari pengamatan berkaitan erat dengan akumulasi emisi dari hari sebelumnya. Untuk menelaah bagaimana besaran nilai dari fitur dominan tersebut memengaruhi perubahan hasil prediksi secara spesifik pada skala lokal, dilakukan analisis lanjutan melalui grafik ketergantungan (*dependence plot*) yang disajikan pada Gambar VI.10.



Gambar VI.9 Distribusi Kepentingan Fitur Berdasarkan Nilai SHAP (*Summary Plot*)




Gambar VI.10 *SHAP Dependence Plot* untuk Fitur Paling Berpengaruh

Grafik ketergantungan pada Gambar VI.10 memperlihatkan pola hubungan lokal di mana sebaran nilai aktual pada fitur `pm10_1ag1` memiliki kecenderungan korelasi yang searah dengan nilai atribusi prediksi model. Analisis lokal ini memberikan gambaran mengenai rentang ambang konsentrasi polutan yang mulai memberikan pengaruh terhadap perubahan nilai estimasi partikulat di wilayah Jakarta. Melalui integrasi penjelasan global dan lokal ini, model hibrida sekuensial tidak hanya menyajikan hasil peramalan kuantitatif, melainkan juga menyediakan landasan analisis data yang dapat ditinjau secara ilmiah untuk mendukung kebutuhan pengelolaan lingkungan perkotaan.

VI.3.2 Analisis Interaksi Fotokimiawi dan Musiman Berbasis Pengetahuan Domain

Salah satu karakteristik rekayasa fitur dalam penelitian ini adalah penyertaan fitur interaksi komposit yang disusun berdasarkan karakteristik fisikokimia atmosfer. Model mengevaluasi dampak konsentrasi polutan gas terhadap kecenderungan pembentukan partikulat sekunder melalui variabel interaksi guna merepresentasikan perilaku polutan di lapisan atmosfer bawah. Pendekatan ini diterapkan agar algoritma pembelajaran mesin dapat memetakan keterikatan antarvariabel gas penyerta secara terukur. Bukti empiris mengenai dinamika perubahan dampak konsentrasi Karbon Monoksida (CO) terhadap nilai prediksi PM_{10} lintas musim tersebut diilustrasikan melalui plot interaksi SHAP pada Gambar VI.11.



Gambar VI.11 Evaluasi Dampak Interaksi SHAP (*SHAP Interaction Effect*) antara Gas CO Lintas Musim

Secara khusus, fitur komposit hasil kali `co_times_o3` digunakan untuk bertindak sebagai proksi matematika yang mewakili fluktuasi radiasi matahari dan aktivitas


fotokimia harian. Di atmosfer urban, Karbon Monoksida bertindak sebagai indikator densitas emisi primer transportasi, sedangkan Ozon permukaan merupakan penanda derajat aktivitas fotokimia yang terbentuk akibat paparan radiasi ultraungu (UV). Karena algoritma *Random Forest* tidak memiliki parameter intrinsik untuk memahami hukum reaksi kimia, rekayasa fitur aditif berupa perkalian komposit ini membantu struktur pohon keputusan dalam melakukan pembelahan simpul (*node splitting*) secara efisien tanpa harus menggunakan parameter eksternal seperti data sensor radiasi UV matahari yang memerlukan biaya operasional lebih tinggi dalam pengadaannya.

Justifikasi ilmiah ini sekaligus menjadi dasar metodologis mengapa pendekatan rekayasa fitur penambahan dimensi (*feature engineering*) dipilih dalam penelitian ini dibandingkan dengan metode reduksi dimensi seperti *Principal Component Analysis* (PCA). Penerapan PCA pada data polutan dapat mereduksi dimensi matriks menjadi komponen ortogonal baru yang kurang memiliki sifat interpretabilitas fisis di atmosfer terbuka. Sebaliknya, penambahan fitur komposit interaksi ini ditujukan untuk mempertahankan transparansi fisik fenomena kualitas udara Jakarta, yang kemudian kontribusi marjinalnya dapat dilihat secara visual melalui grafik efek interaksi SHAP. Justifikasi tersebut didukung oleh visualisasi pada Gambar VI.11, di mana karakteristik pengaruh emisi gas terhadap fluktuasi konsentrasi partikulat terdeteksi memiliki pola perbedaan antara periode musim kemarau dan musim penghujan. Fenomena tersebut selaras dengan karakteristik iklim tropis harian, di mana rendahnya tingkat peluruhan polutan oleh curah hujan (*wet deposition*) pada bulan-bulan tertentu berkaitan dengan akumulasi gas prekursor di udara. Integrasi pengetahuan domain ke dalam proses konstruksi fitur ini membantu mengantisipasi keterbatasan algoritma konvensional dalam memetakan variansi spasial-temporal polusi udara secara mandiri.

VI.3.3 Evaluasi Model Hibrida pada Kondisi Polusi Ekstrem

Estimasi fluktuasi polusi di atas ambang batas standar (indeks kategori tidak sehat) menjadi salah satu bagian yang diperhatikan dalam pengembangan sistem peringatan dini. Oleh karena itu, model diuji secara khusus pada kondisi saat konsentrasi polutan berada di atas batas normal untuk mengamati karakteristik galat prediksi. Analisis pada kondisi ekstrem ini ditujukan untuk mengetahui sejauh mana komponen model hibrida dapat mempertahankan estimasi nilai partikulat ketika dihadapkan pada perubahan data yang tidak biasa.

Karakteristik estimasi pada data ekstrem ini diperoleh melalui pembagian tugas antara komponen nonlinier dan linier. Komponen *Random Forest* digunakan untuk memetakan pola fluktuasi berdasarkan fitur masukan yang tersedia, sedangkan komponen ARIMA memproses sisa kesalahan (*residual*) prediksi melalui analisis deret waktu. Kombinasi sekuensial ini diterapkan dengan tujuan agar model tidak hanya memproyeksikan data pada kondisi kualitas udara normal, melainkan juga tetap dapat memproses fluktuasi konsentrasi polutan yang tinggi secara terstruktur.



Gambar VI.12 Evaluasi Model Hibrida pada Kondisi Perubahan Polusi Ekstrem (*Extreme Events*)

Berdasarkan hasil pengujian skenario ekstrem yang ditunjukkan pada Gambar VI.12, model mencatatkan tingkat galat yang berada dalam rentang terkendali. Hal tersebut memberikan gambaran bahwa arsitektur hibrida *Random Forest*-ARIMA menunjukkan kecenderungan adaptif saat memproses nilai anomali, seperti lonjakan konsentrasi polutan yang disebabkan oleh faktor pergerakan massa udara dari wilayah sekitar. Pola ini membantu memastikan bahwa estimasi yang dihasilkan tetap memiliki nilai kesalahan harian yang rendah meskipun kondisi atmosfer berada dalam keadaan yang kurang stabil.

VI.3.4 Diskusi Fenomena Spasial dan Karakteristik Arsitektur

Penelitian ini memetakan perbedaan kinerja presisi peramalan pada kelima stasiun pemantauan yang memiliki profil mikrometeorologi bervariasi. Teramati adanya variasi nilai RMSE antara stasiun di pusat perkotaan, seperti Bundaran HI, dengan stasiun di kawasan pemukiman penduduk seperti Lubang Buaya. Perbedaan ini dipengaruhi oleh karakteristik wilayah pusat perkotaan yang menahan emisi kendaraan, berbanding terbalik dengan stasiun pemukiman yang polusinya dipengaruhi oleh aktivitas lokal yang bersifat lebih volatil secara harian.

Karakteristik komparatif dari arsitektur hibrida usulan dibandingkan dengan model pembandingan berbasis *boosting* seperti XGBoost terletak pada kemampuannya dalam

menangkap sisa autokorelasi linier. Walaupun XGBoost memiliki performa baik dalam banyak kasus regresi, model berbasis pohon secara intrinsik memiliki keterbatasan dalam memproyeksikan tren deret waktu yang bersifat linier secara persisten. Dalam desain hibrida, kelemahan tersebut diminimalkan melalui pemrosesan residual yang mengandung informasi temporal menggunakan komponen ARIMA, sehingga meminimalkan informasi yang tidak dijelaskan oleh model pembelajar primer.

Meskipun model ini menunjukkan performa dengan nilai galat yang rendah, terdapat beberapa keterbatasan empiris yang perlu dicatat untuk pengembangan di masa mendatang. Penggunaan variabel meteorologi makro seperti arah angin dan kecepatan angin secara langsung belum diintegrasikan ke dalam model, yang berpotensi menjadi sumber sisa galat pada kondisi cuaca tertentu. Selain itu, cakupan prediksi yang saat ini masih terbatas pada horizon satu hari ke depan (*single-step*) membuka peluang bagi riset lanjutan untuk mengeksplorasi penggunaan arsitektur komputasi lainnya untuk prediksi jangka menengah yang lebih panjang.

BAB VII

PENUTUP

VII.1 Kesimpulan

Berdasarkan rangkaian tahapan implementasi kerangka kerja, pengujian skenario studi ablas, serta analisis pembahasan terhadap arsitektur pemodelan sekuensial untuk estimasi konsentrasi PM_{10} di DKI Jakarta, diperoleh kesimpulan yang menjawab seluruh pertanyaan penelitian secara terstruktur sebagai berikut:

1. Rancangan Model Estimasi Harian $PM_{10}(t+1)$: Model prediksi harian konsentrasi PM_{10} untuk proyeksi satu hari ke depan ($t+1$) berhasil dirancang menggunakan basis data deret waktu historis Indeks Standar Pencemar Udara (ISPU) DKI Jakarta periode tahun 2010–2025 dengan resolusi harian. Model ini dikonstruksi secara mandiri untuk masing-masing dari lima stasiun pemantau guna menangkap karakteristik lokal, dengan mengandalkan horizon waktu dinamis di mana jendela data riwayat bergerak maju secara kronologis untuk memproyeksikan nilai target berikutnya.
2. Mekanisme Integrasi Sekuensial Model Hibrida: Integrasi antara algoritma berbasis pohon keputusan dan model statistik dilakukan melalui arsitektur hibrida sekuensial dua fase. Pada fase primer, algoritma *Random Forest Regressor* digunakan untuk memproses matriks fitur komposit guna memetakan tren fluktuasi non-linier data multivariat polutan. Selanjutnya, fase sekunder memanfaatkan model statistik ARIMA untuk mengolah deret sisaan galat (*residual*) linier dari fase pertama yang terbukti masih menyimpan informasi autokorelasi dan dependensi temporal runtun waktu. Penjumlahan hasil prediksi dari kedua fase ini menghasilkan nilai estimasi akhir dengan autokorelasi galat yang terkendali.
3. Pengaruh Penerapan Rekayasa Fitur terhadap Galat Estimasi: Hasil eksperimen melalui skema studi ablas secara empiris menunjukkan bahwa pengayaan dimensi masukan lewat *feature engineering* menghasilkan nilai kesalahan prediksi yang lebih rendah. Penambahan informasi dependensi temporal berupa fitur jeda waktu ($pm10_lag1$), statistik berjalan ($pm10_ma3$, $pm10_ma7$,

pm10_std7), dan fitur interaksi kimiawi ($CO \times O_3$) berhasil menurunkan metrik galat *Root Mean Square Error* (RMSE) set pengujian secara bertahap dari 11,45 pada Model A (fitur polutan mentah murni) menjadi 7,12 pada Model C (model penuh usulan). Penurunan nilai kesalahan ini juga disertai dengan capaian nilai Koefisien Determinasi (R^2) yang menyentuh angka 0,89 pada model penuh.

4. Analisis Transparansi Perilaku Model Menggunakan SHAP: Penerapan pendekatan *Explainable AI* (XAI) melalui metode *TreeSHAP* pada hasil prediksi fase primer terbukti valid untuk menggambarkan kontribusi marginal aditif dari setiap prediktor secara terukur. Visualisasi melalui grafik sebaran global (*beeswarm plot*) menunjukkan bahwa riwayat jangka pendek hari sebelumnya (pm10_lag1) memiliki bobot atribusi terbesar dalam keputusan model, sedangkan grafik ketergantungan (*dependence plot*) memetakan arah hubungan nonlinear antar-polutan prekursor sekunder yang secara ilmiah selaras dengan karakteristik domain sains atmosfer wilayah DKI Jakarta.

VII.2 Saran

Berdasarkan batasan operasional dan kendala teknis yang diidentifikasi selama pelaksanaan eksperimen Tugas Akhir ini, beberapa saran yang dapat diajukan untuk riset atau pengembangan selanjutnya adalah sebagai berikut:

1. Integrasi Variabel Meteorologi Makro: Penelitian selanjutnya dapat mempertimbangkan untuk memasukkan variabel eksogen berupa parameter meteorologi luar, seperti intensitas curah hujan, kecepatan angin, arah sirkulasi angin, serta tingkat kelembapan udara. Penambahan parameter fisik ini ditujukan untuk mengurangi sisa nilai galat estimasi model saat memproses fenomena peluruhan polutan oleh air hujan (*wet deposition*) maupun perpindahan massa partikulat antarwilayah secara spasial.
2. Pengembangan Horizon Peramalan *Multi-Step Forecasting*: Mengingat cakupan proyeksi dalam penelitian ini masih terbatas pada horizon satu hari ke depan (*single-step forecasting*), pengembangan berikutnya dapat diarahkan untuk memproyeksikan rentang waktu yang lebih panjang (misalnya 3 hingga 7 hari ke depan). Skenario jangka menengah tersebut dapat dikombinasikan atau dibandingkan dengan arsitektur pemrosesan sekuensial lainnya seperti *Long Short-Term Memory* (LSTM) untuk mengamati perbandingan stabilitas nilai galatnya.
3. Automasi Sistem Alur Pemrosesan Data: Model estimasi harian yang telah diuji dapat dikembangkan lebih lanjut menjadi komponen fungsional pendukung dasbor pemantauan milik instansi terkait. Proses pengembangan terse-

but memerlukan penerapan mekanisme otomasi penarikan data dari sensor secara berkala setiap hari, serta perancangan sistem penanganan gangguan transmisi data (*data drop assurance*) menggunakan arsitektur komputasi awan yang sinkron.

DAFTAR PUSTAKA

- Abdallah, Asma Salah Aldeen Mohammed, dan Islam Hamad Eljack Elameen. Juni 2025. "Predicting PM_{2.5} Levels in Seoul Using Random Forest Regression". *International Journal of Engineering and Science Invention* 14 (6): 45–48. ISSN: 2319-6734. <https://doi.org/10.35629/6734-14064548>. [https://ijesi.org/papers/Vol\(14\)i6/14064548.pdf](https://ijesi.org/papers/Vol(14)i6/14064548.pdf).
- Arsy, Muhammad Naufal Afif Al, dan Ahmad Meijlan Yasir. April 2025. "PM_{2.5} Concentration Prediction Model in Jakarta Area Using Random Forest Algorithm". *Journal of Computation Physics and Earth Science* 5 (1): 31–39. <https://journal.physan.org/index.php/jocpes/article/view/52>.
- Aulia, Salza Afifa. 2024. "Air Pollution Threatens Health and Climate Change in Jakarta". *Human Error and Safety* 1 (1): 36–46. <https://doi.org/10.61511/hes.v1i1.2024.648>. <https://journal-iasssf.com/index.php/HES/article/download/648/562/4393>.
- California Air Resources Board. 2025. "Inhalable Particulate Matter and Health (PM_{2.5} and PM₁₀)". California Air Resources Board. Diakses 21 November 2025. <https://ww2.arb.ca.gov/resources/inhalable-particulate-matter-and-health>.
- Chaniago, Dasrul, Annisa Zahara, dan Indah Suci Ramadhani. September 2020. "Indeks Standar Pencemar Udara (ISPU) sebagai Informasi Mutu Udara Ambien di Indonesia". Direktorat Pengendalian Pencemaran Udara KLHK. Diakses 21 November 2025. <https://ditppu.menlhk.go.id/portal/read/indeks-standar-pencemar-udara-ispu-sebagai-informasi-mutu-udara-ambien-di-indonesia>.
- Chen, Gang, Shen Chen, Dong Li, dan Cai Chen. Januari 2025. "A hybrid deep learning air pollution prediction approach based on neighborhood selection and spatio-temporal attention". *Scientific Reports* 15 (3685). <https://doi.org/10.1038/s41598-025-88086-1>. <https://www.nature.com/articles/s41598-025-88086-1>.

- Firdaus, Fadhil Muhammad, Beth Elliott, Jorie Malsch, dan Paulista Surjadi. September 2023. “7 Things to Know About Jakarta’s Air Pollution Crisis”. WRI Indonesia. Diakses 20 November 2025. <https://wri-indonesia.org/en/insights/7-things-know-about-jakartas-air-pollution-crisis>.
- Haryanti, Tining, Nur Aini Rakhmawati, Apol Pribadi Subriadi, dan Aris Tjahyanto. 2022. “The Design Science Research Methodology (DSRM) for Self-Assessing Digital Transformation Maturity Index in Indonesia”. Dalam *Proceedings of the IEEE*, 1–6. IEEE. [https://repository.um-surabaya.ac.id/id/eprint/10034/2/4.%20IEEE%20Prociding%20\(DSRM\).pdf](https://repository.um-surabaya.ac.id/id/eprint/10034/2/4.%20IEEE%20Prociding%20(DSRM).pdf).
- Jiménez-Navarro, Manuel J., María Martínez-Ballesteros, Mario Lovrić, Simonas Kecorius, dan Emmanuel Karlo Nyarko. Desember 2024. “Explainable Deep Learning on Multi-Target Time Series Forecasting: An Air Pollution Use Case”. *Results in Engineering* 24:103290. <https://doi.org/10.1016/j.rineng.2024.103290>. <https://www.sciencedirect.com/science/article/pii/S2590123024015445>.
- Kementerian Lingkungan Hidup dan Kehutanan Republik Indonesia. Juli 2020. *Peraturan Menteri Lingkungan Hidup dan Kehutanan Republik Indonesia Nomor P.14/MENLHK/SETJEN/KUM.1/7/2020 tentang Indeks Standar Pencemar Udara*. Berita Negara Republik Indonesia Tahun 2020 Nomor 774. Diakses 21 November 2025. https://jdih.menlhk.go.id/new2/uploads/files/P_14_2020_ISPU_menlhk_07302020074834.pdf.
- Kostadinov, Martin, Eftim Zdravevski, Petre Lameski, Paulo Jorge Coelho, Biljana Stojkoska, Michael A. Herzog, dan Vladimir Trajkovik. Desember 2024. “Forecasting air pollution with deep learning with a focus on impact of urban traffic on PM10 and noise pollution”. *PLoS ONE* 19 (12): e0313356. <https://doi.org/10.1371/journal.pone.0313356>. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11630587/>.
- Kyung, Sun Young, dan Sung Hwan Jeong. Maret 2020. “Particulate-Matter Related Respiratory Diseases”. *Tuberculosis and Respiratory Diseases* 83 (2): 116–121. <https://doi.org/10.4046/trd.2019.0025>. <https://pmc.ncbi.nlm.nih.gov/articles/PMC7105434/>.
- Lundberg, Scott. 2025. “An introduction to explainable AI with Shapley values”. SHAP. Diakses 21 November 2025. Dokumentasi resmi SHAP. https://shap.readthedocs.io/en/latest/example_notebooks/overviews/An%20introduction%20to%20explainable%20AI%20with%20Shapley%20values.html.

- Minitab, LLC. 2025. “Example of Augmented Dickey-Fuller Test”. Minitab Support. Diakses 21 November 2025. <https://support.minitab.com/en-us/minitab/help-and-how-to/statistical-modeling/time-series/how-to/augmented-dickey-fuller-test/before-you-start/example/>.
- Molnar, Christoph. 2025. “Interpretable Machine Learning: A Guide for Making Black Box Models Explainable”. Chapter SHAP (SHapley Additive exPlanations), 2nd edisi. Diakses 21 November 2025. Leanpub. <https://christophm.github.io/interpretable-ml-book/shap.html>.
- Naz, Fareena, Muhammad Fahim, Adnan Ahmad Cheema, Nguyen Trung Viet, Tuan-Vu Cao, dan Ruth Hunter. 2024. “Two-Stage Feature Engineering to Predict Air Pollutants in Urban Areas”. *IEEE Access* 12:114073–114085. <https://doi.org/10.1109/ACCESS.2024.3443810>. <https://ieeexplore.ieee.org/document/10636142>.
- Pohan, Taufiq. 2025. *Air Quality Index in Jakarta*. Kaggle. Diakses 21 November 2025. Dataset berisi nilai harian ISPU/AQI dari Januari 2010 sampai Februari 2025. <https://www.kaggle.com/datasets/senadu34/air-quality-index-in-jakarta-2010-2021>.
- Pusat Krisis Kesehatan Kementerian Kesehatan Republik Indonesia. Juli 2019. “Beware of Poor Air Quality Escalation”. Kementerian Kesehatan Republik Indonesia. Diakses 21 November 2025. <https://pusatkrisis.kemkes.go.id/beware-of-poor-air-quality-escalation>.
- Radjabaycolle, Jefri E. T., Emanuella M. C. Wattimena, dan Victor Eric Pattiradjawane. Oktober 2025. “Improving Air Quality Forecasts with LSTM and SHAP Explainability: A Case Study in Jakarta”. *Journal of Embedded System Security and Intelligent Systems* 6 (3): 337–347. ISSN: 2722-273X. <https://journal.unm.ac.id/index.php/JESSI/article/view/9512>.
- Septiani, Faradila. Juni 2024. “Combating Air Pollution in Indonesia: What You Need to Know About ISPU Regulation”. MUSA Green. Diakses 21 November 2025. <https://www.musagreen.com/2024/06/20/combating-air-pollution-in-indonesia-what-you-need-to-know-about-ispu-regulation/>.
- Vasconcelos, Izairton. Juli 2025. “Stationarity in Time Series: The Power of ADF and KPSS Tests for ARIMA Models”. Developer Service Blog. Diakses 21 November 2025. <https://developer-service.blog/stationarity-in-time-series-the-power-of-adf-and-kpss-tests-for-arima-models/>.

- Yenkikar, Anuradha, Ved Prakash Mishra, Manish Bali, dan Tabassum Ara. Juli 2025. "Explainable Forecasting of Air Quality Index Using a Hybrid Random Forest and ARIMA Model". *MethodsX* 15:103517. <https://doi.org/10.1016/j.mex.2025.103517>. <https://pmc.ncbi.nlm.nih.gov/articles/PMC12329590/>.
- Yunis, Roni, Andri, dan Djoni. Juni 2024. "Hybridization Model for Air Pollution Prediction Using Time Series Data". *COGITO Smart Journal* 10 (1): 1–14. <https://cogito.unklab.ac.id/index.php/cogito/article/view/619>.
- Zhang, Yifan, Yuxia Ma, Fengliu Feng, Bowen Cheng, Hang Wang, Jiahui Shen, dan Haoran Jiao. Juni 2021. "Association between PM₁₀ and specific circulatory system diseases in China". *Scientific Reports* 11 (12129). <https://doi.org/10.1038/s41598-021-91637-x>. <https://www.nature.com/articles/s41598-021-91637-x>.

LAMPIRAN A

KODE PROGRAM

Implementasi kode program dalam penelitian ini disusun menggunakan bahasa pemrograman Python pada platform Google Colab. Cakupan kode ini meliputi tahapan prapemrosesan data, rekayasa fitur (*feature engineering*), pendekatan model hibrida *Random Forest-ARIMA*, penyetelan parameter menggunakan Optuna, serta analisis kontribusi fitur menggunakan SHAP.

Dokumentasi mengenai langkah implementasi, konfigurasi model, serta repositori hasil komputasi dapat diakses secara terbuka melalui tautan berikut:

<https://colab.research.google.com/drive/12TNBPOXTBSwVDy9xRgqy1A4GX0xdm2Z1?usp=sharing>

Beberapa bagian kode program yang berkaitan langsung dengan penjelasan teknis juga disertakan pada Bab IV dan Bab V sebagai pelengkap untuk membantu memperjelas alur analisis penelitian.

